УРАЛЬСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ
ИМЕНИ ПЕРВОГО ПРЕЗИДЕНТА РОССИИ Б.Н. ЕЛЬЦИНА

На правах рукописи
УДК 004.93

ГЛАЗЫРИН НИКОЛАЙ ЮРЬЕВИЧ

ОБ АЛГОРИТМИЧЕСКОМ РАСПОЗНАВАНИИ АККОРДОВ В ЦИФРОВОМ ЗВУКЕ

Специальность 05.13.18 —
«Математическое моделирование, численные методы и комплексы программ»

Диссертация на соискание учёной степени
кандидата физико-математических наук

Научный руководитель:
уч. степень, уч. звание
Волков М.В.

Екатеринбург – 2013

Содержание

Введение

С давних времён в области музыки возникают задачи воспроизведения (в том числе повторного), записи, хранения, классификации, поиска. В настоящее время все они решаются в том числе с помощью компьютеров. Тематика данной работы относится к областям классификации и поиска музыки.

На текущий момент компьютер является основным средством для хранения и обработки музыки и любой информации о музыке, будь то ноты, биография композитора, год выпуска записи или график концертов группы. Сама по себе музыка, содержащаяся в цифровых звукозаписях, более ценна для человека, поскольку никакая информация о ней не может заменить собой её прослушивание. Вместе с тем, именно эта дополнительная информация даёт возможность ориентироваться в музыкальных коллекциях, находить новую музыку, организовывать существующие записи. В силу большей ценности музыки, зачастую звукозаписи не сопровождаются дополнительной информацией. Необходимость получения разнообразной информации о данной цифровой звукозаписи порождает множество задач, связанных с обработкой звука: идентификация композиции, нахождение разных версий одной композиции, определение заданной композиции в потоке звука с радио, поиск похожих композиций, определение мелодии композиции для последующего воспроизведения на музыкальном инструменте и другие. Эта диссертация посвящена задаче определения последовательности аккордов в звуке.

Одним из способов решения названных задач является автоматизированное при помощи компьютера извлечение мелодии и/или аккордов из цифровой записи звука с последующим использованием извлеченной информации для индексации, поиска, сравнения. Данная диссертация посвящена задаче определения последовательности аккордов в звуке, представленном в цифровом виде.

Аккорды – это основная информация, необходимая гитаристу для того, чтобы сыграть композицию. Многочисленные гитаристы-любители, не имеющие достаточно опыта или усидчивости, чтобы самостоятельно определить звучащие аккорды, смогут получить инструмент, решающий эту задачу за них. Такой инструмент может быть полезен при обучении музыке, в курсах гармонии, музыкальной формы, сольфеджио.

Информация о последовательности аккордов может быть использована также для индексации композиций и последующего поиска по запросу. Среди возможных сценариев такого поиска можно отметить следующие:

- поиск заимствований или разных версий одной и той же композиции;
- поиск композиций, которые могут гармонично сочетаться друг с другом.

Последовательность аккордов может быть представлена в текстовом виде. С одной стороны, представление звука в виде последовательности символов позволяет перенести задачи индексации и поиска музыки в хорошо проработанную область индексации и поиска текстов. С другой стороны, такое представление композиции позволяет человеку вводить поисковые запросы без использования звуковых файлов.

Первые попытки обработки музыкальной информации в символьном виде были сделаны в 1950-х годах с появлением первых компьютеров. Они были связаны с автоматическим опре-

делением закономерностей в музыке с целью использования их для создания новых мелодий (см. [1]). Тогда же было предложено использовать компьютер для распознавания и печати нотных записей, анализа схожести различных композиций и поиска по образцу. В 1960-х годах появляются первые работы (например, [2]), связанные с анализом звукозаписей, представленных в цифровом виде. Их целью было, прежде всего, понимание того, из чего состоят воспроизводимые музыкальными инструментами звуки и как они воспринимаются человеком.

В 1975 году в [3] было положено начало новому применению компьютера к анализу цифровых музыкальных звукозаписей: распознаванию в них отдельных нот. Этот процесс объединяют с компьютерным распознаванием нотных записей под общим названием *транскрибирование*. Здесь впервые теория музыки используется для анализа композиции не в виде нотной записи, а в том виде, в котором её воспринимает обычный слушатель – в виде звукозаписи. Несмотря на раннюю постановку и большое количество приложенных усилий, задача транскрибирования музыкальной звукозаписи не решена до сих пор.

В 1982 году компаниями Sony и Philips было запущено массовое производство компакт-дисков, на которых музыка была записана в цифровом формате. Со временем доступных в цифровом виде произведений стало на порядки больше, чем доступных нотных записей. Закономерно возрос интерес к автоматическому транскрибированию музыки. В [3] рассматривались только звукозаписи, содержащие не более двух одновременно звучащих музыкальных инструментов. В 1996 году в [4] был представлен один из первых методов, подходивших для любой многоголосной цифровой аудиозаписи.

Задача определения последовательности аккордов при этом не отделялась от задачи транскрибирования. Как отмечает Т. Фуджишима в [5], в 1980-1990-х годах (например, в работе [6]) проблема распознавания аккордов в музыке решалась путём распознавания отдельных нот и их объединения в аккорды. Он же впервые предложил метод распознавания аккордов без предварительного транскрибирования звукозаписи. В [6] метод распознавания аккордов являлся частью системы для автоматического аккомпанемента выступлению живого человека.

В 2000-х годах определение аккордов окончательно выделяется в отдельную задачу. Начиная с 2008 года в рамках ежегодной кампании по оценке методов музыкального информационного поиска MIREX [7] проводятся соревнования среди алгоритмов распознавания аккордов в музыкальном звучании. За это время был достигнут существенный прогресс в качестве распознавания. В 2012 году на это соревнование были выставлены более 10 алгоритмов.

В 2010-х годах появляются широко доступные программные продукты, включающие в себя такие алгоритмы. Популярный пакет для профессионального создания музыки *Ableton Live 9* [8] позволяет преобразовать любую звукозапись, в том числе полифоническую, в нотное представление в редакторе. Эта возможность может быть использована в первую очередь как альтернативный способ ввода нотных данных для последующего редактирования.

Приложения для смартфонов *AnySong Chord Recognition* [9] и *Chord Detector* [10] позволяют определить аккорды в звуковом файле и показывают соответствующие гитарные табулатуры, позволяя играть на гитаре композицию одновременно с её воспроизведением. Соответственно, эти приложения нацелены в первую очередь на использование с музыкой для гитары.

Интернет-сервис Chordify [11] позволяет определить последовательность аккордов в произвольном видео с `http://youtube.com`, аудио с `http://soundcloud.com` или в загруженной пользователем звукозаписи, после чего воспроизвести звук или видео с одновременной индикацией звучащего аккорда. Наряду с недостаточным качеством распознавания, недостатком этого продукта является отсутствие возможности поиска по заданной последовательности аккордов. На сегодняшний день автору не известны какие-либо продукты, предназначенные для обработки коллекции разнообразных музыкальных звукозаписей с целью поиска похожих или гармонично сочетающихся друг с другом композиций.

Музыкальные звуки имеют длительность, которая, как правило, существенно меньше длительности всей композиции. Аккорд как совокупность звуков также имеет определенную относительно небольшую длительность. Поэтому естественно анализировать звукозапись, разделяя её на короткие фрагменты соразмерной длины. Для каждого фрагмента вычисляется набор признаков, по которому определяется соответствующий аккорд. Итоговое качество распознавания зависит как от выбора признаков, так и от алгоритма, сопоставляющего набору признаков аккорд.

Признаки позволяют представить в компактном по сравнению со звукозаписью виде основную информацию о звуке в данном фрагменте. В отличие от амплитудно-частотного представления, признаки не содержат дубирующейся информации. Было предложено большое количество разнообразных алгоритмов получения звуковых признаков, использующих особенности звучания музыкальных инструментов, особенности человеческого восприятия и возможные помехи на звукозаписях.

В 2010-х годах становятся чрезвычайно популярными так называемые методы обучения представлениям. Они, фактически, являются алгоритмами со множеством автоматически подбираемых параметров, позволяющими получить признаки, наилучшим образом отражающие необходимую для дальнейшего использования информацию. За исключением Хамфри [12] никто не применял методы глубокого обучения к распознаванию аккордов.

Наиболее простым способом определения аккорда по набору признаков является метод ближайшего соседа: вычисление расстояний от заданного набора до «идеальных», шаблонных наборов признаков для каждого аккорда. При этом можно рассматривать разные метрики в пространстве признаков.

Вероятностные модели позволяют найти в некотором смысле наилучшую из заданного класса метрик. Большинство алгоритмов, представленных в рамках соревнований MIREX Audio Chord Estimation, используют скрытую марковскую модель или байесовскую сеть и моделируют последовательность векторов признаков как марковский процесс. При этом наблюдениями модели являются признаки в каждом фрагменте, а скрытыми состояниями – соответствующие аккорды. Параметры моделей настраиваются в процессе обучения на размеченных данных. Несмотря на достаточно высокое качество распознавания аккордов, такого рода модели имеют свои недостатки. Среди них Де Хаас в [13] выделяет следующие:

- Потребность в большом количестве данных для обучения. Подготовка таких данных весьма трудоёмка, а сами данные могут сильно разниться для разных стилей музыки, эпох, композиторов.

- Опасность переобучения. Модели с большим количеством параметров наилучшим образом подстраиваются под доступный набор обучающих данных, но непонятно, насколько хорошо они будут подходить для работы с данными не из обучающей выборки.

- Многомерность данных. Она приводит к экспоненциальному увеличению объема данных и времени их обработки, а также к росту необходимого объёма обучающей выборки.

- Недостаточное использование времени. Марковское свойство предполагает зависимость только от предыдущего фрагмента. Но музыкальная композиция зачастую имеет определённую, достаточно протяжённую по времени, структуру, которая не может быть отражена в модели.

- Существуют другие условия, которые также не могут быть выражены в рамках обучаемой модели. Например, это культурный или географический контекст или сложившиеся практики и правила создания музыки.

- Сложность интерпретации модели, оперирующей в большей степени искусственными, математическими, нежели музыкальными конструкциями.

Ещё одним недостатком является то, что упомянутые вероятностные методы хорошо приспособлены для моделирования смены состояния (звучащего аккорда) и хуже – для моделирования продолжительности нахождения в одном состоянии.

Перечисленные проблемы не могут быть разрешены в рамках модели, строящейся исключительно путём обучения на реальных данных. Де Хаас предложил другую модель, которая строится на основе правил западной тональной гармонии без использования алгоритмов машинного обучения, а следовательно, менее подверженную описанным выше недостаткам. Она допускает простую интерпретацию и может быть использована для гармонического анализа композиции. Эта модель позволяет корректировать последовательность, полученную после вычисления евклидовых расстояний между векторами признаков и шаблонами аккордов. К сожалению, при попытке применения модели ко всей последовательности расстояний требуется перебор слишком большого количества вариантов. Поэтому требуется разделять последовательность на короткие участки. Другим недостатком этой модели является необходимость привязки к фрагментам, для которых считается, что аккорд изначально был определён верно. Ошибка в таком фрагменте влечёт за собой ошибки в соседних фрагментах.

Таким образом, разработка метода для распознавания последовательности аккордов, не требующего большого объема данных для обучения, и не предполагающего использования сложной многопараметрической самообучающейся модели, но при этом сопоставимого по качеству результатов с уже существующими методами, является вполне естественной и актуальной. Именно разработка такого метода стала целью для автора данной работы.

С учётом описанных выше недостатков существующих подходов, для достижения поставленной цели перед автором данной работы были поставлены следующие задачи:

1. разработать метод для более точного выделения в звуке компонент, соответствующих музыкальным инструментам, с целью улучшения существующих алгоритмов вычисления признаков по фрагменту звукозаписи;

2. исследовать применимость некоторых универсальных методов обучения представлениям к получению музыкальных признаков;

3. улучшить алгоритм определения аккорда по вектору признаков, использующий сопоставление с шаблонами аккордов;

4. реализовать описанные алгоритмы в виде комплекса программ, позволяющего распознавать последовательность аккордов в поданном на вход звуковом файле;

5. сравнить качество распознавания аккордов с аналогами, приняв участие в соревновании MIREX Audio Chord Estimation.

В рамках данной работы все поставленные задачи были решены.

При решении поставленных задач в работе использованы методы математического моделирования, спектральный анализ (для получения и обработки спектрограммы), алгоритмы машинного обучения (для получения признаков), методы объектно-ориентированного программирования и многопоточного программирования (для реализации описанных методов и ускорения вычислений).

В диссертации получены следующие основные результаты, которые выносятся на защиту.

1. Новый метод распознавания последовательности аккордов в звукозаписи, не использующий алгоритмов машинного обучения.

2. Новый метод представления звукозаписи в виде последовательности векторов признаков с применением многослойной нейронной сети.

3. Сравнительный анализ результатов работы предлагаемых методов на коллекции из 319 звукозаписей, подтверждающий их эффективность.

4. Реализующий предложенные методы комплекс программ на языках Java и Python, созданный в рамках данной работы.

Разработанный метод распознавания последовательности аккордов может применяться для анализа звукозаписей с целью их самостоятельного воспроизведения, с целью поиска схожих музыкальных композиций. Метод не подвержен опасности переобучения под конкретную музыкальную коллекцию.

Основные результаты диссертационной работы докладывались на всероссийской научной конференции "Анализ Изображений, Сетей и Текстов"(Екатеринбург, 2012), на всероссийской научной конференции "Анализ Изображений, Сетей и Текстов"(Екатеринбург, 2013), на 9-й международной конференции по вычислениям в области звука и музыки (Копенгаген, 2012), на 13-й конференции международного сообщества по музыкальному информационному поиску (Порто, 2012).

Результаты изложены в 4 печатных изданиях, 1 из которых изданы в журналах, рекомендованных ВАК, 3 – в тезисах докладов всероссийских и международных конференций. Алгоритм был выставлен на соревнования среди алгоритмов распознавания аккордов MIREX Audio Chord Estimation 2012 [14], [15] и MIREX Audio Chord Estimation 2013 [**?**], [**?**], проводимые международной лабораторией оценки систем музыкального информационного поиска (International Music Information Retrieval Systems Evaluation Laboratory) университета Иллинойса, США.

Журналы из перечня ведущих периодических изданий:

Н. Ю. Глазырин: "О задаче распознавания аккордов в цифровых звукозаписях Известия Иркутского государственного университета, серия "Математика 2013, Т. 6, № 2. с. 2-17.

Тезисы международных конференций:

Nikolay Glazyrin, Alexander Klepinin: «Chord Recognition using Prewitt Filter and Self-Similarity», Proceedings of the 9th Sound and Music Computing Conference, Copenhagen, Denmark, 11-14 July, 2012, pp. 480-485.

Тезисы всероссийских конференций:

Николай Глазырин, Александр Клепинин: «Выделение гармонической информации из музыкальных аудиозаписей». Доклады всероссийской научной конференции "Анализ Изображений, Сетей и Текстов"(АИСТ 2012), Москва, Национальный Открытый Университет "Интуит с. 159-168.

Николай Глазырин: «Применение автоассоциаторов к распознаванию последовательностей аккордов в цифровых звукозаписях», Доклады всероссийской научной конференции "Анализ Изображений, Сетей и Текстов"(АИСТ 2013), Москва, Национальный Открытый Университет "Интуит с. 199-203.

Все исследования, результаты которых изложены в данной работе, получены лично соискателем в процессе научных исследований. Из совместных публикаций в диссертацию включен лишь тот материал, который непосредственно принадлежит соискателю.

Диссертация состоит из введения, четырех глав, заключения и двух приложений. Полный объем диссертации составляет XXX страница с XX рисунками и XX таблицами. Список литературы содержит XXX наименований.

В главе 1 представлены необходимые для дальнейшего изложения сведения из теории музыки. Делается формальная постановка и теоретические основы задачи распознавания аккордов в музыке.

Глава 2 посвящена подробному обзору литературы по рассматриваемой теме.

В главе 3 описываются улучшения для алгоритмов вычисления векторов признаков и получения аккорда по вектору признаков. Вычисление спектрограммы с повышенным разрешением

по времени и частоте с последующим применением скользящего фильтра и прореживанием позволяет лучше сохранить компонеты спектра звука, соответствующие звучанию музыкальных инструментов с определённой высотой звучания. Это помогает получить векторы признаков, в большей степени сохраняющие необходимую для определения аккорда информацию. Коррекция вектора признаков с использованием наиболее схожих с ним других векторов, а также некоторые эвристические правила для коррекции последовательности распознанных аккордов дают возможность исправить некоторые ошибки определения звучащего аккорда. Описанные улучшения позволили вплотную приблизить качество распознавания аккордов к результатам алгоритмов, использующих обучаемые вероятностные модели.

В главе 4 описывается способ вычисления векторов признаков с использованием различных вариантов многослойных автоассоциаторов. Рассматриваются также рекуррентные многослойные автоассоциаторы, позволяющие моделировать зависимость вектора признаков на текущем фрагменте от векторов признаков на предыдущих фрагментах звукозаписи. Автору не удалось добиться повышения качества распознавания аккордов с использованием признаков, полученных с при помощи автоассоциаторов, в сравнении с признаками, алгоритмы вычисления которых придуманы и настроены человеком.

В главе 5 описываются и анализируются результаты экспериментов. Исследуется влияние параметров описанных алгоритмов на результат, а также количественный вклад каждого из реализованных методов в повышение качества распознавания аккордов.

Глава 1

Необходимые теоретические сведения

Для формальной постановки задач, рассматриваемых в данной работе, требуются некоторые специальные теоретические сведения из музыкальной теории. Данная глава предназначена для знакомства читателя с соответствующей областью музыкальной теории и формализации рассматриваемых в данной работе задач. В параграфе 1.1 даются базовые понятия звука и спектра. В параграфе 1.2 описываются основные свойства звука с точки зрения теории музыки. В разделе 1.3 разъясняются основные понятия из теории музыки, необходимые для дальнейших рассуждений. В параграфе 1.4 представлены основы представления звука в цифровом виде. В параграфе 1.5 указаны характерные черты музыкальных звукозаписей, которые могут быть использованы для решения рассматриваемых задач. В параграфе 1.6 приведена формальная постановка задачи.

1.1 Звук

Большая Советская Энциклопедия [16], с. 432, определяет звук в широком смысле как колебательное движение частиц упругой среды, распространяющееся в виде волн в газообразной, жидкой или твёрдой средах. В воздухе звук передается как последовательность сгущений и разрежений. Поэтому звук можно считать непрерывной функцией $x(t)$, показывающей зависимость давления воздуха в данной точке от времени. В рамках данной работы нас будет интересовать только звук в узком смысле как явление, субъективно воспринимаемое человеком через органы слуха. Уловленные ими колебания преобразуются в нервные импульсы, которые передаются в мозг человека. Воспринимаемый человеком звук $x'(t)$ определяется как общим строением органов слуха, так и их индивидуальными особенностями для конкретного человека.

Если звук был вызван колебательным процессом с периодом T_0 и частотой $f_0 = \frac{1}{T_0}$, то полученный звуковой сигнал также будет иметь *период* T_0 и *частоту* f_0. Будем называть такой звук *чистым тоном*. Реальные звуковые сигналы обычно вызваны множеством колебаний с различными частотами, поэтому можно говорить о *частотном спектре* звука или его *спектральной функции* $a(f)$ в заданный момент времени. Это неотрицательная функция, которая отражает зависимость интенсивности (амплитуды) колебаний на конкретной частоте от этой частоты в данном звуковом сигнале $x(t)$ в момент времени t. Также выделяют спектр мощности и фазовый спектр сигнала. В дальнейшем, если не оговорено иное, под спектром будет пониматься частотный спектр звукового сигнала.

Спектр сигнала меняется со временем, поэтому имеет смысл анализировать его в окрестности $[t_{start}, t_{end}]$ некоторой точки t. Размер окрестности должен быть не меньше периода самой низкой из частот спектра. Понятно, что для более высоких частот достаточно меньшей окрестности. Поэтому приходится принимать допущение о том, что спектр звука не меняется

(или меняется незначительно) в пределах данной окрестности. Для более высоких частот, соответственно, спектр будет усреднен по промежутку $[t_{start}, t_{end}]$.

Любой ограниченный сигнал, определённый на промежутке $[t_{start}, t_{end}]$, можно периодически продолжить на всю вещественную ось с периодом $\tau = t_{end} - t_{start}$. Продолженная таким образом функция $x(t)$ будет ограниченной. Потребуем также, чтобы она была непрерывной. Этого можно добиться, например, сделав плавное затухание сигнала рядом с точками t_{start}, t_{end} путем умножения на гладкую функцию, равную нулю в этих точках. Заданная таким образом функция будет непрерывной и ограниченной, поэтому она может быть однозначно выражена в виде ряда гармонических функций (или *гармоник*), частоты которых кратны $1/\tau$:

$$x(t) = a_0 + \sum_{k=1}^{\infty} a_k \cos\left(2\pi \frac{k}{\tau} t - \phi_k\right),$$

где a_k – амплитуда, а ϕ_k – фаза k-й гармонической функции. Значения a_k составляют спектр звукового сигнала $x(t)$. Если $x(t)$ является чистым тоном с частотой f_0 и периодом $\tau = 1/f_0$, сумма вырождается в одно слагаемое $a_{f_0} \cos(2\pi f_0 t - \phi_{f_0})$. Данная сумма представляет собой ряд Фурье для полученной периодической функции.

Звуки, издаваемые музыкальными инструментами, не являются чистыми тонами. В каждом таком звуке можно выделить *основной тон*, имеющий наиболее низкую частоту, и *обертоны*, имеющие более высокие частоты. Обертоны, у которых частоты кратны частоте основного тона, называют гармоническими. Они характерны, например, для струнных музыкальных инструментов. Обертоны с другими частотами называют негармоническими. Обилие обертонов придаёт звуку насыщенность, но при этом затрудняет выделение чистых тонов.

1.2 Свойства звука

В классическом учебнике по элементарной теории музыки В. А. Вахромеева [17] выделяются 4 основных свойства музыкального звука: высота, длительность, громкость, тембр. Рассмотрим их более подробно.

Высота звука отражает субъективное восприятие человеком частоты звука. Высота звука нелинейно (но монотонно) зависит от его частоты. На основе экспериментов были предложены различные модели этой зависимости, в том числе шкала ме́лов и шкала ба́рков (1 барк = 100 мел). Более подробно эти модели описаны, например, в [18], с. 79-81 или в [19], с. 155-156. Высота звука может быть выражена с разной степенью ясности. Высота звуков, имеющих основной тон, определяется его частотой. Человек способен различать высоту только у периодических сигналов (по основному тону) [19]. Для остальных звуков (например, разного рода шумы, шорохи, звуки шумящих и ударных музыкальных инструментов) высота может быть неясной. Также человек не различает высоту у очень коротких звуков: короче 60 мс для низкочастотных звуков, короче 15 мс для частот 1-2 кГц. Эти значения задают разумные ограничения снизу на длину промежутка $[t_{start}, t_{end}]$, на котором имеет смысл рассматривать спектр звука.

Длительность звука соответствует длительности колебаний источника звука. Она приобретает особое значение в контексте музыкального произведения, когда последовательность звуков и их продолжительность задают ритм. То есть длительности звуков и размещение звуков на временной оси в большинстве случаев носят не случайный, а закономерных характер.

Громкость звука определяется амплитудой колебаний. Но, как в случае с высотой, эта характеристика звука является субъективной. Воспринимаемая человеком громкость зависит как от амплитуды (нелинейно и монотонно), так и от высоты звука (нелинейно и немонотонно). Эти зависимости подробно описаны в [20]. Также воспринимаемая громкость зависит от спектрального состава и длительности звуков.

Тембр или окраска звука определяется частотами, процессами вступления и затухания и интенсивностью его обертонов, которые, в свою очередь, определяются физическими свойствами музыкального инструмента и способом звукоизвлечения. Благодаря разнице в тембрах человек может отличать друг от друга разные музыкальные инструменты.

1.3 Основные понятия из теории музыки

Определения этого раздела даны в соответствии с [17] и [21].

Музыкальной системой называется отобранный практикой ряд звуков, которые находятся в определённых соотношениях по высоте. Музыкальная система является результатом длительно развивающейся музыкальной практики человеческого общества. Для нас наиболее привычна система, сформировавшаяся в европейской, в том числе русской классической музыке. Далее под музыкальной системой будет пониматься именно эта система.

Звукорядом называется совокупность звуков музыкальной системы, расположенных в порядке высоты (в восходящем или нисходящем направлении).

Ступенью называется звук музыкальной системы. Основные ступени соответствуют звукам, извлекаемым на фортепиано на белых клавишах. Им присвоены собственные названия: *до*, *ре*, *ми*, *фа*, *соль*, *ля*, *си*. Необходимо отдельно отметить, что слово «нота» обозначает графическое изображение звука. Тем не менее, оно часто используется как синоним для понятия «звук», например, «нота *до*» в значении «звук *до*».

Строем называется совокупность постоянных отношений по высоте между звуками музыкальной системы.

Человек воспринимает звуки с частотами f_0 и $2f_0$ (до 5000 Гц) как очень похожие и тесно связанные друг с другом. Расстояние между такими звуками называется *октавой*. Как отмечает Д. Левитин в [22], «в основе музыки каждой из известных нам культур лежит октава [. . .] даже некоторые животные – например, обезьяны и кошки, – воспринимают звуки, отличающиеся на октаву, как похожие».

Звукоряд делится на октавы на основе октавного сходства его звуков и отражающей это сходство повторности их названий. В свою очередь, каждая октава имеет своё название: субконтр-октава, контр-октава, большая октава, малая октава и октавы с первой по пятую. Началом октавы принято считать звук ступени *до*.

Темперированным называется строй, который делит каждую октаву звукоряда на равные части. С начала XVIII века в европейской музыке принята двенадцатизвуковая (двенадцатиступенная) темперация, делящая октаву на 12 равных друг другу частей, называемых *полутонами*. Полутон является наименьшим расстоянием по высоте, возможным в двенадцатизвуковом темперированном строе. Он образуется между звуками любых двух соседних ступеней звукоряда. Расстояние, образованное двумя полутонами, называется *целым тоном*. Расстояние между двумя соседними основными ступенями звукоряда (соответствующими белым клавишам фортепиано) может быть равно полутону (например, *ми–фа*) или целому тону (например, *фа–соль*).

Частоту каждой ступени звукоряда можно вычислить по формуле

$$f_j = f_0 \cdot 2^{j/12}, \tag{1.1}$$

где f_0 – частота настройки музыкальных инструментов. В 1939 году на международной конференции в Лондоне был принят стандарт для частоты настройки $f_0 = 440$ Гц. Эту частоту фиксируют для звука *ля* первой октавы. Клавиатура фортепиано охватывает 88 ступеней: от *ля* субконтроктавы до ступени *до* пятой октавы. Частота, соответствующая k-й слева клавише фортепиано (отсчитывается с нуля), может быть вычислена по формуле

$$f_k = 27.5 \cdot 2^{k/12}$$

Широко используемый в настоящее время стандарт MIDI (Musical Instrument Digital Interface) [23], задающий формат обмена данными между электронными музыкальными инструментами, определяет 128 возможных значений для частоты звука [24]. Частота, соответствующая ступени с номером $k,\ 0 \leq k \leq 127$, может быть получена по формуле

$$f_k = 2^{\frac{k-69}{12}} \cdot 440$$

И наоборот, номер ступени может быть получен из частоты по формуле

$$k = 69 + round\left(12 \log_2\left(\frac{f}{440}\right)\right) \tag{1.2}$$

Приведенные выше формулы справедливы для стандартного значения частоты настройки $f_0 = 440$ Гц. В рамках стандарта MIDI звук *ля* первой октавы соответствует 69-й ступени.

Производными называются ступени звукоряда, получаемые посредством повышения или понижения его основных ступеней. Повышение или понижение ступени называется *альтерацией*. Знаки альтерации указывают на повышение или понижение основной ступени. Для дальнейшего изложения важны знаки *диез* (♯) и *бемоль* (♭), обозначающие, соответственно, повышение и понижение на один полутон.

Интервалом называется расстояние по высоте между двумя звуками, взятыми последовательно или одновременно. Звуки интервала, взятые последовательно, образуют мелодический интервал. Звуки интервала, взятые одновременно, образуют гармонический интервал.

Каждый интервал определяется двумя величинами – количественной и качественной. Количественной называется величина, выраженная количеством ступеней, составляющих интервал. Качественной называется величина, выраженная количеством тонов и полутонов, составляющих интервал.

Интервалы, образующиеся в пределах октавы, называются простыми. Всего существует 8 простых интервалов. Их названия зависят от количества основных ступеней, которые они охватывают. Каждое название обозначает порядковый номер второго звука интервала, как если бы от первого его звука брались все ступени до него подряд: прима, секунда, терция, кварта, квинта, секста, септима, октава. Эти названия характеризуют количественную величину интервала.

Как было отмечено выше, расстояние между двумя соседними основными ступенями (образующими секунду) может быть равно полутону или целому тону. Аналогично, терция *до–ми* состоит из 2 целых тонов, а терция *ре–фа* – из 1 целого тона и 1 полутона. Качественная величина интервала определяет различие звучания однородных интервалов. Она обозначается словами: большая, чистая, увеличенная, уменьшенная. Например, терция *до–ми* называется большой, а терция *ре–фа* – малой.

Обращением интервала называется перемещение его нижнего звука на октаву вверх или верхнего звука на октаву вниз.

Аккордом называется одновременное сочетание трёх или более звуков, которые расположены по терциям или могут быть расположены по терциям. Аккорд строится от нижнего звука вверх. Аккорд, состоящий из трёх звуков, расположенных по терциям, называется *трезвучием*. Мажорное трезвучие состоит из большой и малой терций (4 и 3 полутона соответственно). Минорное трезвучие состоит из малой и большой терций. Уменьшенное трезвучие состоит из двух малых терций. Увеличенное трезвучие состоит из двух больших терций. Во всяком трезвучии, независимо от его типа, нижний звук называется *основным звуком* или *примой*, второй (по расстоянию от примы) – *терцией*, а третий – *квинтой*.

Аккорд, состоящий из четырёх звуков, расположенных по терциям, называется *септаккордом*. Его крайние звуки образуют интервал септимы. Наиболее употребительны доминантсептаккорд (большая, малая, малая терции), уменьшенный септаккорд (малая, малая, малая

терции), малый септаккорд (малая, малая, большая терции) и минорный септаккорд (малая, большая, малая терции).

Основным аккордом называется такое положение аккорда, в котором основной звук лежит ниже остальных его звуков. *Обращением* аккорда называется такое его положение, в котором нижним звуком является терция или квинта основного трезвучия. Обращения получаются посредством переноса звуков основного трезвучия вверх на октаву.

Аккорды применяются к музыке не только как сопровождение (аккомпанемент) к данной мелодии, но часто проявляются и в самой мелодии, когда её движение следует по аккордовым звукам. Последовательность, образованная несколькими аккордами, называется *гармоническим оборотом*.

Ритмом называется организованная последовательность длительностей звуков. *Ритмическим рисунком* называется последовательность звуковых длительностей, взятая отдельно от высотных соотношений звуков. Основные соотношения звуковых длительностей в музыке таковы, что каждая более крупная длительность относится к ближайшей более мелкой как 2 к 1. При этом нотные знаки обозначают только относительную длительность звуков, но не абсолютную.

Чередование звуков равными по времени долями образует в музыке равномерное движение или пульсацию. В этом движении звуки некоторых долей выделяются ударениями. Такое выделение звука посредством большей громкости (часто также длительности) по сравнению с окружающими звуками называется *акцентом*. *Метром* называется непрерывно повторяющаяся последовательность акцентируемых и неакцентируемых равнодлительных ритмических единиц (отрезков времени). Эти ритмические единицы времени, образующие метр, называются, в свою очередь, *метрическими долями*. Акцентируемая доля называется *тяжёлой* или *сильной*, неакцентируемая – *легкой* или *слабой*. Акценты, как правило, повторяются через одинаковое количество долей: через одну, две и т.д.

Размером в нотной записи называется метр, доля которого выражена определённой ритмической длительностью (например, четвертью ноты). Размер обозначается дробью, числитель которой говорит о количестве его долей, а знаменатель – о длительности, которая принята за долю. *Тактом* называется часть музыкального произведения, которая начинается с тяжёлой доли и заканчивается перед следующей тяжёлой долей. *Темпом* называется скорость движения, частота пульсирования метрических долей. Темп иногда указывают числом, которое обозначает количество ударов метронома в минуту.

Размер и метр формируют сетку на временной шкале. Очень часто начала нот оказываются выровнены по этой сетке. Вместе с тем, эта сетка может оказаться неравномерной, поскольку понятия метра и темпа являются относительными, субъектинвыми для исполнителя. Изменение акцентов, изменение длительности такта являются средствами музыкальной выразительности, но затрудняют автоматическую обработку звукозаписи.

Для музыкальной выразительности также необходимо объединение нескольких звуков или созвучий в систему, основанную на определённых высотных соотношениях и связях. В таких системах есть звуки, используемые как опора (в частности для окончания мелодии). Эти звуки появляются на тяжёлой доле такта, в конце музыкальной мысли (что часто бывает на чётных тактах). Кроме того, мелодия время от времени возвращается к таким звукам. Музыкальная практика выделяет среди таких звуков один, наиболее устойчивый, который называется *тоникой*. Неустойчивыми называются звуки системы, в которых выражается незавершённость музыкальной мысли. Переход неустойчивого звука в устойчивый называется *разрешением*. *Тяготением* называется притяжение неустойчивого звука системы к устойчивому, отстоящему от него на секунду.

Ладом называется система взаимоотношений между устойчивыми и неустойчивыми звуками. Многие лады состоят из 7 звуков, но существуют лады с большим и меньшим их числом. В основе отдельной мелодии и музыкального произведения в целом всегда лежит определён-

ный лад. *Тональностью* называется высотное положение лада. Название тональности состоит из обозначения тоники и обозначения лада. В двух основных ладах – мажорном и минорном – устойчивые звуки, взятые вместе, образуют соответственно мажорное и минорное трезвучия.

1.4 Цифровой звук

Звуковой сигнал $x(t)$ может быть представлен в цифровом виде при помощи операций *дискретизации* и *квантования*. Для этого с некоторой частотой ν раз в секунду измеряется амплитуда функции $x(t)$ (дискретизация), после чего каждое полученное значение $x(t_i)$ заменяется на ближайшее из заданного множества X_Q возможных значений амплитуды (квантование). Как правило, это множество содержит 2^8, 2^{16} или 2^{24} элементов, чтобы каждое значение можно было представить целым числом байт. Частота ν часто выбирается равной 44100 Гц (по историческим причинам). При этом ν называют *частотой дискретизации*, а значения $x_Q(t_i)$ – *отсчётами* исходного сигнала $x(t)$). В соответствии с классической теоремой Котельникова, если спектр сигнала $x(t)$ ограничен сверху частотой $\nu/2$ (т.е. $a_k = 0$ для $\frac{k}{\tau} > \nu/2$), то исходный сигнал может быть восстановлен однозначно и без потерь по измеренным значениям $x(t_i)$. При квантовании эти значения заменяются на $x_Q(t_i)$, поэтому исходный сигнал может быть восстановлен из оцифрованного только с некоторой ошибкой, которая тем меньше, чем больше возможных значений амплитуды использовалось при квантовании. Для большинства звукозаписей эта ошибка незаметна на слух. Отметим ещё раз, что спектр любых оцифрованных звуковых сигналов ограничен.

1.5 Свойства музыкальных звукозаписей

Последовательность аккордов имеет смысл определять в звукозаписи, содержащей музыку в том или ином виде. Это может быть как студийная запись на компакт-диске, так и запись гитары через микрофон мобильного телефона. Музыкальные звукозаписи в целом обладают рядом свойств, которые нужно учитывать при определении последовательности аккордов. Каждое из них может быть выражено в большей или меньшей степени или вообще отсутствовать.

- Одновременное звучание нескольких музыкальных инструментов. При этом звуковые сигналы, издаваемые разными инструментами (и даже разными звучащими элементами одного инструмента, например, струнами) складываются. Точно так же складываются спектры этих инструментов.

- Наличие гармоник у музыкальных инструментов с ясно выраженной высотой звучания. В звучании таких инструментов можно выделить отдельную ноту. При этом наряду с частотой, соответствующей этой основной ноте, звучат другие частоты. Их звучание менее выражено, но они могут соответствовать другим ступеням музыкальной системы. Математически это означает, что если k_0 таково, что a_{k_0} – наибольшая по абсолютному значению компонента спектра звучащей ноты, то существует по меньшей мере одно значение $k > k_0$ такое, что a_k существенно отлична от 0. Соотношения между парами (k_0, k) для разных k и разных k_0 (соответствующих разным нотам) во многом задают тембр музыкального инструмента.

- Наличие инструментов с невыраженной высотой звучания. К ним относятся многие ударные инструменты, в звучании которых невозможно выделить конкретную ноту. Спектр таких инструментов характеризуется большим количеством расположенных подряд существенно отличных от нуля значений, слабо отличающихся друг от друга. Иными

словами, существуют такие положительные числа A и δ, что A существенно больше δ и $A < a_k < A + \delta$ для всех k из некоторого промежутка $[k_0, k_1]$.

- Наличие ритма и метра. Метрические доли зачастую акцентируются началом звучания нот, а в некоторых музыкальных стилях – также звучанием ударных инструментов. Широко употребляются простые метры, где акцент делается один раз на две или три доли. Также широкоупотребителен метр, состоящий из четырёх долей с акцентом на первой и третьей, при этом акцент на первой доле чуть сильнее. Другие метры и размеры используются реже.

- Наличие лада и тональности. Они позволяют объединить в целостную композицию звуки различных музыкальных инструментов и голоса. Они накладывают ограничения на допустимые аккорды в композиции. Вместе с тем, эти ограничения не являются строгими и могут сознательно нарушаться композиторами. Кроме того, тональность может меняться на протяжении композиции, что влечёт за собой изменение набора «допустимых» аккордов.

- Наличие периодичностей (повторений). Как пишет Д. Левитин в [22], «музыка основана на повторениях». Одна и та же музыкальная фраза, последовательность аккордов и даже целый фрагмент композиции могут повториться в точности или с небольшими изменениями.

1.6 Формализация задачи

Теперь, с использованием введенных понятий и обозначений, можно дать формальную постановку задач, решаемых в данной работе. Сначала дадим формулировку задачи в целом:

пусть заданы звуковой сигнал $x(t),\ t \in [t_{start}, t_{end}]$ и множество возможных названий аккордов Y. Необходимо для каждого момента времени $t \in [t_{start}, t_{end}]$ указать аккорд $y \in Y$, звучащий в этот момент.

Такая постановка является достаточно общей. Разделим задачу на отдельные шаги, после чего сформулируем конкретные задачи, которые решаются в данной работе.

1.6.1 Частотно-временное представление

Представление звука в виде последовательности отсчётов амплитуды не является удобным для обработки: неясно, как сопоставить аккорду последовательность отсчётов и наоборот. Поэтому естественным первым шагом является часто используемый при обработке звука переход к частотно-временному представлению звукозаписи, или получению её спектрограммы $C_{N \times M}$. Основным инструментом для такого перехода является дискретное оконное преобразование Фурье.

Спектрограмма представляет из себя матрицу, каждая из N строк которой соответствует определённой частоте, а каждый из M столбцов – промежутку времени. Элементами её являются значения интенсивности данной частоты на данном промежутке времени. Фактически, каждый столбец представляет из себя спектр короткого фрагмента исходного сигнала. Удобно представлять спектрограмму в виде последовательности столбцов $C_{N \times M} = \{C_m\}_{m=0}^{M-1}$.

Здесь возникает 2 подзадачи: разбиение звукозаписи на фрагменты и вычисление спектра на каждом из них. Важно отметить, что для современной западной музыки характерны использование равномерно темперированного строя и наличие ритма. Поэтому большее количество звуковой энергии должно быть сосредоточено в точках, соответствующих частотам нот и моментам начала метрических долей. Исходя из этих соображений, можно скорректировать выбор моментов начала фрагментов и выбор используемого преобразования. Удобно

использовать одно и то же преобразование для всех фрагментов, поскольку в этом случае все столбцы спектрограммы будут иметь одинаковый размер и смысл. После этого на каждом фрагменте необходимо решить задачу классификации.

1.6.2 Классификация

Обозначим за $C \subset \mathbb{R}^N$ множество всех возможных векторов-столбцов спектрограммы. Для каждого вектора из данной последовательности $\{C_m\}_{m=0}^{M-1}$ необходимо указать аккорд $y \in Y$, соответствующий этому вектору. Принимая во внимание известные из равномерно темперированного строя частоты нот, можно по спектру звука в данном фрагменте делать предположения относительно звучащего аккорда. Возможно использование не только текущего, но и предыдущих векторов (а также последующих, если от алгоритма не требуется выдавать результат в реальном времени). Также возможно использование результатов классификации других векторов.

На этом этапе важными вопросами являются выбор метода классификации и выбор целевой функции (если метод предполагает нахождение наилучших параметров путём обучения). Основной подзадачей является отыскание такого набора преобразований множества X, который позволит уменьшить количество ошибок классификации с использованием выбранного метода. Результатом преобразования будет последовательность векторов признаков, отличная от исходной последовательности векторов-столбцов спектрограммы. Для отыскания подходящих преобразований могут быть использованы свойства, перечисленные в разделе 1.5.

1.6.3 Постановка задач

1. Предложить и реализовать способ более точного вычисления значений спектра в точках, соответствующих частотам нот и моментам начала метрических долей.

2. Разработать набор преобразований спектра, позволяющих достичь хорошего качества распознавания аккордов без использования методов классификации на основе машинного обучения.

3. Применить один из методов обучения представлениям – многослойные очищающие автоассоциаторы – для получения набора пребразований спектра в вектор признаков.

В главе 2 описываются основные уже существующие подходы, применяемые для решения каждой из отмеченных выше подзадач.

Глава 2

Обзор литературы

Данная глава посвящена обзору литературы в области распознавания аккордов. Область исследований достаточно молодая, поэтому практически все рассматриваемые работы были опубликованы в последние 15 лет, а наиболее значимые результаты были получены в течение последних 5 лет.

Предварительная обработка звукозаписи (параграф 2.1) так или иначе присутствует практически во всех алгоритмах распознавания аккордов. Она используется для уменьшения объёма вычислений на последующих этапах, а также для более точной настройки алгоритма на конкретную звукозапись. Первым шагом к непосредственному распознаванию аккордов является получение спектрограммы (параграф 2.2). В зависимости от наличия или отсутствия предварительной обработки, а также используемого метода для вычисления спектра, к ней применяются те или иные преобразования (параграф 2.3). Конечным итогом всех преобразований является представление спектрограммы в виде последовательности векторов признаков, различные типы которых также описаны в этом параграфе. Наконец, параграф 2.4 описывает часто применяемые методы классификации, позволяющие получить последовательность названий аккордов из последовательности векторов признаков.

2.1 Предварительная обработка

На этом этапе собирается информация, которая будет использоваться для получения частотно-временного представления звукозаписи: определяются моменты начала метрических долей и частота настройки музыкальных инструментов. Иногда дополнительно производится разделение звука на гармонические и перкуссионные компоненты, после чего последние удаляются из сигнала. К этому же этапу можно отнести понижение частоты дискретизации цифровой звукозаписи для ускорения вычислений на следующем этапе и преобразование стереофонических записей в монофонические.

Понижение частоты дискретизации применяется во многих работах ([25], [26], [27], [28], [29], [30], [31], [32], [33], [34], [35], [36], [37], [38], [12]) для ускорения обработки файла. Как правило, частота дискретизации понижается со стандартной для компакт-дисков 44100 Гц до 11025 Гц путем замены каждых 4 подряд идущих отсчётов $x_Q(t_i), x_Q(t_{i+1}), x_Q(t_{i+2}), x_Q(t_{i+3})$ на $x_Q(t_i)$. При этом терятся информация о частотах выше 5.5 кГц. Такая потеря не является критичной, поскольку на частотах свыше 5 кГц человеческое восприятие высоты тона существенно изменяется, в частности, нарушается октавное сходство при удвоении частоты звука. Поэтому в музыке большая часть информации находится на частотах до 5 кГц и остаётся незатронутой при таком понижении частоты дискретизации.

Такое преобразование позволяет использовать меньший размер окна при вычислении быстрого преобразования Фурье. Но при отсутствии жестких ограничений на производительность

понижение частоты дискретизации не является обязательным. В [39], [40], [41], [42], [13] частота дискретизации звукозаписей не меняется.

Общепринятым является преобразование стерофонических звукозаписей в монофонические путём взятия среднего арифметического от сигналов левого и правого каналов. При этом предполагается, что в них не будут звучать разные аккорды, что, скорее всего, звучало бы неприятно для человека.

Определение моментов начала метрических долей позволяет на следующем шаге получить спектрограмму, соотносящуюся с ритмом композиции. Смена аккорда, как и любое другое событие в музыке, очень часто подчинена ритму и происходит на границе метрических долей. Кроме того, в столбцах спектрограммы, соответствующих акцентированным долям, будет более ярко выражено звучание инструментов и соответствующие им пики спектра. Моменты начала метрических долей используются как для деления звука на фрагменты, каждый из которых соответствует одной доле или её части ([43], [44], [45], [46], [38]), так и для усреднения столбцов спектрограммы, вычисленной с фиксированным шагом по времени, в пределах одной метрической доли ([26], [33], [36], [13], [47]. В [47], помимо описанных вариантов, также применялась медианная фильтрация по всем столбцам спектрограммы в пределах одной метрической доли, но лучший результат был достигнут с использованием усреднения.

Задача определения моментов начала метрических долей обычно формулируется в рамках музыкального информационного поиска как задача отслеживания ритма (beat detection). Новые алгоритмы для её решения появляются каждый год, но в методах распознавания аккордов обычно применяется один из алгоритмов, представленных в [48], [49], [50]. Соответствующие программные модули для этих алгоритмов доступны бесплатно и удобны в подключении, что, по-видимому, является основной причиной их популярности.

Отклонение частоты настройки музыкальных инструментов от стандартного значения 440 Гц может как явно определяться на этапе предварительной обработки ([51], [30], [32], [37], [38], [52], так и неявно учитываться в процессе обработки спектрограммы ([26], [27], [35], [36], [41]). Особенно важно учитывать это отклонение при использовании преобразования постоянного качества (см. параграф 2.2), использующего заранее заданные частоты для вычисления спектральных компонент. Некоторые алгоритмы для определения частоты настройки представлены в работах [53], [54], [51], [55], [56].

Разделение звука на гармонические и перкуссионные компоненты позволяет ослабить влияние музыкальных инструментов с неясной высотой звучания на спектрограмму, получаемую на следующем этапе. Аналогичные преобразования делаются на этапе преобразования спектрограммы в последовательность векторов признаков во многих работах. Но в [35] и [38] перкуссионные компоненты удаляются из сигнала до построения спектрограммы при помощи свободно доступной для научного использования реализации алгоритма [57].

2.2 Спектрограмма

Переход к частотно-временному представлению звукозаписи в виде спектрограммы является ключевым, поскольку даёт возможность работать с отдельными частотными компонентами звука. Как было отмечено выше, для этого звукозапись делится на короткие, возможно, пересекающиеся фрагменты, на каждом из которых вычисляется спектр звука.

В алгоритмах распознавания аккордов используются следующие методы получения спектра.

1. Дискретное оконное преобразование Фурье.

$$X[n] = \sum_{j=0}^{J-1} w(j) x_Q(t_j) e^{-\frac{i2\pi nj}{J}}, \quad n = 0, 1, \ldots, N-1$$

Здесь J – размер анализируемого фрагмента звукозаписи в отсчётах, $w(j)$ – функция, отличная от нуля на некотором промежутке, не выходящем за пределы этого фрагмента – оконная функция. Прямоугольная оконная функция $w(j)$, равная 1 только на анализируемом фрагменте и 0 – вне его, получается автоматически при разделении на фрагменты исходной звукозаписи. Среди других оконных функций наиболее популярной является окно Хемминга:

$$w(j) = 0.53836 - 0.46164 \cos\left(\frac{2\pi j}{J-1}\right)$$

При использовании оконной функции результатом преобразования Фурье является не спектр исходного сигнала, а спектр его произведения с оконной функцией. Согласно свойству преобразования Фурье, этот спектр будет равен свёртке спектров исходного сигнала и оконной функции. Её выбор влияет на форму полученных искажений спектра. Более подробную информацию об эффектах от выбора оконной функции можно найти в [58], раздел 10.3.1.

Достоинствами дискретного оконного преобразования Фурье являются существование быстрых алгоритмов вычисления в определённых случаях и наличие большого количества реализаций на разных языках программирования. Вместе с тем, при использовании алгоритмов быстрого преобразования Фурье невозможно произвольным образом выбирать частоты его компонент. Это создает неудобства при дальнейшей обработке, поскольку невозможно точно определить количество звуковой энергии, приходящейся на частоты, соответствующие ступеням звукоряда. Дискретное оконное преобразование Фурье используется в [25], [51], [28], [30], [32], [45], [36], [37], [13].

2. Преобразование постоянного качества (constant Q преобразование).

$$X[n] = \frac{1}{J(n)} \sum_{j=0}^{J(n)-1} w(n,j) x_Q(t_j) e^{-\frac{i2\pi nj}{J(n)}}, \quad n = 0, 1, \ldots, N-1$$

Здесь, в отличие от преобразования Фурье, размер анализируемого фрагмента и размер оконной функции зависят от номера соответствующей частотной компоненты f_n. В свою очередь, f_n можно выбрать таким образом, что каждой ступени звукоряда будет соответствовать одинаковое число частотных компонент (одна или более). Пусть N_0 – количество компонент в одной октаве, а f_{min} – частота наименьшей из анализируемых компонент. Тогда частота n-й компоненты задается формулой $f_n = 2^{n/N_0} f_{min}$. Точно так же задаются частоты для ступеней звукоряда при использовании равномерно темперированного строя, поэтому параметр f_{min} напрямую связан с частотой настройки музыкальных инструментов. Отношение $\frac{f_n}{f_{n+1}-f_n} = \frac{1}{2^{1/N_0}-1} = Q$ называется коэффициентом качества. При таком выборе частот Q не зависит от k. Отсюда происходит название constant-Q преобразования.

Достоинством этого преобразования является легкость дальнейшей работы со спектром, поскольку его компоненты напрямую соответствуют ступеням звукоряда. Недостатками являются большая сложность вычислений и зависимость от правильного определения частоты настройки. Более быстрый алгоритм вычисления преобразования постоянного качества, использующий результат быстрого преобразования Фурье исходного сигнала, был предложен в [59]. Преобразование постоянного качества используется в [26], [27], [31], [33], [34], [35], [40], [42], [38].

3. Гребёнка фильтров (filter bank). В цифровой обработке сигналов любое преобразование сигнала называют фильтром. В данном случае под фильтром понимается полосовой фильтр – преобразование, сохраняющее в звуке только частоты, находящиеся в некоторой полосе частот. Известно (см. [60], с. 424-425), что быстрое преобразование Фурье

эквивалентно вполне определенной гребёнке достаточно грубых фильтров. Вместо них можно использовать любые другие фильтры, у каждого из которых центр полосы пропускания соответствует частоте одной из ступеней звукоряда, а ширина полосы пропускания достаточно мала, чтобы не охватывать частоты соседних ступеней. Эти фильтры можно подобрать так, чтобы они были менее грубыми, то есть более точно определяли количество звуковой энергии, приходящейся на их полосы пропускания. Недостатком данного метода является большая вычислительная сложность в сравнении с алгоритмом быстрого преобразования Фурье. Гребёнки фильтров используются в [52], [12].

Независимо от способа получения спектра, он подвергается дальнейшей обработке и в конце концов преобразуется в имеющий меньшую размерность вектор признаков.

2.3 Векторы признаков

Переход от столбцов спектрограммы к векторам признаков основан на том, что человек воспринимает звуки с частотами, отличающимися на октаву, как похожие. Эта же особенность используется композиторами, когда инструменты, звучащие в разных частотных полосах, воспроизводят одну и ту же ноту в разных октавах, или несколько голосов из разных октав составляют один аккорд. Поэтому вполне естественно просуммировать в каждом столбце спектрограммы компоненты, соответствующие одному и тому же звуку в разных октавах. Пусть спектрограмма была получена в результате преобразования постоянного качества, и N_0 – количество частотных компонент в одной октаве в столбце C_m, что соответствует шагу в $N_0/12$ полутонов. Ко всем значениям $C_m[n],\ 0 \leq n < N_0$, прибавляются значения $C_m[n+N_0], C_m[n+2N_0], C_m[n+3N_0], \ldots$ для каждого $0 \leq m \leq M-1$. В результате из последовательности столбцов $\{C_i\}_{m=0}^{M-1}$ получается последовательность N_0-мерных векторов $\{B_m\}_{m=0}^{M-1}$.

Если при получении спектрограммы использовалось быстрое преобразование Фурье с размером фрагмента J отсчётов, то необходимо сопоставить компоненты спектра частотам звукоряда. Обычно это делается по следующей формуле

$$n = 12\log_2\left(\frac{f_k}{f_0}\right) + 69, k = 0, 1, \ldots J-1 \tag{2.1}$$

где f_k – частота, соответствующая k-й компоненте спектра, f_0 – частота настройки музыкальных инструментов, n – номер частоты звукоряда. Эта формула применима и для спектрограммы, полученной преобразованием постоянного качества.

Векторы признаков, полученные путём объединения спектральной информации по всем октавам, носят общее название векторов хроматических признаков или *хроматических векторов*. Впервые такой процесс был предложен в [5], а соответствующие признаки получили название *профиль тональных классов* (pitch class profile). Под *тональным классом* здесь понимается совокупность звуков, имеющих одно название, но находящихся в разных октавах, например, все звуки *до*.

В отличие от столбцов исходной спектрограммы, каждый хроматический вектор имеет всего 12 компонент, а значит, соответствующая задача классификации решается в пространстве меньшей размерности. Каждая из координатных осей в этом пространстве соответствует уровню энергии, приходящемуся на один тональный класс. Недостатками такого преобразования является потеря информации об октавах исходных звуков (влекущая потерю информации об обращении аккорда) и наложение шумовых компонент спектра на полезные. Несмотря на это, хроматические векторы используются в большинстве существующих алгоритмов распознавания аккордов.

Для определения обращения аккорда анализируют низкочастотную область спектра, что позволяет определить басовую ноту, по которой, в свою очередь, определяется обращение аккорда. В [31], [33], [37], [38], [13], [47] строятся отдельные спектрограммы для низкочастотной и высокочастотной областей спектра, граница между которыми обычно пролегает в диапазоне от 200 Гц до 250 Гц. Соответственно, получается два набора хроматических векторов, используемых в дальнейшем анализе.

Для отделения полезных компонент спектра от шумовых было предложено множество преобразований. Как правило, они не затрагивают способ получения вектора признаков из столбца спектрограммы, поэтому их итогом является хроматический вектор. Тем не менее, из-за наличия дополнительных преобразований таким векторам иногда дают собственные названия.

В [27] было предложено для случая спектрограммы, полученной быстрым преобразованием Фурье, перед вычислением (2.1) заменять каждое значение $X_m[n]$ на $\prod_{k=0}^{N_{harm}} |X[2^k \cdot n]|$, где N_{harm} – параметр, регулирующий количество гармоник. Это позволяет учесть информацию о гармониках инструментов с определённой высотой звучания в векторе признаков, который был назван *расширенный профиль тональных классов* (enhanced pitch class profile).

В [51] было предложено для случая спектрограммы, полученной быстрым преобразованием Фурье, учитывать только спектральные пики (локальные максимуы в каждом столбце). Каждый из них учитывался при вычислении не одного, а нескольких компонентов вектора, с разными весами, в зависимости от разницы между частотой пика и частотой ступени звукоряда. Кроме того, чтобы учесть наличие гармоник, каждый пик с частотой f_n прибавлялся к пикам с частотами $f_n, f_n/2, f_n/3, \ldots$ с соответствующими весами. Такой вектор признаков получил название *гармонический профиль тональных классов* (harmonic pitch class profile).

В [45] и [37] были предложены способы перераспределения звуковой энергии в пределах спектрограммы, полученной быстрым преобразованием Фурье, от участков с меньшим количеством энергии к участкам с большим количеством энергии (эта техника была предложена в [61]). В [45] допускается только перемещение энергии в пределах одного стобца спектрограммы, в [37] допускается таже перемещение энергии между столбцами. В полученных таким образом спектрограммах более чётко выделены горизонтальные участки с большим количеством звуковой энергии, соответствующие инструментам с определённой высотой звучания и их гармоникам.

В [36] каждый столбец X_m спектрограммы, полученной быстрым преобразованием Фурье, преобразуется аналогично (2.1) в вектор C'_m из 256 компонент, расположенных с шагом в $1/3$ полутона, что соответствует охвату в чуть более, чем 7 октав. После этого для 84 ступеней звукоряда от *ля* субконтроктавы (27.5 Гц) до *фа* третьей октавы (3322 Гц) генерируются шаблонные 256-компонентные векторы-столбцы. В каждом из них элементы, соответствующие ступени звукоряда и её гармоникам, задаются как h^{k-1}, где $h = 0.6$, а k – номер гармоники; остальные элементы равны 0. Взятые вместе, они образуют матрицу E. Далее линейным методом наименьших квадратов находится вектор C_m, минимизирующий $||C'_m - EC_m||$, при условии, что все компоненты C_m неотрицательны. Полученные векторы C_m образуют новую спектрограмму с шагом по частоте в $1/3$ полутона, которая обрабатывается как если бы она была получена в результате преобразования постоянного качества. Полученный в результате хроматический вектор признаков получил название *NNLS chroma* (Non-Negative Least Squares chroma).

Мощность звука определяется как энергия, передаваемая звуковой волной через рассматриваемую поверхность в единицу времени. Спектр мощности звука показывает изменение его мощности с течением времени. Он может быть получен из частотного спектра путем возведения в квадрат каждой из его компонент. Как показано в [62], воспринимаемая громкость звука приблизительно пропорциональна десятичному логарифму уровня мощности звука (sound power level). Поэтому имеет смысл перед преобразованием спектрограммы в последователь-

ность хроматических векторов заменить каждое её значение $C_m[n]$ на $\log(\eta \cdot C_m[n] + 1)$, где η – положительная константа, которая обычно выбирается из диапазона $100 \leq \eta \leq 10000$. Тогда соотношение между разными компонентами спектрограммы будет приблизительно соответствовать соотношению между воспринимаемыми человеком уровнями громкости соответствующих частот. Полученные таким образом признаки называют *chroma-log-pitch* (CLP) [52].

В [63] было предложено после логарифмирования элементов спектрограммы для каждого столбца C_m вычислять дискретное косинусное преобразование, занулять первые ξ полученных коэффициентов, после чего выполнять обратное дискретное косинусное преобразование. Если представлять спектр звука как функцию интенсивности звука от частоты, данное преобразование удаляет низкочастотные компоненты в спектре этой функции, т.е. длинные последовательности отличных от нуля значений, незначительно отличающихся друг от друга. Похожие действия выполняются при вычислении мел-частотных кепстральных коэффициентов [64], широко используемых в распознавании речи. Из полученной спектрограммы обычным образом вычисляются хроматические векторы. Они получили название *chroma DCT-reduced log pitch* (CRP). Целью этого преобразования является повышение устойчивости хроматических векторов к изменению тембра музыкальных инструментов, прежде всего для сопоставления различных музыкальных записей. Но CRP-признаки были успешно применены к распознаванию аккордов в [42].

В [38] было предложено наряду с зависимостью человеческого восприятия громкости от звуковой мощности учитывать зависимость от частоты звука. Для этого на каждом фрагменте звукозаписи вместо частотного спектра вычисляется спектр мощности, от каждой его компоненты вычисляется десятичный логарифм, после чего к каждой компоненте применяется A-взвешивание [65].

В [66] были предложены преобразования последовательности хроматических векторов, направленные на повышение устойчивости к шумам. В последовательности полученных обычным способом хроматических векторов каждый вектор B_m заменяется на $B_m/||B_m||_1$, где $||B_m||_1 = \sum_{n=0}^{N_0-1} |B_m[n]|$. Затем производится квантование значений $B_m[n],\ 0 \leq B_m[n] \leq 1$ с порогами, величины которых расположены логарифмически. Далее вычисляется свёртка последовательности $\{B_m\}_{m=0}^{M-1}$ с окном Ханна длины $w \in \mathbb{N}$, а затем прореживание полученной последовательности по основанию d. Полученные в результате этих преобразований векторы признаков получили название *chroma energy normalized statictics* ($CENS_d^w$).

В [67] были предложены особые признаки, не являющиеся хроматическими. Они являются векторами в пространстве *Tonnetz* [68], [69], моделирующем взаимоотношения между ступенями равномерно темперированного строя. Согласно [67], в случае равномерно темперированного строя это 6-мерное пространство. Для удобства векторы в этом пространстве нормируют так, чтобы они попадали внутрь 6-мерного эллипса с радиусами $(r_1, r_1, r_2, r_2, r_3, r_3)$. Координаты можно разделить попарно на 3 круга. Первый из них в некотором роде соответствует квинтовому кругу. В нём точки, соответствующие ступеням звукоряда, расположены на окружности радиуса r_1 с шагом $5\pi/6$. Во втором круге эти точки расположены на окружности радиуса r_2 с шагом $\pi/4$, а в третьем – на окружности радиуса r_3 с шагом $\pi/3$. Их можно мыслить как круги малых и больших терций соответственно. Точка, соответствующая аккорду, имеет координаты, равные среднему арифметическому координат составляющих его нот. Любой хроматический вектор может быть легко преобразован в вектор в этом пространстве. Такие векторы признаков были использованы в [29], [70], [47], [12].

Сравнение качества работы некоторых из описанных типов признаков в приложении к задаче распознавания аккордов было проведено в [52]. Наилучшие результаты были получены с использованием признаков CRP. Авторы отмечают, что логарифмическое преобразование спектра, применяемое при вычислении признаков CLP и CRP, является важным шагом к повышению качества распознавания аккордов.

Принципиально другой подход к получению вектора признаков был предложен в [12]. Описанные выше 6-мерные признаки получаются из спектрограммы путём применения свёрточной нейронной сети [71]. При этом не применяются никакие знания о свойствах спектра или музыки. Предполагается, что нейронная сеть сама определит наиболее характерные свойства в процессе обучения.

На соревнованиях MIREX Audio Chord Estimation алгоритмы, использующие современные признаки ([37], [36], [63]) показывают близкие результаты. Но на результат в значительной степени влияет используемый в алгоритме метод классификации векторов признаков.

2.4 Классификация векторов признаков

На этом этапе находится решение задачи распознавания аккордов в звукозаписи: полученная на предыдущем этапе последовательность векторов признаков преобразуется в последовательность аккордов с указанием моментов начала и конца их звучания. Перед вычислением спектрограммы звукозапись была поделена на фрагменты, моменты начала и конца которых известны. Поэтому считается, что каждый из полученных векторов признаков соответствует промежутку времени между началами текущего и следующего фрагментов.

Для определения звучащего на данном фрагменте аккорда по вектору признаков необходимо классифицировать этот вектор. В рамках задачи MIREX Audio Chord Estimation 2012 выделялись 25 возможных классов: по одному классу для каждого мажорного и минорного аккордов, а также один класс для отсутствия аккорда. Многие алгоритмы также ограничиваются этим набором ([26], [27], [32], [34], [45], [40], [41], [42], [52], [38], [47], [12]). В некоторых работах выделяют также отдельные классы для доминантсептаккордов ([25], [31], [39], [33], [36], [13]), других септаккордов ([25], [36]), уменьшенных и увеличенных ([25], [28], [70], [31], [44], [33], [36], [72]) и других видов аккордов.

2.4.1 Метод ближайшего соседа

Наиболее простой способ классификации – определение расстояния от вектора признаков до «идеальных» шаблонных векторов той же размерности, соответствующих аккордам. В качестве результата выбирается аккорд, расстояние до шаблона которого является наименьшим. Фактически, это метод k ближайших соседей для $k = 1$. Такой подход был применён в [27], [34], в одном из вариантов [52]. Мерой расстояния может выступать косинусное расстояние, евклидово расстояние, расхождение Кульбака-Лейблера и другие. Их сравнение было проведено в [34]. В качестве шаблона аккордов часто используют вектор, у которого на позициях, соответствующих входящим в аккорд нотам, стоят 1, а на остальных – 0. Например, шаблон для аккорда до-минор имеет вид $(1, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0)$ (при условии, что первая компонента вектора соответствует звуку *до*).

Важным достоинством такого способа классификации является отсутствие этапа обучения. Отсюда следует лёгкость добавления новых типов распознаваемых аккордов: для этого требуется всего лишь добавить новые шаблоны. Недостатком является невозможность учесть зависимость между подряд идущими фрагментами звукозаписи.

Иногда (например, в [34]) в шаблоны также включают информацию о гармонических обертонах входящих в аккорд звуков. Звуки, соответствующие частотам гармонических обертонов, могут быть получены из формулы (1.2). Вклад обертона в соответствующую компоненту шаблона определялся в [51] и в [34] как

$$w_{harm}(k) = h^{k-1} \tag{2.2}$$

где k – номер обертона, а $h < 1$ – параметр. Основной тон звука здесь соответствует $k = 1$. Соответствующий шаблонный вектор будет иметь компоненты со значениями, отличными от 0 и 1.

Для повышения устойчивости к шумам к последовательности векторов признаков можно предварительно применить скользящий медианный фильтр или фильтр скользящего среднего, как в [27], [34].

В [33] было предложено учитывать структуру композиции перед определением аккордов. Структура может быть задана заранее или определена автоматически. Последовательности хроматических векторов, соответствующие одинаковым структурным сегментам, усреднялись перед распознаванием аккордов. Эта идея была продолжена в [42], где было предложено использовать метод рекуррентного анализа для нахождения похожих друг на друга последовательностей хроматических векторов и их взаимного сглаживания.

2.4.2 Скрытые марковские модели и байесовские сети

Широко используемые в методах распознавания речи *скрытые марковские модели* (СММ) [73] также нашли применение в алгоритмах распознавания аккордов. В отличие от метода ближайшего соседа, они позволяют в явном виде моделировать вероятность перехода между двумя заданными аккордами. Дадим формальное определение элементов СММ.

- Набор состояний модели $Q = \{Q_1, Q_2, \ldots, Q_{N_{states}}\}$. За q_t будем обозначать состояние модели в момент времени t.
- Множество наблюдаемых символов $\Lambda = \{\lambda_1, \lambda_2, ..., \lambda_{M_{symbols}}\}$.
- Матрица переходных вероятностей $\Omega = \{\omega_{ij}\}$, где $\omega_{ij} = P(q_t = Q_j | q_{t-1} = Q_i), 1 \leq i, j \leq N_{states}$. Если любое состояние достижимо из любого, то все ω_{ij} неотрицательны. Для всех $i,\ 1 \leq i \leq N_{states}$ верно $\sum_{j=1}^{N_{states}} \omega_{ij} = 1$
- Распределение вероятностей появления наблюдаемых символов в состоянии Q_j, $V = \{v_j(k)\}$, где $v_j(k) = P\{\lambda_k \; at \; t | q_t = S_j\}$ при $1 \leq j \leq N_{states},\ 1 \leq k \leq M_{symbols}$.
- Начальное распределение вероятностей состояний $\pi = \{\pi_i\}$, где $\pi_i = P\{q_t = Q_i\},\ 1 \leq i \leq N_{states}$.

Состояния СММ ненаблюдаемы, в каждый момент времени доступен для наблюдения только какой-либо символ из множества Λ. Важным свойством СММ является то, что вероятность перехода из состояния Q_i в состояние Q_j не зависит от предыдущих состояний модели.

Набор состояний СММ фиксируется заранее. В качестве наблюдаемых символов обычно выступают векторы признаков. Матрица переходных вероятностей, параметры распределения вероятностей появления наблюдаемых символов и параметры начального распределения вероятностей состояний могут как задаваться изначально (как в [26], в одном из вариантов [30], в нескольких вариантах [40]), так и определяться в результате обучения СММ (как в [28], в нескольких вариантах [30], [31], [32], [35], в одном из вариантов [40], [52], [37], [38]). Вероятности появления наблюдаемых символов обычно моделируются одним многомерным нормальным распределением (как в [25], [26], [30], [38], [47]) или смесью многомерных нормальных распределений (как в [28], [32], [35], [40], [37]). При обучении обычно используется итеративный метод математического ожидания – модификации (expectation-modification), также называемый методом Баума-Уэлша или методом прямого-обратного хода. В [35] минимизируется ошибка классификации, параметры модели обновляются при помощи градиентного

спуска. При распознавании наиболее вероятной последовательности скрытых состояний применяется алгоритм Витерби. Стоит отметить, что иногда алгоритм Витерби применяют, не вводя явно СММ, а задавая псевдовероятности вместо необходимых в алгоритме распределений вероятностей (например, в [42], [12]).

Несмотря на свою популярность, СММ не свободны от недостатков, ограничивающих возможность их применения. Основными из них являются очень большое количество параметров и марковское свойство, позволяющее учитывать зависимость состояния на данном шаге от состояния только на предыдущем шаге.

Обычно наблюдаемыми символами СММ являются хроматические векторы. Соответственно, вероятности появления наблюдаемых символов моделируются многомерными распределениями с числом измерений, равным размерности хроматического вектора. Оценим число параметров для типичного случая. Пусть СММ имеет $N_{states} = 25$ состояний, каждому из которых соответствует одно 12-мерное нормальное распределение, а начальное распределение вероятностей состояний равномерно. Тогда имеется $25 \cdot 24 = 600$ элементов в матрице переходных вероятностей, а также как минимум 24 параметра на каждое из 25 состояний (в предположении, что матрицы ковариации многомерных нормальных распределений диагональны). С использованием смеси нормальных распределений вместо одного распределения количество параметров для каждого состояния увеличивается пропорционально числу компонентов смеси.

Для уменьшения количества настраиваемых параметров часто предполагают, что параметры для разных состояний в некотором смысле схожи, а потому могут быть скорректированы после первоначального обучения. В хроматическом векторе каждая компонента соответствует одному классу звуков, например, всем звукам *до*. Если его первую компоненту такого вектора, соответствущую классу звуков *до*, переставить в конец, то полученный вектор останется хроматическим, но его первая компонента будет соответствовать классу звуков *до-диез*. Аналогичные циклические перестановки возможны для математических ожиданий и матрицы ковариации соответствующего многомерного распределения.

Так, если в векторе математических ожиданий для распределения, соответствующего аккорду *до-диез-мажор*, переставить одну компоненту из начала в конец, то полученный вектор математических ожиданий будет соответствовать аккорду *до-мажор*. Такими сдвигами можно привести все векторы матожиданий для распределений, соответствующих мажорным аккордам, к виду, в котором компонента, соответствующая основному звуку аккорда, будет первой. После этого можно усреднить все математические ожидания по всем аккордам, и обратными сдвигами вернуть усреднённые векторы матожиданий на свои места. Аналогично можно усреднить матрицы ковариации для всех аккордов одного типа. Также возможно усреднение компонентов матрицы переходов для случаев переходов между аккордами соответствующих типов, основные звуки которых отстоят на одинаковое число полутонов. Процедура усреднения применяется, например, в [25], [30], [40], [37]. Усреднение параметров модели полезно в случае недостатка обучающих данных или их неравномерного распределения по рассматриваемому набору аккордов.

Моделирование зависимости текущего состояния модели только от состояния на предыдущем шаге приводит к заметной проблеме. Очевидно, что смена аккорда производится не при каждой смене звукового фрагмента. Поэтому необходимо контролировать длительность нахождения модели в одном состоянии. В случае СММ первого типа это можно сделать, регулируя значения на главной диагонали матрицы переходов. А в [47] в СММ было дополнительно введено распределение, задающее вероятность нахождения модели в состоянии Q_i в течение d фрагментов, где $d \leq 20$. Процедура обучения и алгоритм Витерби были соответствующим образом модифицированы.

Другой подход к моделированию длительности нахождения СММ в одном состоянии – построение отдельной модели для каждого аккорда и связывание этих моделей в одну СММ с

общими входом и выходом для каждой из моделей. Он применялся в одном из вариантов [28], [31], [32], [37]. В этом случае можно регулировать параметры моделей каждого отдельного аккорда (как в [31]), а также добавлять штраф за переход от модели одного аккорда к модели другого аккорда (как в [32], [37]).

Были предложены различные способы для учёта информации о предыдущих состояниях модели в том числе через введение понятий жанра и тональности. В [32] использовалась языковая модель, которая позволяет учитывать более чем одно предыдущее состояние СММ. В [29] было предложено строить 24 СММ, по одной для каждой из мажорных и минорных тональностей. При распознавании аккордов для каждой модели определялась наиболее вероятная последовательность состояний. В качестве результата выбиралась та из последовательностей, вероятность которой была наибольшей. Дополнительным результатом при этом было определение тональности композиции. В [70] аналогичным образом строились отдельные СММ для 6 различных музыкальных жанров. В [72] отдельные СММ строились для 11 различных жанров, но при этом они были объединены в одну гипер-жанровую модель с более сложной процедурой обучения. Несмотря на большой потенциал такого рода комбинаций, они требуют существенно больше обучающих данных. В случае [29] и [70] использовались звукозаписи, сгенерированные из MIDI-файлов. В [72] исползовался достаточно большой набор реальных музыкальных звукозаписей. Тональность может быть явным образом введена в саму СММ наряду с басовой нотой. Предложенная в [38] СММ включала в себя в том числе 12 скрытых состояний для текущей басовой ноты и 24 скрытых состояний для текущей тональности. При этом общее количество комбинаций скрытых состояний становится слишком большим, поэтому приходится накладывать дополнительные ограничения на допустимые переходы между аккордами и между тональностями и на допустимые сочетания аккордов и басовых нот.

В [36] было предложено использовать динамическую байесовскую сеть, которая, по сути, является обобщением СММ (см. [74]). В ней используются скрытые состояния для текущих метрической позиции, тональности, аккорда и басовой ноты; наблюдениями являются 2 вектора хроматических признаков: для высоких и для низких частот. Такая модель позволяет моделировать сложные музыкальные взаимоотношения. С другой стороны, она имеет множество параметров, и поэтому требует большего количества обучающих данных. Для получения наиболее вероятной последовательности в такой сети можно использовать модификацию алгоритма Витерби, но из-за размеров сети этот процесс оказывается более длительным, чем в случае СММ.

2.4.3 Другие модели

В [45] было предложено использовать более сильный алгоритм классификации, чем метод ближайшего соседа, основанный на методе опорных векторов. Помимо текущего вектора признаков этот алгоритм позволяет учитывать также признаки на предыдущем или на следующем фрагменте звукозаписи, а также попарные произведения компонент вектора признаков.

В одном из вариантов [28] было предложено заменить СММ на условное случайное поле [75]. Оно определяется следующим образом. Обозначим за $\boldsymbol{X}$ и $\boldsymbol{Y}$ множество наблюдений и множество случайных переменных соответственно. Пусть $G = (V, E)$ – такой граф, что $\boldsymbol{Y} = (\boldsymbol{Y}_v)_{v \in V}$, то есть $\boldsymbol{Y}$ можно проиндексировать вершинами этого графа. Тогда $(\boldsymbol{X}, \boldsymbol{Y})$ называется *условным случайным полем*, если случайные переменные $\boldsymbol{Y}_v$ при условии $\boldsymbol{X}$ удовлетворяют марковскому свойству с учётом графа: $p(\boldsymbol{Y}_v | \boldsymbol{X}, \boldsymbol{Y}_w, w \sim v) = p(\boldsymbol{Y}_v | \boldsymbol{X}, \boldsymbol{Y}_w, w \sim v)$, где $w \sim v$ означает, что w и v являются соседями в графе G. В случае, когда G является цепью или деревом, к соответствующему условному случайному полю можно применять алгоритмы, аналогичные методу прямого-обратного хода и алгоритму Витерби. В отличие от СММ, при определении наиболее вероятной последовательности вершин графа максимизируется не $p(\boldsymbol{X}, \boldsymbol{Y})$, а $p(\boldsymbol{Y} | \boldsymbol{X})$. Кроме того, в такой модели каждое скрытое состояние зависит не только

от текущего наблюдения, но от всей предыдущей последовательности наблюдений. В [28] отмечается, что условное случайное поле обучается существенно дольше, чем СММ.

В [13] была предложена полноценная модель гармонии, построенная на основе музыкально-теоретических соотношений между аккордами. Её применение требует знания тональности, поэтому для звукозаписи предварительно определяется последовательность тональностей с ограничением на минимальную длину фрагмента в одной тональности в 16 метрических долей. На каждом фрагменте звука определяется набор наиболее вероятных аккордов (вычисляются расстояния от хроматического вектора до шаблонов аккордов), после чего модель гармонии используется для определения наиболее вероятной последовательности аккордов с учётом уже определённых аккордов на всех предыдущих фрагментах.

В [43] использовался собственный алгоритм для определения вероятности гипотез. Каждая гипотеза состоит из последовательности аккордов, определённой до данного фрагмента, и тональности. На каждом фрагменте определяется вероятность гипотез со всеми возможными вариантами текущего аккорда. В формуле для вычисления вероятности гипотезы учитываются тональность, вероятность смены аккорда, хроматический вектор, басовый звук, сочетаемость аккорда и басового звука. Очень похожий подход с другими формулами для определения вероятности гипотез был применён в [44].

Подход, в чём-то похожий на алгоритм Витерби, был предложен в [41]. Здесь на каждом фрагменте определяется набор наиболее вероятных аккордов (вычисляются расстояния от хроматического вектора до шаблонов аккордов) и тональностей (вычисляются расстояния от хроматического вектора до шаблонных векторов тональностей из [76]). Затем все наиболее вероятные кандидаты объединяются в пары. Расстояние между парами (аккорд, тональность) определяется в соответствии с [77] на основе взаимоотношений между звуками, составляющими аккорды, и звуками, входящими в тональности. Тогда методом динамического программирования можно определить последовательность пар (аккорд, тональность) по всем фрагментам, имеющую наименьшую сумму расстояний между соседними парами.

2.5 Выводы

1. В большинстве современных алгоритмов для распознавания аккордов используются методы определения ритма; методы определения частоты настройки музыкальных инструментов применяются реже.

2. Среди множества типов хроматических признаков наилучшее качество распознавания достигается при помощи тех из них, алгоритмы вычисления которых обеспечивают подавление шумовых спектральных компонент.

3. Скрытые марковские модели и динамические байесовские сети являются наиболее популярными методами классификации в алгоритмах распознавания аккордов. Эти методы позволяют добиться наилучшего качества распознавания, но требуют настройки очень большого количества параметров в процессе обучения.

Глава 3

Распознавание аккордов без использования машинного обучения

РИСУНОК: общая схема реализованного метода

В этой главе описывается метод определения последовательности аккордов в звукозаписи, не требующий предварительного обучения. Глава разделена на параграфы в соответствии с основными реализованнами в данной работе улучшениями существовавших ранее алгоритмов. В параграфе 3.1 описываются предварительная обработка и получение спектрограммы звукозаписи. Преобразование спектрограммы в векторы признаков и обработка последовательности векторов признаков описаны в параграфах 3.2 и 3.3. Наконец, используемый метод классификации и эвристики, предназначенные для уменьшения количества ошибок классификации, описаны в параграфе 3.4.

3.1 Частотно-временное представление звукозаписи

Западная музыка основывается на равномерно темперированном строе. Поэтому, как правило, все звуки, издаваемые музыкальными инструментами с определённой высотой звучания, имеют частоты, соответствующие формуле 1.1. В звучании аккорда, состоящего из нескольких нот, большая часть энергии должна приходиться на частоты этих нот. Соответственно, разница в звучании двух аккордов должна выражаться в наличии или отсутствии звуковой энергии на определённых частотах. Поэтому при построении частотно-временного представления наибольший интерес представляют частоты, соответствующие звукам западной музыкальной системы.

3.1.1 Определение частоты настройки музыкальных инструментов

В формуле 1.1 присутствует параметр f_0, задающий частоту настройки музыкальных инструментов. Как отмечается в [18], с. 89, некоторые оркестры до сих пор используют частоты настройки 442 Гц и 443 Гц. Встречающееся гораздо чаще воспроизведение звукозаписи с изменённой скоростью приводит к аналогичному эффекту, повышая или понижая частоты звучания всех инструментов композиции. Частоту настройки необходимо определить предварительно, чтобы избежать ошибок на таких звукозаписях.

Увеличение частоты настройки в $2^{1/12} \approx 1.06$ раз (или примерно на 6%) приведёт к повышению звучания инструмента на полутон: вместо звука *си* будет звучать *до*, вместо *до* – *до*♯ и так далее. Аналогично, повышение скорости воспроизведения в $2^{1/12}$ раз приведёт к уменьшению периода каждого звука в $2^{-1/12}$ раз, а значит, к повышению частоты в $2^{1/12}$ раз. Очевидно, в случае такого изменения скорости воспроизведения невозможно обнаружить сам

факт его наличия, не обладая дополнительной информацией об изначальной тональности композиции. Поэтому обычно фиксируют диапазон для возможных значений частоты настройки: $[440 \cdot 2^{-1/24}, 440 \cdot 2^{1/24})$, приблизительно соответствующий диапазону от 427 до 452 Гц.

Обзор некоторых алгоритмов определения частоты настройки можно найти в [78] в разделе 4.1. В рамках данной работы используется алгоритм, похожий на предложенный в [54]. Звукозапись делится на короткие фрагменты между моментами времени $t_m, m = 0, 1, 2, \ldots, M'$, на каждом из которых выполняется constant-Q преобразование с $f_{min} = 440 \cdot 2^{m_0/12}$ для некоторого целого m_0, и достаточно высоким разрешением по частоте: $N_0 = 12b_0$ компонент на октаву. В каждом фрагменте $C_m = C(t_m)$ определяется номер компоненты $C_m[n]$, $0 \leq n < N'$, которой соответствует максимальное значение спектра. Затем строится гистограмма значений функции $C_m[n]$, она состоит из N' столбцов. Значения всех столбцов, номера которых сравнимы по модулю b_0, суммируются. В полученной гистограмме из b_0 столбцов номер столбца с наибольшим значением можно интерпретировать как отклонение f_0 от стандартной частоты настройки 440 Гц в диапазоне от -1/2 до +1/2 полутона с точностью до $1/b_0$ полутона. Если наибольшее значение приходится на 0-й столбец, то отклонения нет. Используемые здесь значения M' и N' не обязательно совпадают с соответствующими значениями M и N для основной спектрограммы.

Допустим, вместо настоящей частоты настройки f_0 была ошибочно определена $f_0' \neq f_0$. Это приведёт к тому, что настоящие частоты звуков будут отличаться от использованных в преобразовании постоянного качества в f_0/f_0' раз. Если этот множитель незначительно отличается от 1, разница не будет заметна. В противном случае возможно определение аккордов не в той тональности.

Влияние алгоритма определения частоты настройки на качество распознавания аккордов рассматривается в параграфе 5.2.3

3.1.2 Определение ритма

Ритм играет важную роль в западной музыке. Так же, как равномерно темперированный строй упорядочивает звуки по высоте, ритм упорядочивает и группирует их по времени начала и продолжительности звучания. Поэтому и смена звучащего аккорда должна происходить в соответствии с ритмом. Наиболее чётко воспринимаемая человеком пульсация соответствует периодической смене метрических долей. В дальнейшем будем предполагать, что смена звучащего аккорда всегда происходит в момент начала какой-то метрической доли. При этом теряется возможность определения нескольких аккордов в пределах одной метрической доли. Но расположенные в соответствии с ритмом анализируемые фрагменты позволят анализировать звук ровно в те моменты, когда музыкальные инструменты звучат наиболее ярко, и интересующие нас частоты лучше выделены в спектре.

В рамках данной работы для определения ритма в звукозаписях использовались 2 внешние библиотеки: *Beatroot* [49] и *Beat tracker* [48] из набора *Queen Mary Vamp plugins*. Вторая библиотека потребовалась для обработки тех композиций, в которых *Beatroot* не смог определить начала метрических долей. Зависимость качества распознавания аккордов от выбора библиотеки для определения ритма рассматривается в параграфе 5.2.1.

3.1.3 Снижение влияния ударных инструментов

В звучании любого музыкального инструмента можно условно выделить 3 части: атака, стационарная часть, затухание. В процессе атаки в музыкальном инструменте устанавливаются колебания, начинают звучать основной тон и обертоны. На протяжении стационарной части звучание меняется слабо. В процессе затухания колебания прекращаются. В [19] приводятся следующие цифры для основных категорий музыкальных инструментов:

- струнные щипковые и ударные (гитара, фортепиано): атака 10-50 мс, нет стационарной части, продолжительное затухание;
- струнные смычковые (скрипка): атака до 50 мс, продолжительная стационарная часть;
- орган: атака до 300 мс, продолжительная стационарная часть, продолжительное затухание;
- духовые (труба): атака 10-30 мс, выраженный стационарный участок, короткое затухание;
- ударные (барабаны, тарелки): атака 3-10 мс, продолжительное затухание.

Как видно, ударные инструменты начинают звучать раньше остальных. Поскольку ритм обычно задаётся именно ударными инструментами, имеет смысл анализировать спектр в моменты времени, отстоящие на несколько десятков миллисекунд от моментов начала метрических долей. В эти моменты звучание инструментов с выраженной высотой будет наиболее ярким и полным, в то время как ударные инструменты будут находиться в процессе затухания. Обозначим соответствующую задержку во времени за d.

Очевидно, введение такой задержки имеет смысл только совместно с использованием алгоритма для определения ритма. Автору неизвестно о других алгоритмах распознавания аккордов, в которых применялась бы такая задержка. Влияние величины задержки на качество распознавания аккордов анализируется в параграфе 5.2.2.

3.1.4 Получение спектра

Моменты начала метрических долей $(t_0, t_1, \ldots, t_{M-1})$ (с учётом смещения) и частоты звуков равномерно темперированного строя образуют сетку на плоскости «частота-время». Особый интерес представляют значения интенсивности звука, вычисленные в узлах этой сетки. Информация о моментах начала метрических долей позволяет разделить звукозапись таким образом, чтобы на каждый из них приходилась середина одного из фрагментов. Преобразование постоянного качества позволяет в каждом фрагменте определить интенсивность звука для каждой из указанных частот.

Во многих работах (например, в [52], [42]) отмечалась важность сглаживания последовательности столбцов спектрограммы или векторов признаков. Сглаживание осуществляется путём применения фильтра скользящего среднего или скользящего медианного фильтра с шириной окна w к каждой строке спектрограммы. Оно позволяет избавиться от единичных выбросов в спектре, но при этом несколько размывает спектр, снижая разрешение по времени. Если каждый столбец спектра соответствует промежутку между двумя метрическими долями, такое размытие будет слишком сильным.

Чтобы преодолеть этот недостаток, увеличим разрешение спектрограммы по времени в T раз путём вставки между каждыми моментами (t_m, t_{m+1}) равномерно $T-1$ промежуточных значений, где T – параметр. Тогда появляется возможность использовать достаточно большой размер окна при сглаживании, не приводящий к существенному размытию спектра во времени. После сглаживания разрешение спектрограммы уменьшается в T раз путем удаления добавленных промежуточных столбцов.

Равномерно темперированный строй предполагает расположение $N_0 = 12$ ступеней звукоряда в пределах октавы, поэтому удобно выбирать N_0 кратным 12. Большие значения N_0 дают возможность в некоторой мере скомпенсировать ошибки при определении частоты настройки музыкальных инструментов f_0, позволяя учесть близкие к $f_k = 2^{k/12} f_0$ частоты. В [26], [27], [31], [34], [40], [42] использовалось значение $N_0 = 36$. Как показано ниже, $N_0 = 60$ позволяет добиться лучшего результата.

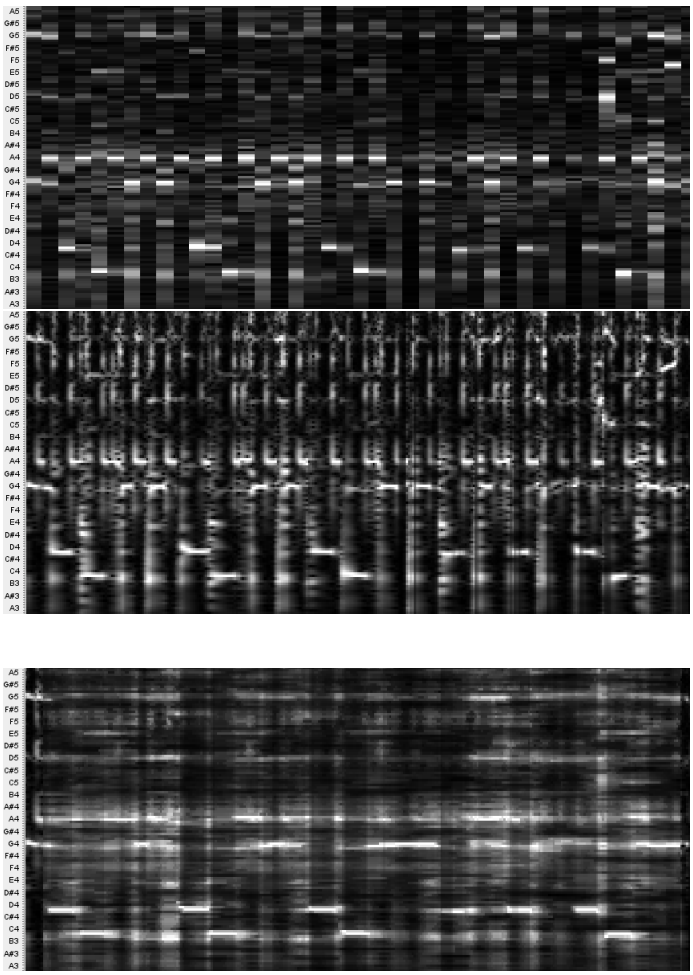

Рисунок 3.1: Фрагменты спектрограммы *The Beatles – Love Me Do* при $T = 1$ (вверху), $T = 8$ (в середине), $T = 8$ после сглаживания с $w = 19$ (внизу).

Важно также правильно выбрать частоту наименьшей из компонент преобразования f_{min} и общее количество компонент N. Они определяют используемый для анализа частотный диапазон. Обычно используются частоты в пределах 50-2000 Гц. В [45] используемый диапазон ограничен сверху 1000 Гц, а в [42] – 4186 Гц. Для определения более частот ниже 50 Гц требуется слишком длинный фрагмент звука, а частоты выше 2000 Гц обычно содержат только гармоники более низких нот, затрудняющие определение аккорда.

В параграфе 5.2.4 анализируется влияние параметров T и N_0 на качество распознавания аккордов.

3.2 Выделение мелодических компонент спектра и векторы признаков

На этом этапе к спектрограмме применяется серия преобразований. Они нацелены на акцентирование компонент, которые несут важную для идентификации аккорда информацию, и на подавление остальных компонент. Наиболее важным является подавление шума и инструментов с неопределенной высотой звучания, поскольку их спектр не зависит от звучащего аккорда и сопоставим по уровню со спектром инструментов, задающих аккорд.

Как видно из рисунка 3.1 (в середине), барабан оставляет на спектрограмме яркие вертикальные полосы. В то же время, гитаре соответствуют горизонтальные полосы. Это свойство

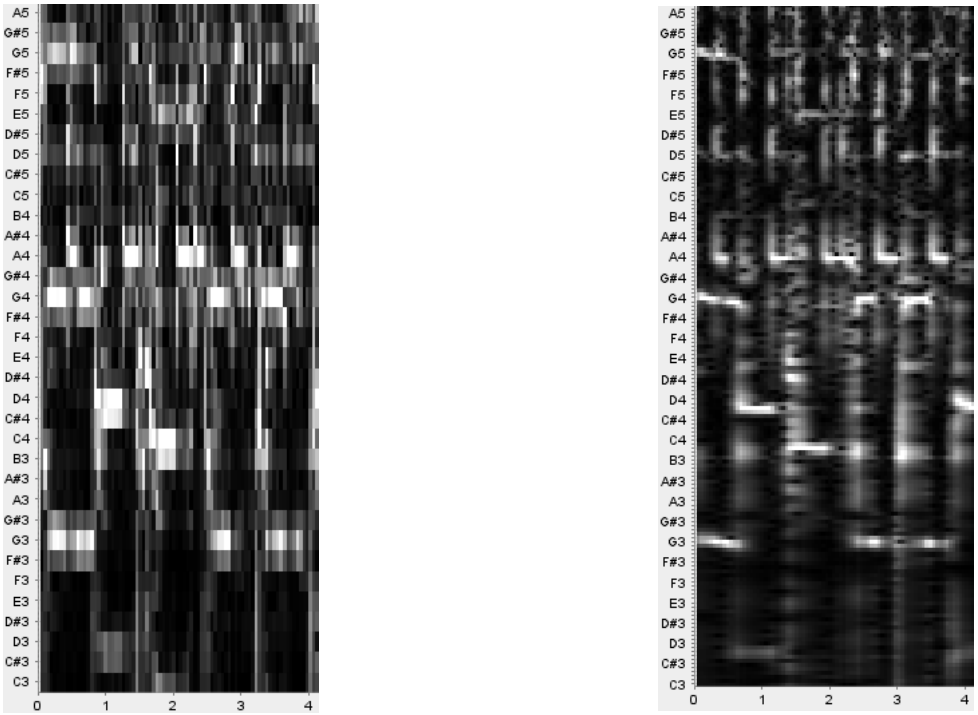

а) б)

Рисунок 3.2: Фрагменты спектрограммы *The Beatles – Love Me Do* при: а) $N_0 = 12$; б) $N_0 = 60$.

используют алгоритмы разделения звука на гармонические и перкуссионные компоненты, такие как [57] и [79]. В данном случае полное разделение является излишним, необходимо только подавить перкуссионные компоненты.

Маух в [36] предложил вычитать из спектрограммы так называемый фоновый спектр. При этом каждое значение спектрограммы $C_m[n]$ заменять на $\frac{C_m[n]-\mu_m[n]}{\sigma^q_m[n]}$, где $\mu_m[n]$ представляет собой среднее значение, а $\sigma^q_m[n]$ – среднеквадратическое отклонение в пределах отрезка от $C_m[n-k]$ до $C_m[n+k]$, охватывающего одну октаву, $q \in \{0, 1\}$. Если полученное значение является отрицательным, вместо него подставляется 0.

Автором в [80] было предложено использовать аналог фильтра Превитт, используемого в обработке изображений для выделения границ. Будем для каждого фрагмента спектрограммы размера 9×3 с центром в точке $C_m[n]]$ вычислять его свёртку с матрицей

$$P = \begin{pmatrix} -1 & -1 & -1 \\ -1 & -1 & -1 \\ -1 & -1 & -1 \\ 2 & 2 & 2 \\ 2 & 2 & 2 \\ 2 & 2 & 2 \\ -1 & -1 & -1 \\ -1 & -1 & -1 \\ -1 & -1 & -1 \end{pmatrix}$$

Если полученное значение больше 0, то заменим $C_m[n]$ на него, иначе – на 0.

Еще один подход к подавлению перкуссионных компонент лёг в основу алгоритма вычисления признаков CRP [63]. Будем рассматривать $C_m[n]$ как сигнал (количество энергии, приходящейся на данную частоту, в зависимости от частоты). Применим к этой функции

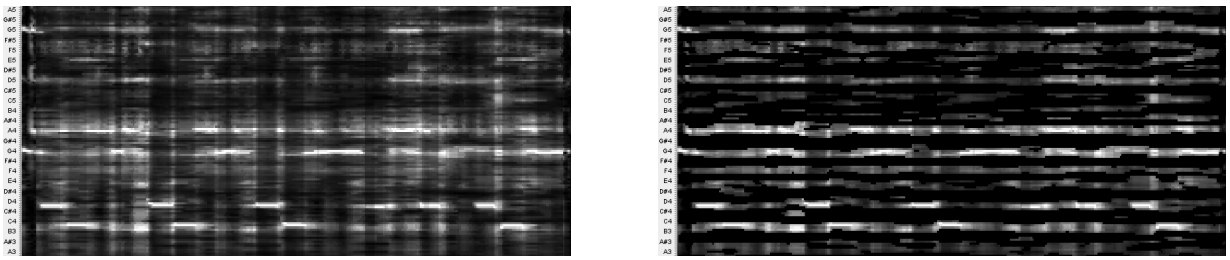

а) б)

Рисунок 3.3: Фрагменты спектрограммы *The Beatles – Love Me Do*: а) до применения фильта Превитт; б) после применения фильта Превитт.

дискретное косинусное преобразование.

$$DC_m[k] = \sum_{j=0}^{N-1} C_m[j] \cos\left[\frac{\pi}{N}\left(j + \frac{1}{2}\right)k\right], \quad k = 0, \ldots, N-1$$

В полученной последовательности значений занулим первые ξ значений, после чего произведём обратное дискретное косинусное преобразование. Зануляемые первые коэффициенты соответствуют низкочастотным компонентам сигнала $C_m[n]$, которые, в свою очередь, соответствуют достаточно длинным последовательностям существенно отличных от нуля значений. При этом имеющиеся в функции «острые» пики выделяются более чётко.

Как показывает практика, важным шагом является применение к спектрограмме логарифмического преобразования: каждая компонента $C_m[n]$ заменяется на $\log_{10}(\eta C_m[n] + 1)$. После него соотношения между компонентами спектрограммы лучше соответствуют человеческому восприятию интенсивности звука.

В параграфе 5.3.1 приводится сравнение результатов от применения различных методов очистки спектра. Параграф 5.3.2 посвящён подбору наилучших параметров для вычисления признаков CRP.

3.3 Применение самоподобия

Важным свойством музыкальных звукозаписей является наличие повторений. Музыка нравится человеку в том числе из-за повторений одного и того же мотива в разных вариациях, с некоторыми изменениями. Во многих композициях имеется достаточно продолжительный повторяющийся припев. В рамках куплета может повторяться одна и та же музыкальная фраза длительностью в несколько тактов. Можно попытаться использовать повторения для улучшения спектрограммы.

В работах [36] и [42] повторяющиеся фрагменты композиции использовались для улучшения качества распознавания аккордов. В обеих методах строились матрицы самоподобия для 12-мерных хроматических векторов признаков с использованием в качестве меры подобия коэффициента корреляции Пирсона (в [36]) и евклидового расстояния (в [42]). В полученной матрице находятся линии, параллельные главной диагонали, которые соответствуют похожим друг на друга фрагментам. Эти фрагменты затем используются для дополнительного сглаживания спектрограммы.

Однако матрицу самоподобия можно строить и для столбцов спектрограммы $\{C_i\}_{i=0}^{M-1}$, каждый из которых содержит больше информации по сравнению с соответствующим вектором признаков. Обозначим эту матрицу за $\{s_{ij}\}$, где s_{ij} – евклидово расстояние между столбцами C_i и C_j. Эта матрица имеет нули на главной диагонали. Нормализуем её таким образом, чтобы $0 \leq s_{ij} \leq 1$ для всех i, j. Затем в каждой строке сохраняются $\zeta \cdot M$ наименьших значений

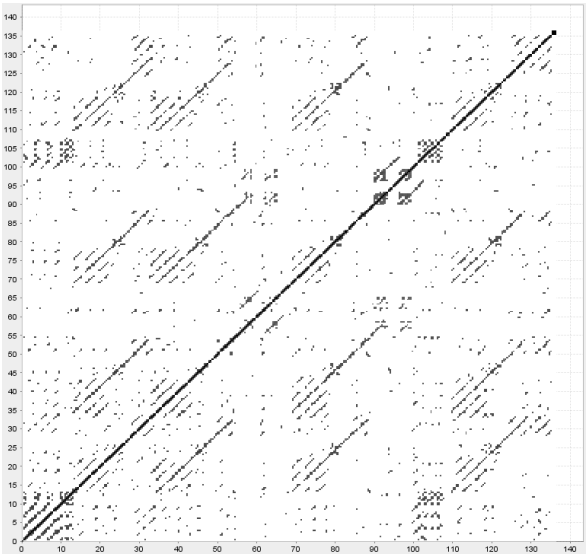

Рисунок 3.4: Матрица самоподобия для композиции *The Beatles – Love Me Do*

($0 \leq \zeta \leq 1$), а все остальные заменяются на 1. Пример полученной матрицы показан на рисунке 3.4.

При помощи полученной матрицы можно скорректировать все столбцы C_m:

$$\widehat{C}_m = \frac{\sum\limits_{j=0}^{M-1}(1 - s_{mj})C_j}{\sum\limits_{j=0}^{M-1}(1 - s_{mj})}$$

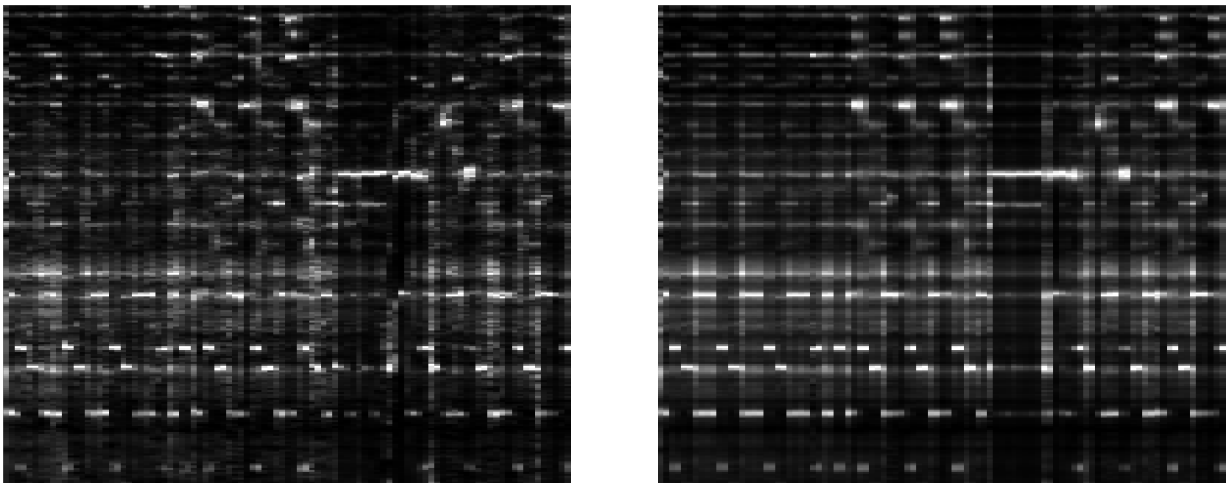

а) б)

Рисунок 3.5: Фрагменты спектрограммы *The Beatles – Love Me Do*: а) без использования самоподобия; б) после коррекции с использованием самоподобия.

На рисунке 3.5 наглядно показан эффект от такой коррекции. Спектрограмма становится существенно чётче, моменты смены аккордов становятся выделенными более явно. Количественная оценка влияния коррекции на качество распознавания аккордов приведена в параграфе 5.3.3.

Важно, что применение этого преобразования требует наличия достаточно большого количества столбцов в спектрограмме. Вряд ли имеет смысл применение самоподобия к короткой звукозаписи, в которой маловероятно наличие повторяющихся элементов.

3.4 Классификация и исправление ошибок

3.4.1 Классификация хроматических векторов

Будем рассматривать в качестве множества возможных названий аккордов Y набор из названий 24 мажорных и минорных аккордов и символа «N», означающего отсутствие аккорда. За основу возьмём метод ближайшего соседа с шаблонами, учитывающими основной тон и 3 первых обертона по формуле (2.2). Эти шаблоны задаются для 12-мерных хроматических векторов. Столбцы спектрограммы охватывают несколько октав, поэтому для каждого из них потребовалось бы несколько шаблонов, чтобы учесть все возможные сочетания октав, в которых могут располагаться ноты аккорда.

Для получения 12-мерных хроматических векторов сначала ко всем значениям $\widehat{C}_m[n],\ 0 \le n < N_0$, прибавляются значения $\widehat{C}_m[n+N_0],\ \widehat{C}_m[n+2N_0],\ \widehat{C}_m[n+3N_0],\ \ldots$ для каждого $0 \le m \le M-1$, давая в результате последовательность N_0-мерных векторов $\{B_m\}_{m=0}^{M-1}$. Далее в случае $N_0 = 12b_0,\ b_0 \ge 3$ каждый вектор B_m преобразуется в 12-мерный вектор D_m:

$$D_m[n] = B_m[b_0 n - 1] + B_m[b_0 n] + B_m[b_0 n + 1], \quad m = 0, \ldots, M-1, \quad n = 0, \ldots, 11$$

Для вычисления $D_m[0]$ в качестве $B_m[-1]$ используются $B_m[59]$.

Для каждого из последовательности векторов $\{D_m\}_{m=0}^{M-1}$ определяется ближайший из шаблонов, и соответствующий ему аккорд считается аккордом, звучащим в данном фрагменте.

Параграф 5.5.1 посвящён подбору наилучших параметров для используемых шаблонов.

3.4.2 Исправление ошибок классификации

В результате экспериментов было обнаружено, что некоторые последовательности аккордов являются маловероятными в реальной композиции, и скорее всего является ошибочными. Для двух классов таких последовательностей предлагается метод их исправления.

A:maj - A:min

К первому классу относятся последовательности, в которых аккорды имеют общую основную ноту, но различные типы, например: A:maj-A:min-A:maj-A:min. Появление таких последовательностей возможно, поскольку соответствующие векторы признаков достаточно близки друг к другу. Для каждой такой последовательности находится вектор признаков, являющийся средним арифметическим составляющих её векторов. Аккорд, соответствующий полученному вектору признаков, приписывается всей последовательности.

A-B-C

Ко второму классу относятся последовательности из 3 разных идущих подряд аккордов: A-B-C (при этом возможно A=C). В этом случае более вероятно, что на самом деле имел место один из следующих 4 вариантов: A-A-C, A-C-C, A-B-B, B-B-C. Из них выбирается тот, для которого сумма расстояний от векторов признаков до соответствующих шаблонных векторов минимальна. Очевидно, что такая коррекция будет ошибочной в тех случаях, когда аккорд действительно звучит только в течение одной метрической доли.

Эффект от использования предложенных эвристик исследуется в параграфе 5.5.2. TODO ПРИМЕРЫ композиций, где это работает и где не работает

3.5 Выводы

1. Разработан метод более точного вычисления спектрограммы, учитывающий свойства музыкальных звукозаписей.
2. Предложен метод для удаления шумовых компонент спектра на основе фильтра Превитт, используемого в обработке изображений.
3. Предложен набор преобразований последовательности векторов признаков, учитывающий свойства музыкальных звукозаписей.
4. Предложены эвристики для исправления распространённых ошибок классификации.

Глава 4

Получение признаков с использованием нейронных сетей

Описанный в главе 3 метод получения векторов признаков из столбцов спектрограммы состоит из нескольких преобразований, каждое из которых опирается на какие-то свойства музыкальных звукозаписей. Представление спектра звука в виде вектора признаков необходимо, чтобы облегчить последующую классификацию. Обучение представлениям – это раздел машинного обучения, рассматривающий алгоритмы, направленные на получение наилучших представлений входных данных. Такие алгоритмы стремятся сохранить наиболее характерные признаки входных данных в сжатом их представлении.

В основе многих алгоритмов обучения представлениям лежит многослойная нейронная сеть. Важным свойством таких алгоритмов является возможность предварительного обучения каждого слоя нейронной сети в отдельности без учителя, на неразмеченных данных. Благодаря нему требуется существенно меньше размеченных данных для окончательного обучения нейронной сети в целом.

В 2012 году Хамфри в [12] предложил использовать свёрточные нейронные сети для получения признаков, позволяющих классифицировать звучащий аккорд. В данной работе рассматриваются обычные многослойные (в том числе рекуррентные) нейронные сети, предварительно обучаемые с помощью очищающих автоассоциаторов. Такие сети были успешно использованы для распознавания речи в [81]. Похожий подход был продемонстрирован в работе [82], где рекуррентная нейронная сеть возвращает на выходе сразу распознанный аккорд, который при помощи рекуррентного соединения подаётся на вход на следующем шаге.

В разделе 4.1 даётся определение многослойного очищающего автоассоциатора и сопутствующих понятий. В разделе 4.2 описывается построение и обучение многослойной нейронной сети с использованием автоассоциаторов, преобразующей столбец спектрограммы в вектор хроматических признаков.

4.1 Теоретические сведения и обзор литературы

Определения в этом разделе даны в соответствии с [83].

Автоассоциатор (автоэнкодер) представляет из себя пару преобразований:

$$y = f_\theta(x) = s(Wx + b) \tag{4.1}$$

$$z = g_{\theta'}(y) = s(W'y + b') \tag{4.2}$$

Здесь x – входной вектор, z – реконструированный выходной вектор, y – *внутреннее представление* для x, $\theta = \{W, b\}$ и $\theta' = \{W', b'\}$ – параметры (обычно накладывают ограничение

$W' = W^T$), s – нелинейная функция активации (обычно это сигмоида или функция гиперболического тангенса). Иногда в (4.2) выбирают в качестве s линейную функцию. Автоассоциатор удобно представлять в виде нейронной сети с одним скрытым слоем.

При обучении автоассоциатора минимизируется *функция стоимости* $L(X, Z(X)))$, где X – множество всех возможных входных векторов. Чтобы в процессе обучения преобразования $f_\theta(x)$ и $g_\theta(y)$ не выродились в тождественные, накладывают различные ограничения. Часто используемое ограничение: размерность вектора y должна быть меньше размерности входного вектора x. Другой возможный вариант – потребовать, чтобы размерность вектора y была больше размерности вектора x и при этом большинство компонент y были равны 0. При этом y становится разреженным представлением вектора x. Обозначим за $f_\theta^j(x)$ j-ю компоненту вектора y при данном входном векторе x. Тогда можем определить среднюю величину компонент вектора y:

$$\hat{\rho}_j = \frac{1}{m} \sum_{i=1}^{m} f_\theta^j(x^{(i)}) \tag{4.3}$$

Чтобы добиться $\hat{\rho}_j = \rho$, где ρ – параметр, контролирующий разреженность, добавим слагаемое L_ρ в функцию стоимости L. Это слагаемое можно определять разными способами, в рамках данной работы будем использовать следующую его форму, предложенную в [84]:

$$L_\rho = \beta \left[\sum_{j=1}^{h} \left(\rho \log \frac{\rho}{\hat{\rho}_j} + (1-\rho) \log \frac{1-\rho}{1-\hat{\rho}_j} \right) \right] \tag{4.4}$$

В дальнейшем будем использовать значение $\rho = 0.05$, также в соответствии с [84].

Очищающий автоассоциатор обучается таким образом, чтобы по повреждённому (зашумлённому) вектору $\tilde{x}$ восстанавливать исходный вектор x. Предполагается, что такие представления более устойчивы к помехам и лучше отражают внутреннюю структуру входных данных. Показано [83], что во многих случаях внутренние представления, которые получаются при помощи очищающего автоассоциатора, позволяют получить лучшие результаты в задачах классификации по сравнению с представлениями, полученными при помощи обычных автоассоциаторов. В [83] рассматриваются различные способы получения зашумлённого вектора $\tilde{x}$.

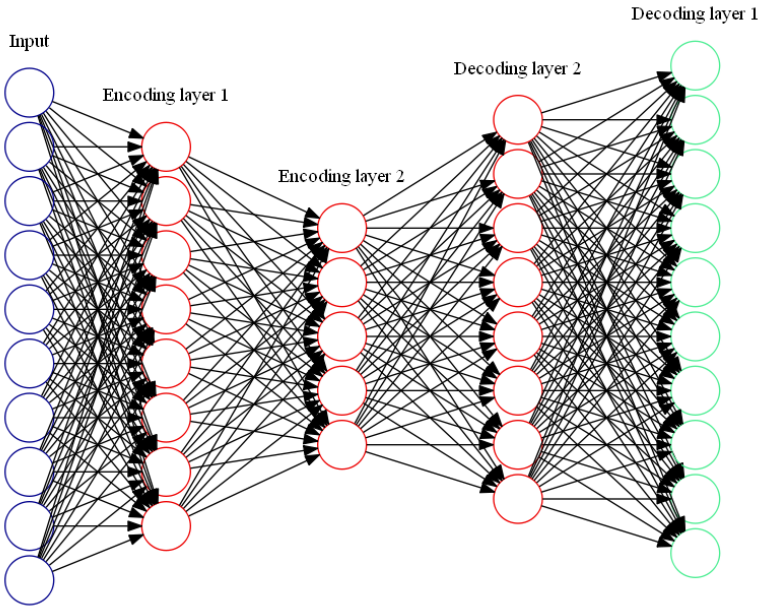

Рисунок 4.1: Многослойный автоассоциатор

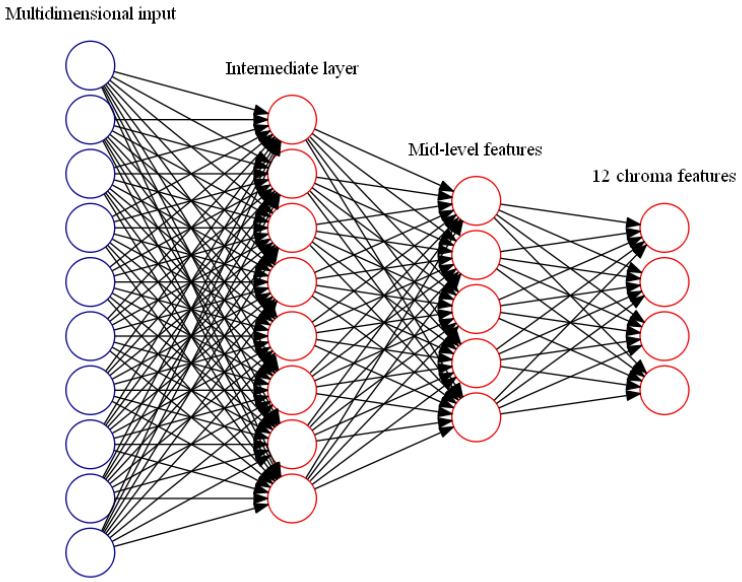

Рисунок 4.2: Многослойная нейронная сеть

Из автоассоциаторов можно строить многослойные модели, отождествляя нейроны из скрытого слоя одного автоассоциатора со входными нейронами другого. Пример такой модели показан на рисунке 4.1. В полученной модели слои можно обучать друг за другом на неразмеченных данных. Значения, полученные в скрытом слое последнего из автоассоциаторов, могут быть использованы как векторы признаков. Пример полученной нейронной сети показан на рисунке 4.2

Рекуррентный автоассоциатор может быть получен из обычного путём добавления рекуррентных соединений, связывающих выходы скрытого слоя с дополнительными его входами, по одному дополнительному входу на каждый выход. Фактически, при этом получается сеть Эльмана, впервые описанная в [85]. Пример такой нейронной сети представлен на рисунке 4.3. Промежуточное представление $y(x_t)$ в таком случае вычисляется как

$$y(x_t) = s(Wx_t + b + Uy(x_{t-1})) \tag{4.5}$$

4.2 Построение нейронной сети и предобучение при помощи автоассоциаторов

Существенным недостатком автоассоциаторов является невозможность содержательной интерпретации значений во внутреннем слое. В частности, невозможно построить шаблонные наборы значений, соответствующие аккордам. Можно попытаться обучить алгоритм классификации на векторах значений на выходах внутреннего слоя. Но для случая 25 классов и достаточно большой размерности векторов для обучения такого классификатора может потребоваться слишком много данных.

Вместо этого соединим внутренный слой с дополнительным слоем, имеющим 12 выходов. Полученную нейронную сеть обучим на размеченных данных таким образом, чтобы на выходе получались хроматические векторы (как в разделе 3.4.1), в которых каждая компонента соответствует одному тональному классу. На вход этой сети будут подаваться столбцы спектрограммы. Таким образом, вместо задачи классификации полученная нейронная сеть решает задачу регрессии. Классификация же полученных 12-мерных векторов делается точно так же, как и для других типов векторов признаков.

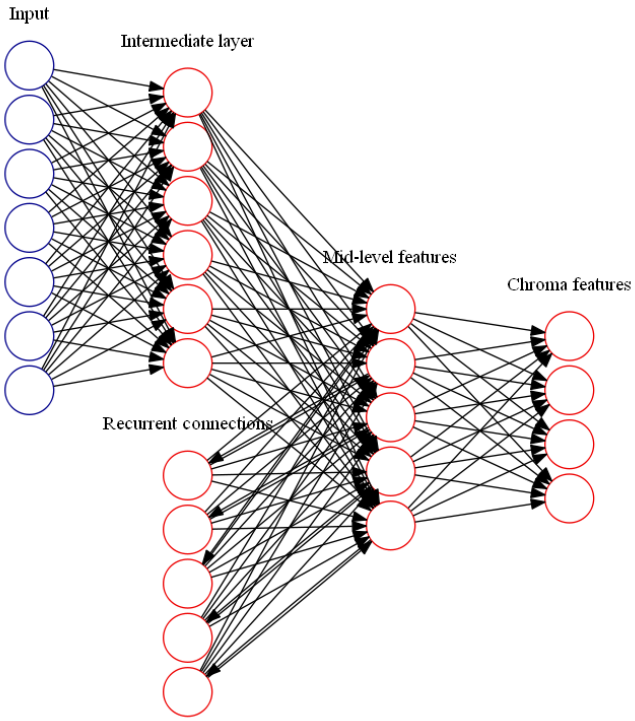

Рисунок 4.3: Многослойная нейронная сеть с рекуррентными соединениями

Предварительное обучение слоёв-автоассоциаторов будем производить методом мини-пакетного (mini-batch) стохастического градиентного спуска. При этом сначала обучается первый слой на всём обучающем множестве, затем полученные значения используются для обучения второго слоя, и так далее. Окончательное обучение сети в целом также производится методом мини-пакетного стохастического градиентного спуска. При этом в качестве целевых векторов используются 12-мерные бинарные шаблоны аккордов (описанные в параграфе 2.4.1), а для случая отсутствия аккорда – нулевой вектор. При классификации, соответственно, отсутствие аккорда определяется в случае, кодга ни одна из компонент полученного вектора по абсолютной величине не превосходит некоторого значения Δ, которое подбирается опытным путём.

Для очищающего автоассоциатора возможные помехи на входе можно смоделировать при помощи аддитивного гауссового шума $\tilde{x}|x \sim \mathcal{N}(x, \sigma_0^2 I)$, где σ_0 – параметр. Это соответствует предположению о том, что помехи равновероятны в любой области спектра. Возможны и другие варианты моделирования помех. Для обучения последующих слоёв также будем использовать эту модель шума с параметром σ_i вместо σ_0 для i-го слоя.

Естественным выбором для функции стоимости будет квадрат евклидова расстояния между шаблоном и вектором на выходе:

$$L(x, z) = ||x - z||^2$$

Для случая отсутствия аккорда в качестве соответствующего шаблона будем использовать нулевой вектор.

В случае, когда в обучающей выборке большинство примеров соответствуют только одному классу, очень вероятно получить в итоге сеть, которая все векторы будет классифицировать как принадлежащие этому классу. В данном случае имеется 25 возможных классов, и желательно иметь приблизительно одинаковое количество примеров на каждый класс. Однако не все аккорды используются в музыке одинаково часто, и аккорд *до-мажор* может встречаться в обучающей выборке в разы чаще, чем *фа-диез-мажор*.

Аналогичная проблема встречается и при обучении скрытых марковских моделей и байесовских сетей для определения последовательности аккордов по последовательности векторов признаков. В этих моделях часто используют циклический сдвиг векторов признаков для усреднения параметров, соответствующих разным аккордам. Этот процесс подробно описан, например, в [25]. Идея его состоит в том, что, поскольку в хроматическом векторе каждая компонента соответствует одному тональному классу, его циклический сдвиг даёт вектор, соответствующий аккорду того же типа (мажорный или минорный) с основной нотой, сдвинутой на полутон.

В данном случае при окончательном обучении нейронной сети в целом можно также использовать сдвиг. Но входными векторами являются столбцы спектрограммы, и циклический сдвиг соответствует неестественному переносу высокочастотных компонент в область низких частот (или наоборот). Циклический сдвиг можно эмулировать, добавив одну октаву к частотному диапазону спектрограммы, после чего просто сдвигать по столбцу спектрограммы окно на октаву короче.

При помощи такого сдвига из каждого столбца спектрограммы получается 12 различных столбцов, соответствующих 12 аккордам одного типа с разными основными нотами. Это позволяет уравновесить количество аккордов в пределах одного типа. Чтобы уравновесить количество аккордов между типами, потребуем, чтобы в процессе генерации обучающей выборки из спектрограмм разница между общим количеством мажорных аккордов и общим количеством минорных аккордов не превосходила заданного числа H.

Во время тестирования также можно использовать циклический сдвиг. Для этого также для каждого столбца спектрограммы генерируется 12 тестовых векторов, для каждого из которых при помощи нейронной сети получается хроматический вектор. Для полученных 12 хроматических векторов производятся соответствующие обратные сдвиги, а в качестве результата берется среднее арифметическое от полученных векторов.

Анализу различных конфигураций нейронной сети и подбору наилучших параметров посвящён параграф 5.4.

4.3 Выводы

1. Предложен метод для получения хроматических векторов из столбцов спектрограммы с использованием предварительно обученной многослойной нейронной сети.

2. Предложен способ для создания обучающей выборки, содержащей приблизительно одинаковое количество векторов для всех возможных аккордов.

Глава 5

Эксперименты

Описанные в главах 3 и 4 алгоритмы имеют значительное количество параметров. Для подбора их оптимальной комбинации, фактически, необходимо решить задачу многомерной оптимизации в достаточно большом пространстве. Очевидно, что в данном случае невозможно решить эту задачу аналитически. Также невозможно перебрать все возможные комбинации параметров ввиду слишком большого их числа. Однако во многих случаях можно определить разумный диапазон возможных значений параметра и исследовать изменение качества распознавания аккордов в зависимости от значений данного параметра в указанном диапазоне.

Применение методов вычисления классификации векторов признаков, основывающихся на машинном обучении, не позволяет целиком избавиться от ручного подбора параметров. Во-первых, эти алгоритмы могут иметь метапараметры, не изменяемые в процессе обучения (например, количество нейронов в j-м слое нейронной сети). Во-вторых, параметры имеются также на этапах подготовки входных данных и интерпретации результата.

Поскольку все эксперименты проводились на описанной в разделе 5.1.1 коллекции из 312 музыкальных звукозаписей, найденные значения параметров будут оптимальными только для этой коллекции. Способствовать преодолению этой проблемы могли бы достаточно большие коллекции аннотированных композиций, не существующие на данный момент.

Все эксперименты можно разделить на 4 группы. В разделе 5.2 рассматривается этап предварительной обработки звукозаписи и получения спектрограммы. В разделе 5.3 исследуется влияние различных преобразований спектрограммы на качество распознавания аккордов. Эксперименты в разделе 5.4 направлены на отыскание наилучших параметров нейронной сети, используемой для получения признаков. Преобразования над последовательностями векторов признаков и распознанных аккордов и параметры выбранного метода классификации анализируются в разделе 5.5. В разделе 5.7 сравниваются скорости работы реализованных алгоритмов.

5.1 Оценка качества распознавания аккордов

Поскольку алгоритмы распознавания аккордов предназначаются для обработки музыкальных звукозаписей, необходимо оценивать качество их работы на реальных звукозаписях, а не на искусственно сгенерированных примерах. Чтобы звукозапись можно было использовать для оценки, требуется вручную решить задачу распознавания последовательности аккордов, то есть для каждого момента времени $t \in [t_{start}, t_{end}]$ указать аккорд $y \in \overline{Y}$, звучащий в этот момент. При этом набор $\overline{Y}$ включает в себя все возможные в музыке сочетания нот и отдельные ноты. Также требуется с высокой точностью указать моменты начала и конца звучания аккордов. Всё это делает задачу подготовки тестовых коллекций очень трудоёмкой.

Для хранения этой информации используют особым образом отформатированные текстовые файлы, называемые файлами разметки или файлами текстовых аннотаций. Ниже приведён пример такого файла:

```
0.000     0.848     N
0.848     1.625     A:min
1.625     3.017     G:maj
3.017     3.895     F:maj
...
```

Первый и второй столбцы содержат время начала и конца звучания аккорда соответственно, в третьем столбце записывается название аккорда.

5.1.1 Коллекции текстовых аннотаций

На текущий момент существует 5 коллекций текстовых аннотаций для популярной музыки разных исполнителей:

- *Isophonics* [86]. Текстовые аннотации для 180 композиций (12 альбомов) *The Beatles*, 20 композиций *Queen* (с альбома *Greatest Hits*), 18 композиций *Zweieck* (с альбома *Zweilicht*). Наиболее часто используется для исследований, несколько раз использовалась для ежегодных соревнований MIREX Audio Chord Estimation.
- *RWC Pop Music* [87]. Текстовые аннотации для 100 композиций японской и западной популярной музыки.
- *Billboard* [88]. Текстовые аннотации для 197 композиций из американского чарта *Billboard 100* за промежуток с 1958 по 1991 год. Использовалась в соревновании MIREX Audio Chord Estimation в 2012 году.
- *uspop2002* [89]. Текстовые аннотации для 195 композиций американской популярной музыки.
- *Robbie Williams annotations*. Текстовые аннтоации для 65 композиций *Robbie Williams* (первые 5 альбомов).

Поскольку в аннотациях указывается точное время, важно при анализе использовать точно те же версии звукозаписей, которые были использованы при подготовке аннотаций. Это затрудняет использование некоторых коллекций. Для тестирования алгоритмов в рамках данной работы использовались коллекции *Isophonics* и *RWC Pop Music*.

5.1.2 Сопоставление последовательностей аккордов

Вопросом оценки того, насколько одна последовательность аккордов (определённая автоматически) соответствует другой (правильной, определённой человеком), занимались Харте [90] и Пауэлс и Питерс [91]. Последние предлагают следующую конструкцию для определения схожести двух последовательностей аккордов.

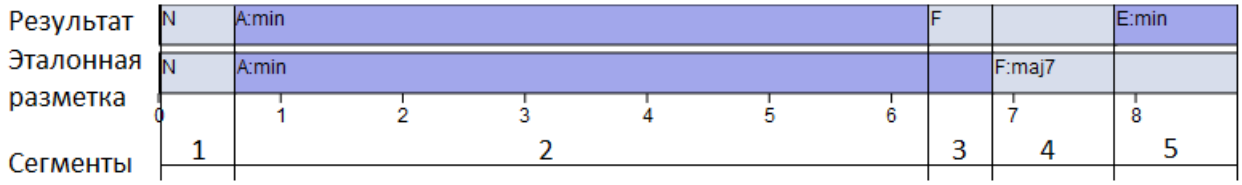

Рисунок 5.1: Сопоставление последовательностей аккордов.

Пусть заданы 2 последовательности аккордов: правильная и определённая при помощи алгоритма. Объединим множества границ аккордов из обоих последовательностей в одно

множество. Используя эти границы, разделим исходную композицию на сегменты (как на рисунке 5.1), на каждом из которых однозначно заданы правильный аккорд c_{ref} и определённый автоматически c_{est}. Пусть также $c_{ref} \in C_{REF}$ – множество всех аккордов, встречающихся в аннотациях, а $c_{est} \in C_{EST}$ – множество всех аккордов, которые могут быть результатом распознавания при помощи данного алгоритма.

Практически всегда $C_{EST} \subset C_{REF}$, поэтому возникает вопрос о том, как сопоставлять фрагменты, на которых $c_{ref} \notin C_{EST}$. Такие фрагменты можно либо отбрасывать, либо задать сюръективное отображение $\mathcal{M} : C_{MI} \to C_{MO}$, которое «сложным» аккордам из множества C_{MI} будет сопоставлять «простые» аккорды из множества C_{MO}. Нужно выбрать эти множества и отображение $\mathcal{M}$ таким образом, чтобы $C_{EST} \subset C_{MI}$. Сравниваться при этом будут аккорды $\mathcal{M}(c_{ref})$ и $\mathcal{M}(c_{est})$. Сегменты, на которых $c_{ref} \notin C_{MI}$, отбрасываются. Примером отображения $\mathcal{M}$ может служить отображение, которое всем аккордам, состоящим из мажорного трезвучия и более высоких ступеней (например, доминантсептаккорд, нонаккорды и другие) сопоставляет мажорный аккорд, соответствующий этому трезвучию.

Если необходимо оценить качество распознавания аккордов определенного типа (например, только трезвучий или только мажорных аккордов), можно ввести дополнительные множества C_{LI} и C_{LO}, ограничивающие соответственно множества C_{MI} и C_{MO}. Тогда аккорды (c_{ref}, c_{est}) сравниваются (не отбрасываются), только если $c_{ref} \in C_{LI} \cap C_{MI}$ и $\mathcal{M}(c_{ref}) \in \mathcal{M}(C_{LI} \cap C_{MI}) \cap C_{LO}$.

Пусть $\mathcal{S} : C_{SR} \times C_{SE} \to \mathbb{R}^+$ – функция оценки, причем $\mathcal{M}(C_{LI} \cap C_{MI}) \cap C_{LO} \subset C_{SR}$ и $C_{MO} \subset C_{SE}$. Эта функция сопоставляет паре аккордов $\mathcal{M}(c_{ref})$ и $\mathcal{M}(c_{est})$ неотрицательное действительное число, которое выражает сходство этих аккордов между собой. Например, можно определить функцию $\mathcal{S}$ как равную 1 в случае, когда аккорды совпадают, и 0 иначе.

Как видно из [91], полученные цифры сильно различаются в зависимости от выбора отображения $\mathcal{M}$ и функции оценки $\mathcal{S}$, и даже в зависимости от некоторых мелких деталей, таких как способ синтаксического разбора названий аккордов. Не всегда в статьях корректно указываются использованные метрики, что делает затруднительным непосредственное сравнение оценок качества распознавания из статей друг с другом. В этом состоит главная ценность соревнования MIREX Audio Chord Estimation, где гарантированно используются одни и те же коллекции и метрики для оценки всех алгоритмов.

Рассмотрим 3 наиболее характерных метрики из [91].

1. “Mirex2010”. В ней не используется отображение $\mathcal{M}$, а функция оценки $\mathcal{S}$ строится следующим образом. Сначала c_{ref} и c_{est} преобразуются в множества тональных классов, для которых находится пересечение. Обозначим количество элементов в пересечении за u. $\mathcal{S} = 1$ в случаях:

   - c_{ref} является уменьшенным или увеличенным аккордом и $u \geq 2$;
   - c_{ref} и c_{est} являются символами отсутствия аккорда;
   - $u \geq 3$.

   В остальных случаях $\mathcal{S} = 0$, то есть $\mathcal{S} : C_{SR} \times C_{SE} \to \{0, 1\}$.

2. “Triads”. Отображение $\mathcal{M}$ строится следующим образом. Если существует мажорное или минорное трезвучие с основной нотой, соответствующей основной ноте аккорда, и имеющее 3 общих ноты с аккордом, то оно сопоставляется этому аккорду. Например, для доминантсептаккорда с добавленной ступенью G:7(9) результатом сопоставления будет мажорное трезвучие G:maj, а для аккорда F:aug сопоставления не существует. Аккорды, которым невозможно сопоставить мажорное или минорное трезвучие, из оценки исключаются. $\mathcal{S} = 1$ тогда и только тогда, когда c_{ref} и c_{est} совпадают.

3. “Tetrads”. Отображение $\mathcal{M}$ строится аналогично “Triads”, но помимо мажорного и минорного трезвучий рассматриваются также мажорный и минорный септаккорды и доминантсептаккорд, а в качестве результата выбирается аккорд, имеющий наибольшее количество общих нот с заданным. Так, для доминантсептаккорда с добавленной ступенью G:7(9) результатом сопоставления будет доминантсептаккорд G:7. $\mathcal{S} = 1$ тогда и только тогда, когда c_{ref} и c_{est} совпадают.

Отметим, что при использовании метрики “Mirex2010” ни один сегмент не отбрасывается. Это может быть нежелательно, поскольку в полученном результате будут учитываться в том числе и сегменты, содержащие аккорды, которые в принципе не могут быть распознаны имеющимся методом. Ещё одним недостатком этой метрики является невозможность различить трезвучие и содержащий его септаккорд: при совпадении хотя бы трёх нот аккорды будут считаться совпадающими. Поэтому в дальнейших экспериментах будут использоваться метрики “Triads” и “Tetrads”, позволяющие более точно оценить качество распознавания аккордов. Первая метрика будет использоваться вместе с набором из 24 шаблонов для всех мажорных и минорных трезвучий, а вторая – с набором из 60 шаблонов, в который входят также шаблоны для всех доминантсептаккордов и мажорных и минорных септаккордов.

Метрика “Mirex2010” использовалась в соревновании MIREX Audio Chord Estimation в 2010, 2011 и 2012 годах. Но в 2013 году вместо неё были использованы метрики “Triads”, “Tetrads”, а также некоторые другие, позволяющие учесть также обращения аккордов и басовую ноту. Поскольку описываемый здесь алгоритм не предназначен для определения обращений аккордов, нет смысла использовать эти дополнительные метрики.

Пусть $\ell_1, \ell_2, \ldots, \ell_{N_{segm}}$ – длины всех сегментов в пределах одной композиции, а $s_1, s_2, \ldots, s_{N_{segm}}$ – соответствующие значения метрики. Тогда *коэффициент перекрытия (overlap ratio, OR)* для данной композции определяется как

$$OR = \frac{\sum_{i=1}^{N_{segm}} s_i \ell_i}{\sum_{i=1}^{N_{segm}} \ell_i} \tag{5.1}$$

При этом неважно, были ли сегменты взяты из одной и той же композиции или из нескольких разных. Но для того, чтобы иметь возможность определить статистически значимые различия между системами, в экспериментах будем определять коэффициент перекрытия отдельно для каждой композиции.

Для примера, на рисунке 5.1 $s_1 = s_2 = s_4 = 1$, $s_3 = s_5 = 0$. На сегментах 1 и 2 аккорды совпадают, на сегменте 4 аккорды F:maj и F:maj7 имеют 3 общих ступени F, A, C.

Пусть коллекция содержит N_{tracks} композиций, для каждой из которых вычислен коэффициент перекрытия OR_k. Обозначим за $L_i = \sum_{i=j}^{N_{segm}} \ell_j$ длину i-й композиции. Тогда совокупная метрика для коллекции, называемая *взвешенным средним коэффициентом перекрытия (weighted average overlap ratio, WAOR)*, вычисляется следующим образом:

$$WAOR = \frac{\sum_{i=1}^{N_{tracks}} OR_i \cdot L_i}{\sum_{i=1}^{N_{tracks}} L_i} \tag{5.2}$$

Такой же способ усреднения применяется в соревнованиях MIREX Audio Chord Estimation. В качестве результатов экспериментов в последующих разделах приведены значения взвешенных средних коэффициентов перекрытия для метрик “Triads” и “Tetrads”.

5.1.3 Сопоставление границ сегментов

Метрика для сопоставления границ сегментов была введена Маухом в [92]. Начиная с 2013 года она также применяется в соревнованиях MIREX Audio Chord Estimation. Она позволяет оценить качество определения границ аккордов алгоритмом, игнорируя при этом сами названия аккордов.

Пусть заданы 2 разбиения звукозаписи длины L на сегменты $G^0 = (G_i^0)$ и $G = (G_i)$. Направленное расхождение Хэмминга определяется как:

$$h(G||G^0) = \sum_{i=1}^{N_G} \left(|G_i^0| - \max_j |G_i^0 \cap G_j| \right)$$

где N_G – количество сегментов в разбиении G, а $|\cdot|$ – длина сегмента. Оно определяет, насколько G фрагментировано по отношению к G^0. Тогда *сегментация* $H(G, G^0)$ определяется как

$$H(G, G^0) = 1 - \frac{1}{L} max\{h(G||G^0), h(G^0||G)\} \in [0, 1]$$

В экспериментах одно из разбиений задаётся правильной разметкой звукозаписи, а другое – результатом распознавания аккордов с использованием только шаблонов для мажорных и минорных трезвучий. Для усреднения значений сегментации вычислялось простое среднее арифметическое от полученных значений по всем композициям из коллекции.

5.1.4 Статистическая значимость

При сравнении нескольких вариантов алгоритма помимо средних значений метрик качества необходимо понять, действительно ли между этими вариантами имеются статистически значимые различия. Для проверки этого предположения будем использовать непараметрический критерий Фридмана. Он позволяет проверять гипотезы о различии более двух зависимых выборок. В отличие от дисперсионного анализа (ANOVA), критерий Фридмана не требует предположений о нормальности распределения значений метрик для разных композиций, а также одинаковых дисперсий этих распределений для разных вариантов алгоритма (как отмечается в [36], эти предположения не является верными в данном случае).

Однако, если в соответствии с критерием Фридмана удаётся отвергнуть нулевую гипотезу (об отсутствии различий между разными методами), необходимо выяснить, для каких пар методов имеется статистически значимая разница в качестве распознавания аккордов. Для этого вычисляется среднее Тьюки (Tukey's honestly significant difference). В отличие от T-теста, при его допускаются множественные попарные сравнения. Этот метод используется для сравнения качества работы разных алгоритмов в рамках всех соревнований MIREX [93]. В экспериментах среднее Тьюки вычислялось для значений взвешенного среднего перекрытия, полученных с использованием метрики "Triads".

5.1.5 Совокупная длительность

Совокупная длительность композиций в коллекции составляет 61701,61 с. Совокупная длительность участвующих в оценке фрагментов (для аккордов на которых определено отображение $\mathcal{M}$) составляет 58937,75 с, что составляет более 95% от совокупной длительности всех композиций.

Совокупная продолжительность звучания аккордов каждого из типов (с учётом отображения $\mathcal{M}$ для метрик) приведена в таблице 5.1. Видно, что в звукозаписях из коллекции преобладают мажорные трезвучия и аккорды, основанные на них.

5.1.6 Типы ошибок

Для удобства в дальнейшем ошибки будут сгруппированы по типам. Название типа ошибок начинается с типа ожидаемого (правильного) аккорда и может включать тип неправильно определённого аккорда, например, maj или maj-min. Ошибки maj-maj соответствуют случаю,

Таблица 5.1: Совокупная продолжительность звучания аккордов в секундах

Тип	Triads	%	Tetrads	%
maj	41733.38	70.81%	34381.76	58.34%
7	-	-	4862.02	8.25%
maj7	-	-	2489.6	4.22%
min	14681.45	24.91%	9921,61	16.83%
min7	-	-	4759.83	8.08%
N	2522.92	4.28%	2522.92	4.28%

когда вместо мажорного аккорда был определён мажорный аккорд с другой основной нотой. Поскольку используемые метрики “Triads” и “Tetrads” используют отображение $\mathcal{M}$ для сведения в некотором смысле более сложных аккордов к более простым (например, G:7(9) к G:7 или G:maj), это же отображение будет применяться ко всем ожидаемым аккордам для уменьшения количества типов ошибок. Так, при использовании метрики “Triads” тип maj7-min будет включен в тип maj-min и не будет рассматриваться отдельно. Аккорды, которым в результате действия отображения $\mathcal{M}$ не сопоставляется никакой другой аккорд, исключаются как из итогового результата, так и из статистики ошибок. Типы ошибок N-chord и chord-N (где chord – любой аккорд) будем объединять в один, поскольку на них оказывает влияние в первую очередь способ определения отсутствия звучащего аккорда.

Ошибки метода можно рассматривать на трёх уровнях. Каждый последующий уровень уточняет предыдущий.

1. Совокупная длительность ошибочных фрагментов в зависимости от типа звучащего аккорда. Например, maj.

2. Совокупная длительность ошибочных фрагментов в зависимости от типа звучащего аккорда и типа неверно определённого аккорда. Например, maj-min. Тип maj-maj соответствует случаям, когда вместо мажорного аккорда неверно определён мажорный аккорд с другим основным звуком.

3. Совокупная длительность ошибочных фрагментов в зависимости от типа звучащего аккорда, типа неверно определённого аккорда и расстояния в полутонах между основными звуками аккордов.

В дальнейшем на диаграммах под буквами а), б) будет показано распределение ошибок, соответствующее первому уровню. Под буквами в), г) (если присутствуют) – соответствующее второму или третьему уровню. Высота столбцов соответствует совокупной длительности фрагментов звукозаписей, содержащих ошибки соответствующего типа. Столбцы сгруппированы по типам ошибок. Цвета столбцов соответствуют разным значениям описываемого параметра.

5.2 Вычисление спектрограммы

На данном этапе необходимо выбрать наилучшие из доступных алгоритмов для определения ритма и определения частоты настройки. Наилучшее значение для параметра d, задающего задержку для моментов времени, в которых анализируется спектр звука, относительно моментов начала метрических долей, также должно быть определено на этом этапе. Кроме того, необходимо определить наилучшие значения для параметров преобразования постоянного качества: разрешение по частоте N_0 (количество компонент, приходящихся на октаву) и количество октав N/N_0, а также для количества вставляемых промежуточных столбцов спектрограммы T и размера окна при сглаживании w.

5.2.1 Определение ритма

Были рассмотрены 3 алгоритма, позволяющие определить моменты начала метрических долей в звукозаписи: *BeatRoot* [49], *Beat tracker* от Дэвиса [48] (*DBT*) из набора плагинов *Queen Mary Vamp plugins*[1] для системы извлечения музыкальной информации из музыкальных файлов *Vamp*[2] и плагина *INESC Porto Beat Tracking plugin* [94] (*IBT*) для этой же системы. Выбор алгоритмов обусловлен наличием свободно доступной реализации. *BeatRoot* дополнительно потребовал небольшого вмешательства в исходный код для уменьшения потребления вычислительных ресурсов. Кроме того, на 6 композициях из анализируемого набора этот алгоритм не смог определить ритм, поэтому для этих композиций использовались значения, полученные при помощи DBT. Для всех алгоритмов определения ритма использовалось значение задержки $d = 100$ мс.

Таблица 5.2: Влияние алгоритма определения ритма на качество распознавания аккордов

Алгоритм	Triads	Tetrads	Сегментация
BeatRoot + DBT	0.7720	0.4310	0.8141
DBT	0.7592	0.4401	0.8007
IBT	0.7335	0.4160	0.7635
–	0.7113	0.4550	0.7584

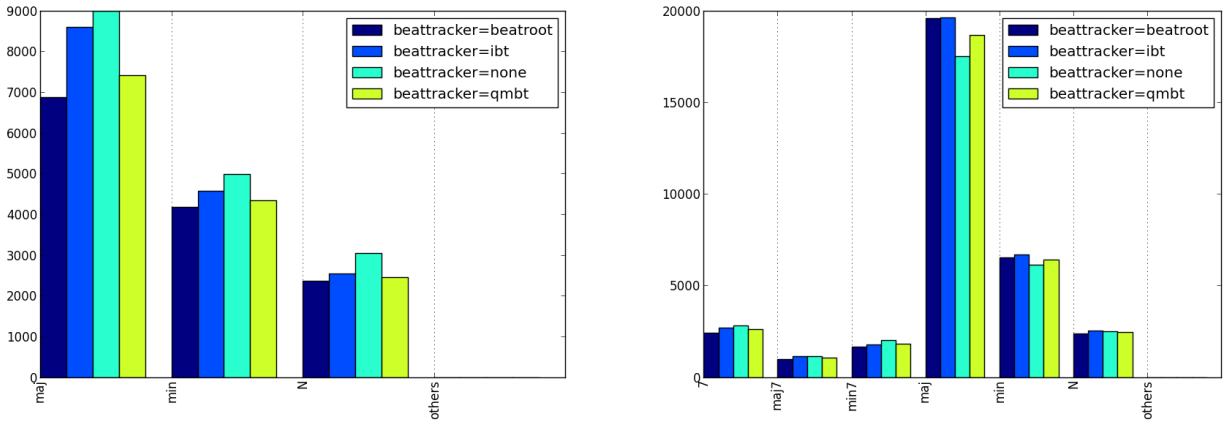

а) б)

Рисунок 5.2: Диаграмма ошибок для разных методов определения ритма

Наилучшие полученные для данных алгоритмов результаты показаны в таблице 5.2. *BeatRoot* показал наилучший результат, статистически значимо превосходящий результаты, полученные с использованием алгоритмов *IBT* и *DBT*. Это достаточно удивительно, поскольку первая версия алгоритма *BeatRoot* была представлена ещё в 2001 году, а в данной работе использовалась его исправленная версия от 2007 года. При этом *DBT* был представлен в 2007 году, а *IBT*, схожий по принципу работы с *BeatRoot*, – в 2012 году.

Последняя строка в таблице 5.2 показывает результат, полученный без определения ритма. При этом искусственно генерировалась последовательность значений времени с шагом в 0.5 с, которые считались моментами начала метрических долей, с задержкой $d = 0$ мс. Ожидаемо, это привело к наихудшему результату, статистически значимо отличающемуся от остальных.

[1] http://www.isophonics.net/QMVampPlugins
[2] http://www.vamp-plugins.org/

5.2.2 Определение задержки

Таблица 5.3: Влияние задержки относительно моментов начала метрических долей на качество распознавания аккордов

d	Triads	Tetrads	Сегментация
0 мс	0.7558	0.4351	0.7932
60 мс	0.7689	0.4303	0.8096
80 мс	0.7711	0.4290	0.8123
100 мс	0.7720	0.4310	0.8141
120 мс	0.7724	0.4374	0.8144

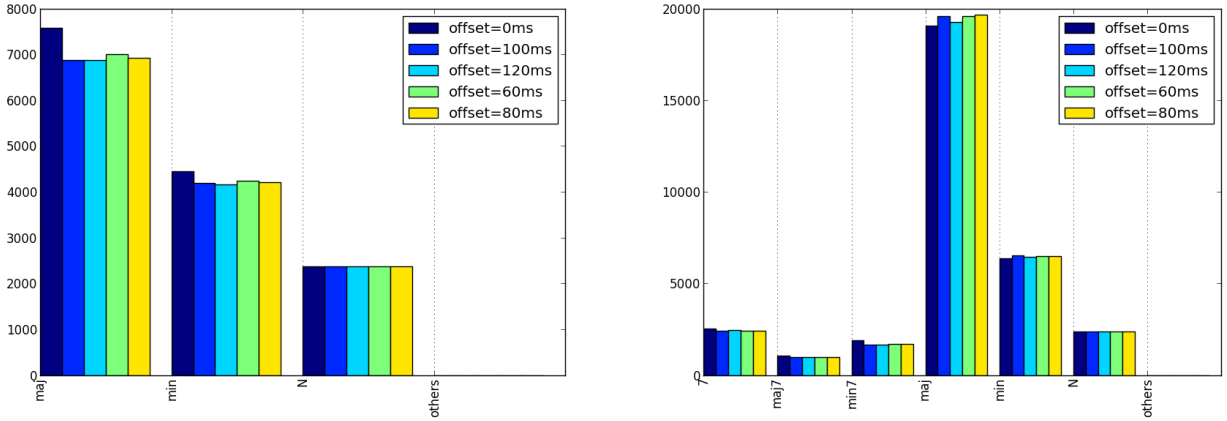

а)

б)

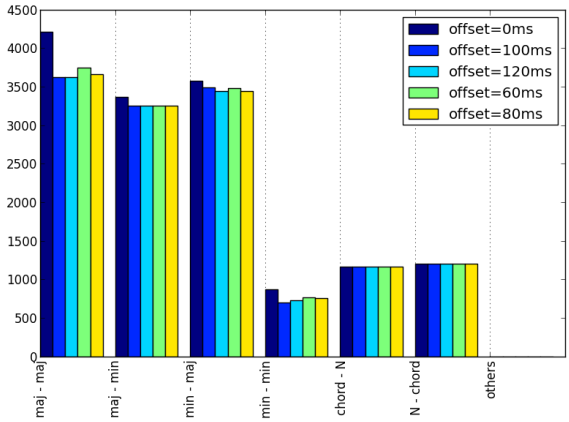

в)

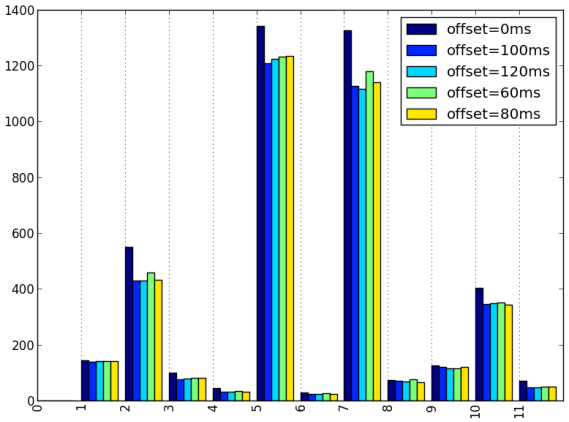

г)

Рисунок 5.3: Диаграмма ошибок для разных значений d

Любое из использованных значений задержки от 60 мс до 120 мс приводит к статистически значимому улучшению качества распознавания аккордов по сравнению с отсутствием задержки. При этом варианты с ненулевыми значениями задержки не имеют статистически значимых различий. Как видно из рисунка 5.3 в), в случае определения только трезвучий при нулевой задержке ухудшение качества распознавания вызвано в основном ошибочным определением основной ноты, а не типа аккорда. Рисунок 5.3 г) показывает распределение расстояний между основными звуками аккордов в полутонах для случая maj-maj. Расстояния в 5 и 7 полутонов соответствуют случаям, когда основной звук правильного аккорда является квинтой ошибочного и наоборот.

5.2.3 Определение частоты настройки

Были проведены эксперименты по распознаванию аккордов с использованием описанного в разделе 3.1.1 алгоритма для вычисления частоты настройки со следующими значениями параметров:

- $f_{min} = 220$ Гц, $N_0 = 12 \cdot 10 = 120$ компонент на октаву;
- $f_{min} = 440$ Гц, $N_0 = 12 \cdot 10 = 120$ компонент на октаву.

Охват во всех случаях составлял 4 октавы. Также для сравнения были проведены эксперименты без коррекции частоты настройки и с использованием алгоритма, описанного Маухом в [92], раздел 3.1.3 и реализованного в виде плагина для системы *Vamp*.

Таблица 5.4: Влияние алгоритма определения частоты настройки на качество распознавания аккордов

Алгоритм	Triads	Tetrads	Сегментация
$f_{min} = 220$ Гц	0.7720	0.4310	0.8141
$f_{min} = 440$ Гц	0.7719	0.4263	0.8134
Маух [92]	0.7718	0.4382	0.8142
–	0.7657	0.4107	0.8120

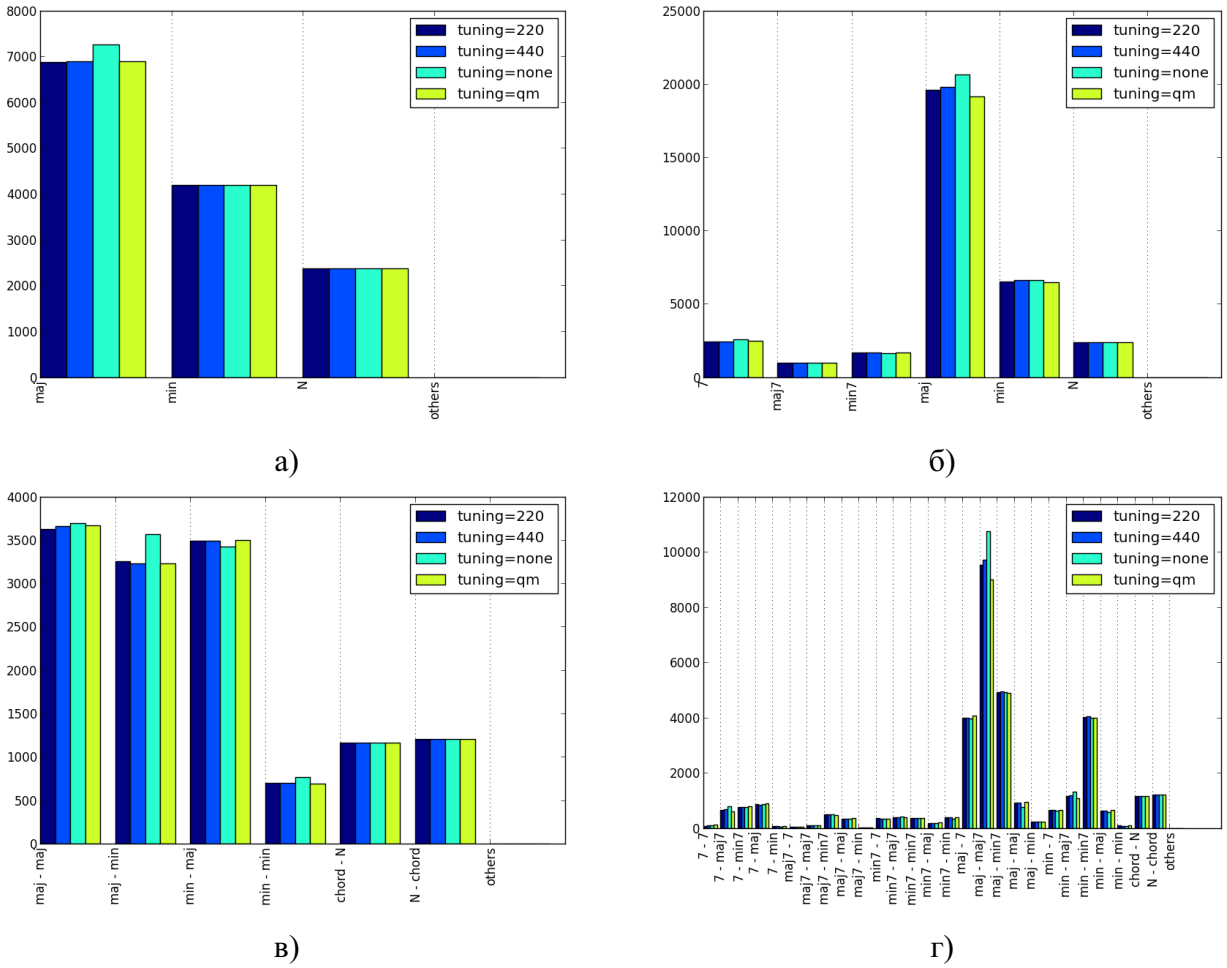

а) б)

в) г)

Рисунок 5.4: Диаграмма ошибок для разных методов определения частоты настройки

Результаты экспериментов приведены в таблице 5.4. Как видно, определение частоты настройки приводит к улучшению качества распознавания аккордов, которое, однако, не является статистически значимым ни для одного из алгоритмов. Из рисунка 5.4 в) можно заметить, что определение частоты настройки помогает уменьшить количество ошибочных определений минорного аккорда для случая трезвучий. А рисунок 5.4 г) показывает, что для случая септаккордов оно помогает уменьшить количество ошибочных определений мажорного септаккорда.

5.2.4 Разрешение по времени и по частоте, сглаживание

Вставка между каждыми двумя соседними моментами начала метрических долей $T-1$ промежуточных значений позволяет повысить разрешение спектрограммы по времени. Затем, после применения скользящего медианного фильтра с размером окна w и прореживания в T раз, спектрограмма содержит ровно 1 столбец на каждую метрическую долю. Ясно, что при больших значениях T имеет смысл выбирать больше значения w и наоборот. В таблице 5.5 приведены значения для некоторых комбинаций T и w.

Таблица 5.5: Влияние параметров T и w на качество распознавания аккордов

Значения параметров	Triads	Tetrads	Сегментация
$T=2$, $w=1$	0.7334	0.3670	0.7999
$T=2$, $w=3$	0.7537	0.4200	0.8094
$T=2$, $w=5$	0.7672	0.4501	0.8149
$T=4$, $w=3$	0.7624	0.4621	0.8115
$T=4$, $w=5$	0.7619	0.4440	0.7992
$T=4$, $w=7$	0.7425	0.3909	0.7664
$T=4$, $w=9$	0.7194	0.3583	0.7307
$T=4$, $w=11$	0.6913	0.3197	0.6917
$T=8$, $w=11$	0.7715	0.4464	0.8176
$T=8$, $w=13$	0.7720	0.4364	0.8160
$T=8$, $w=15$	0.7720	0.4310	0.8141
$T=8$, $w=17$	0.7707	0.4273	0.8089
$T=8$, $w=19$	0.7696	0.3923	0.8043

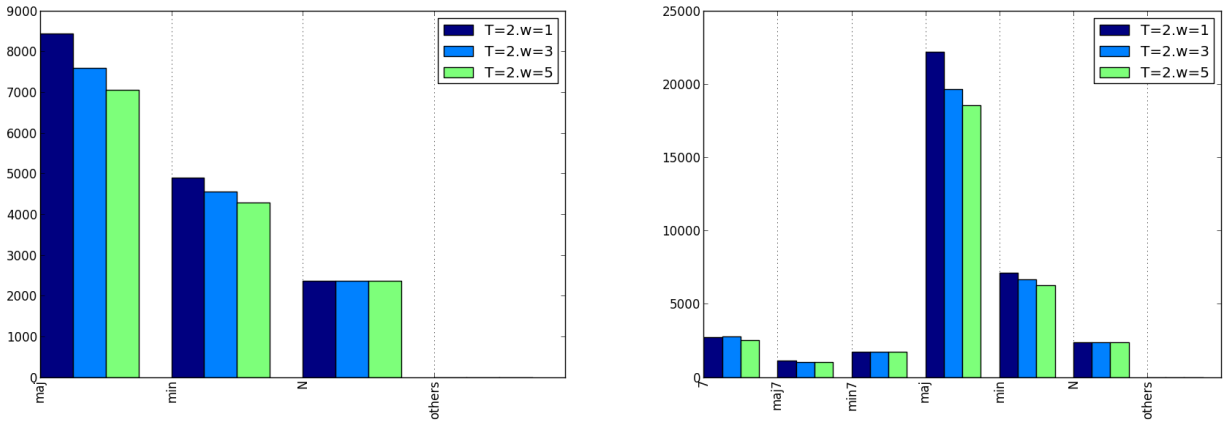

а) б)

Рисунок 5.5: Диаграмма ошибок для разных значений w при $T=2$

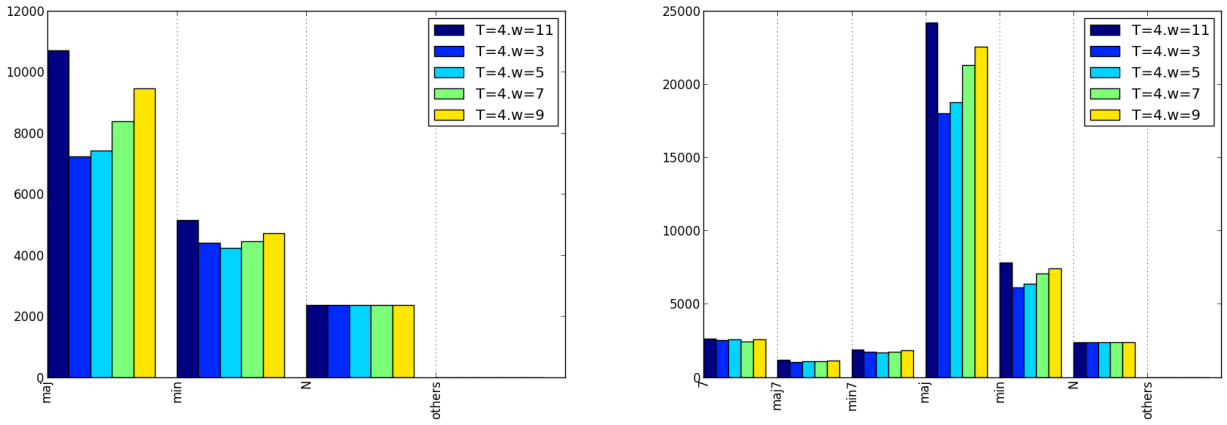

а) б)

Рисунок 5.6: Диаграмма ошибок для разных значений w при $T = 4$

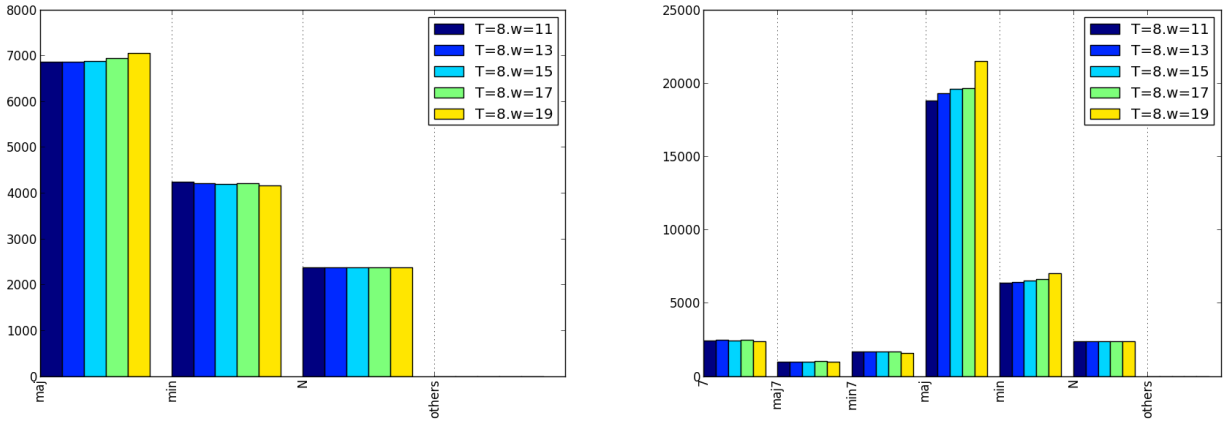

а) б)

Рисунок 5.7: Диаграмма ошибок для разных значений w при $T = 8$

При $T = 2$ качество распознавания аккордов существенно хуже для случая $w = 1$, что фактически соответствует отказу от добавления промежуточных значений и последующих сглаживания и прореживания. Все различия между результатами статистически значимы.

При $T = 4$ результат существенно ухудшается с ростом размера окна w Наилучшие результаты получены при $w = 3$ и $w = 5$, и они статистически значимо превосходят остальные.

При $T = 8$ разница между всеми вариантами очень невелика, статистически значимых различий не обнаружено.

Как показывают рисунки 5.5, 5.6, 5.7, разные значения w влияют только на количество ошибок при распознавании мажорных и минорных трезвучий, но не на количество ошибок при распознавании септаккордов.

Таблица 5.6: Влияние параметра N_0 на качество распознавания аккордов

Значения N_0	Triads	Tetrads	Сегментация
$N_0 = 12$	0.6418	0.0632	0.7898
$N_0 = 36$	0.7720	0.4310	0.8141
$N_0 = 60$	0.7746	0.4266	0.8083

В таблице 5.6 приведены результаты, полученные при разных значениях количества компонент преобразования постоянного качества, приходящихся на одну октаву. Очевидно, что

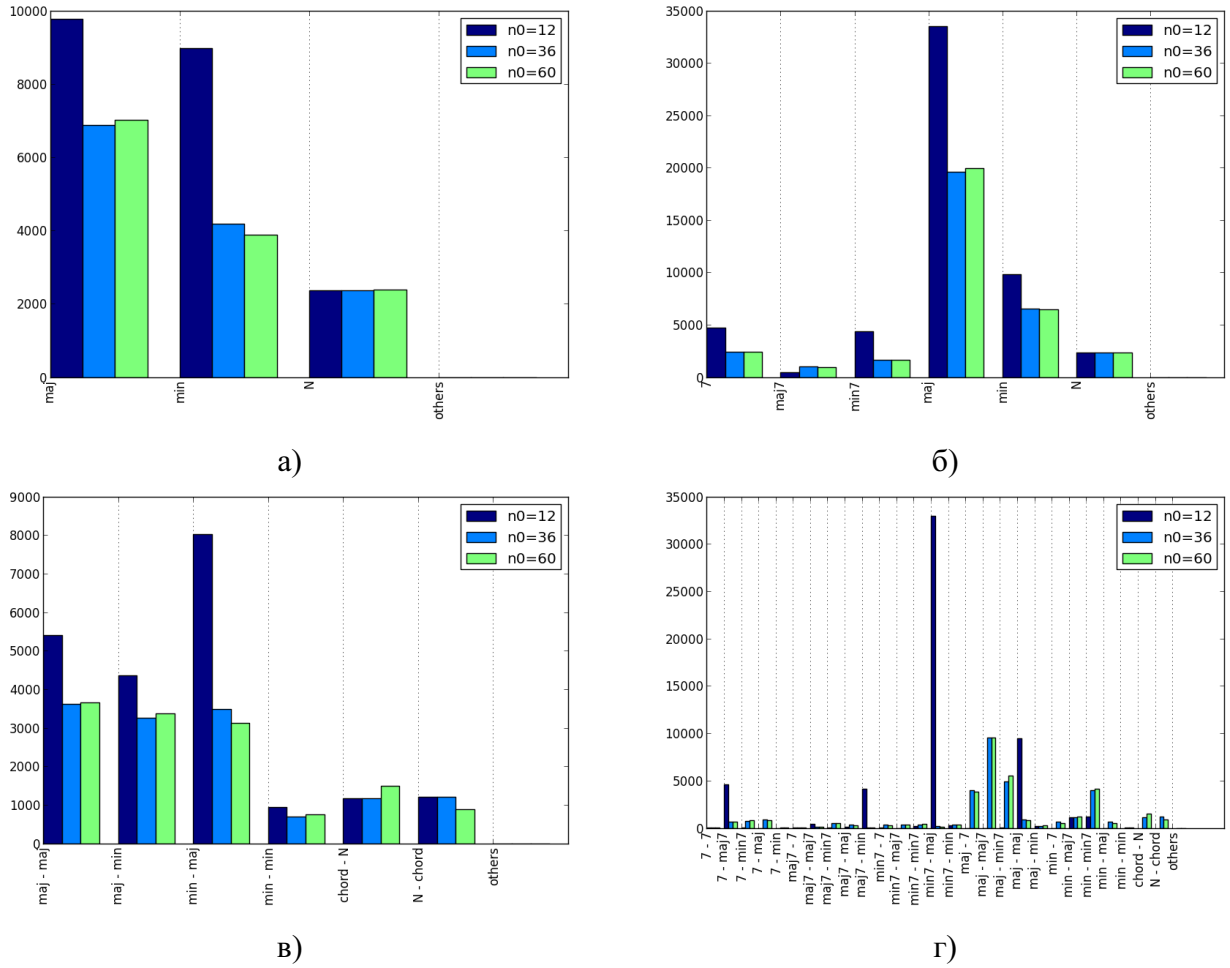

Рисунок 5.8: Диаграмма ошибок для разных значений N_0

при наличии как минимум 36 компонент на октаву (3 компоненты на ноту) качество распознавания аккордов существенно повышается. Различия между $N_0 = 36$ и $N_0 = 60$ не являются статистически значимыми. Однако при $N_0 = 60$ требуется вычислить в 1.8 раз больше значений для компонент преобразования постоянного качества, а также в дальнейшем многократно вычислять дискретное косинусное преобразование для большего набора значений. Из рисунка 5.8 видно, что значение $N_0 = 12$ не позволяет достаточно хорошо различать мажорные и минорные аккорды. Огромное количество ошибок при таком значении N_0 вызваны ошибочным

Эксперименты показывают безусловную важность реализованных методов для улучшенного вычисления спектра. Повышение разрешения по времени с последующим сглаживанием существенно повышает качество распознавания аккордов. Введение задержки относительно моментов начала метрических долей также вносит свой вклад. Использование более высокого разрешения по частоте при вычислении преобразования постоянного качества позволяет использовать больше информации при сглаживании спектрограммы. Превариательное определение ритма при помощи внешних библиотек и предварительное определение частоты настройки при помощи реализованного алгоритма улучшают качество полученной спектрограммы, позволяя вычислять значения спектра для нужных частот в нужные моменты времени. Однако выбор алгоритма определения ритма оказывает существенно более сильное влияние на результат, чем выбор алгоритма определения частоты настройки.

5.3 Преобразования спектрограммы

На этом этапе необходимо оценить эффективность предложенных улучшений при обработке спектрограммы: применение аналога фильтра Превитт, сглаживание с использованием матрицы самоподобия. Также необходимо определить опитмальные значения для количества зануляемых первых коэффициентов ξ дискретного косинусного преобразования, для доли сохраняемых в матрице самоподобия значений ζ.

5.3.1 Применение аналога фильтра Превитт

В разделе 3.2 было предложено использовать аналог фильтра Превитт для подавления компонент спектра, соответствующих шумовым звукам ударных инструментов. Признаки CRP позволяют решить эту же задачу. Поэтому имеет смысл сравнить итоговое качество распознавания аккордов с применением каждого из этих методов в отдельности.

Таблица 5.7: Влияние разных способов подавления шумовых звуков на качество распознавания аккордов

Способ подавления	Triads	Tetrads	Сегментация
Превитт	0.7492	0.5896	0.8063
Признаки CRP	0.7720	0.4310	0.8141
Превитт + признаки CRP	0.7524	0.5520	0.8066

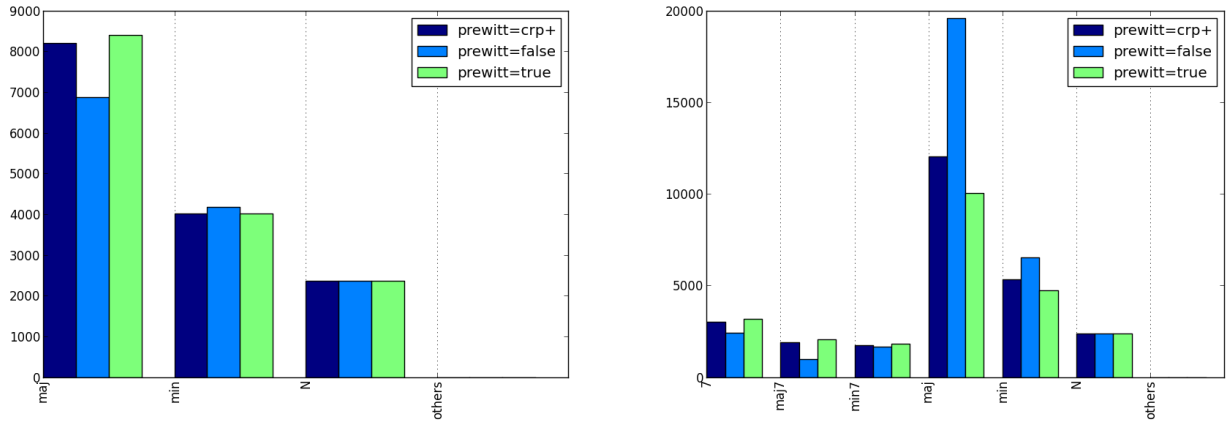

а) б)

Рисунок 5.9: Диаграмма ошибок для разных способов подавления шумовых звуков

Результаты сравнения показаны в таблице 5.7. К сожалению, применение аналога фильтра Превитт только снижает качество распознавания аккордов, независимо от того, будут ли далее применяться признаки CRP. Все попарные различия между вариантами являются статистически значимыми.

5.3.2 Настройка алгоритма вычисления признаков CRP

Вычисление признаков CRP включает в себя взятие логарифма от значений спектрограммы, умноженных на коэффициент η. В работе [63], описывающей этот тип признаков, предлагается выбирать η из диапазона 100–10000. Далее к каждому столбцу спектрограммы применяется дискретное косинусное преобразование. В полученном векторе зануляются первые

Таблица 5.8: Влияние параметра η на качество распознавания аккордов

η	Triads	Tetrads	Сегментация
100	0.7348	0.4815	0.7971
1000	0.7652	0.5170	0.8102
10000	0.7721	0.4721	0.8139
50000	0.7720	0.4310	0.8141
100000	0.7719	0.4202	0.8144

ξ значений, после чего к нему применяется обратное дискретное косинусное преобразование. Необходимо определить влияние параметров η и ξ на качество распознавания аккордов.

В [63] не было обнаружено существенных отличий между значениями η в диапазоне от 100 до 10000 применительно к задаче подавления тембра музыкальных инструментов. Однако в задаче распознавания аккордов этот параметр оказывает достаточно заметное влияние на результат. В таблице 5.8 показаны значения среднего перекрытия и сегментации для разных значений η в промежутке от 100 до 100000. Наилучший результат для метрики “Triads” достигается при $\eta = 10000$, $\eta = 50000$, $\eta = 100000$ (статистически значимые различия отсутствуют). Все остальные различия являются статистически значимыми.

При этом для метрики “Tetrads” наилучшие результаты получаются при меньших значениях η. Из рисунка 5.10 г) можно увидеть, что при больших значениях η растёт количество ошибочно определенных септаккордов вместо соответствующих трезвучий.

Наилучшие результаты в [63] были получены для значений параметра ξ от 22 до 60 при 120-мерном векторе признаков. В этой работе в зависимости от количества охватываемых октав и значения параметра N_0 размерность вектора признаков (столбца спектрограммы) может меняться от 48 до 360. Значения в таблице 5.9 получены при охвате 4 октавы и $N_0 = 36$, что даёт 144-мерный вектор признаков. Видно, что наилучшее качество распознавания аккордов достигается при относительно небольших значениях ξ с резким падением после $\xi = 20$. Только вариант $\xi = 25$ статистически значимо отличается от всех остальных. Из рисунков 5.11 в) и г) видно, что с увеличением ξ растёт количество ошибочно определённых, соответственно, минорных трезвучий и минорных септаккордов.

Таблица 5.9: Влияние параметра ξ на качество распознавания аккордов

ξ	Triads	Tetrads	Сегментация
5	0.7671	0.3734	0.8067
10	0.773	0.4172	0.8138
15	0.7721	0.4310	0.8141
20	0.7705	0.3163	0.8128
25	0.7422	0.1667	0.8055

5.3.3 Применение самоподобия

При использовании матрицы самоподобия для улучшения спектрограммы необходимо выбрать наилушее значение для параметра ζ. Этот параметр контролирует долю столбцов спектрограммы, наиболее схожих с тем, который корректируется в данный момент.

В таблице 5.10 приведены значения среднего перекрытия и сегментации для разных значений ζ. Различия между наилучшими вариантами $\zeta = 0.05$, $\zeta = 0.1$ и $\zeta = 0.15$ не являются статистически значимыми. Значение $\zeta = 0$ соответствует отсутствию коррекции спектрограммы при помощи самоподобия. Полученные при этом значении ζ результаты оказываются существенно хуже, чем при ненулевых значениях ζ.

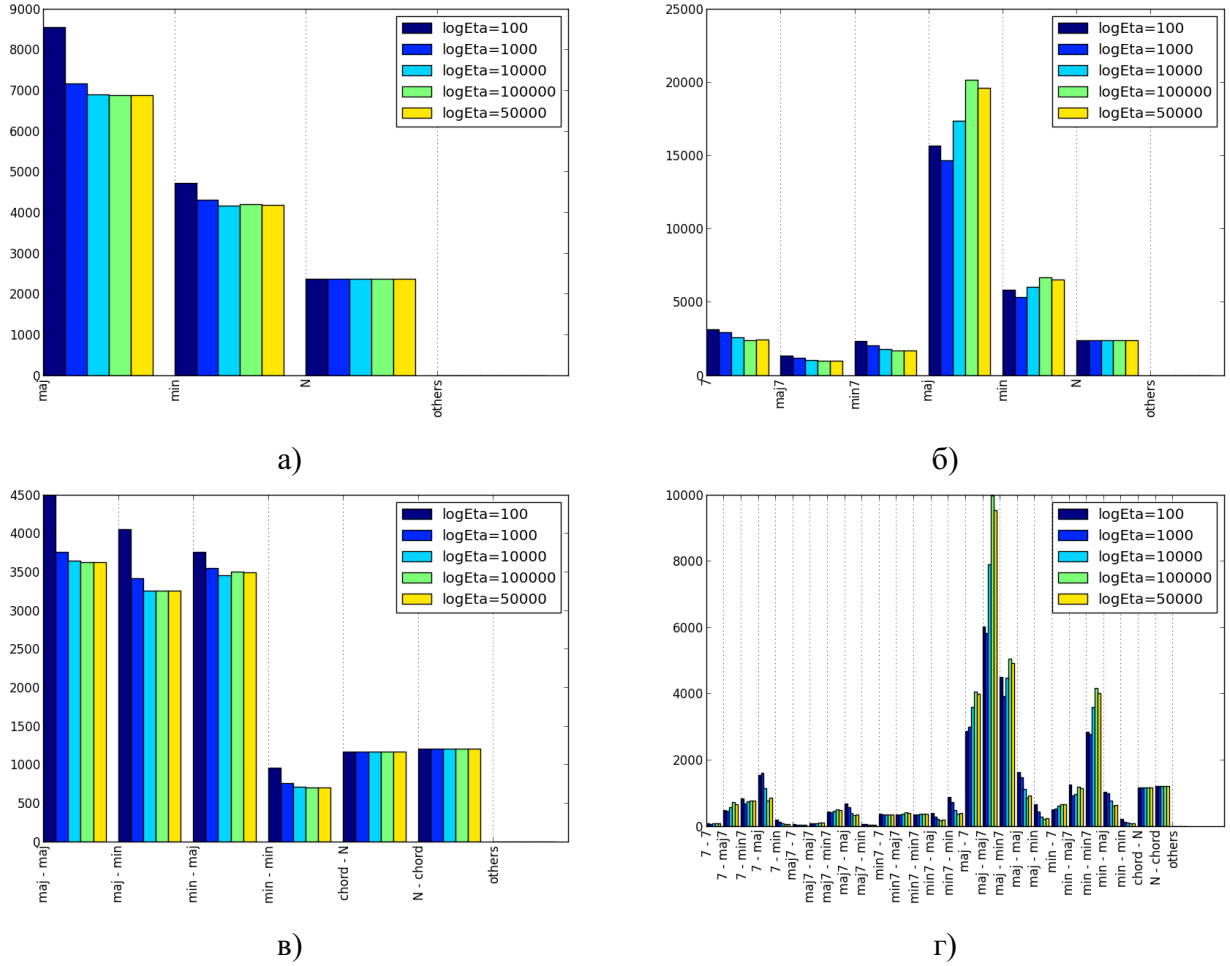

Рисунок 5.10: Диаграмма ошибок для разных значений η

Таблица 5.10: Влияние параметра ζ на качество распознавания аккордов

ζ	Triads	Tetrads	Сегментация
0	0.7001	0.5535	0.7827
0.05	0.7716	0.4204	0.8147
0.1	0.7720	0.4310	0.8141
0.15	0.7663	0.4313	0.8086

В работах [36] и [42] отмечалось положительное влияние от коррекции последовательности векторов признаков с использованием наиболее близких друг к другу векторов. Однако в обеих указанных работах строились матрицы самоподобия для 12-мерных хроматических векторов, в то время как в таблице 5.10 все значения получены с использованием матрицы самоподобия для столбцов спектрограммы. После применения аналогичного метода к хроматическим векторам при $\zeta = 0.08$ были получены значения для взвешенного среднего перекрытия и сегментации, соответственно, 0.7620 и 0.8119. Результат оказался статистически значимо хуже (в соответствии с критерием Вилкоксона).

Использование признаков CRP позволяет более эффективно подавлять шумовые компоненты в спектре по сравнению с применением аналога фильтра Превитт. Эти признаки были предложены в [63] для решения другой задачи, поэтому другими были и оптимальные диапазоны для параметров этих признаков. Коррекция спектрограммы с использованием очищенной матрицы самоподобия приводит к очень существенному повышению качества распознавания

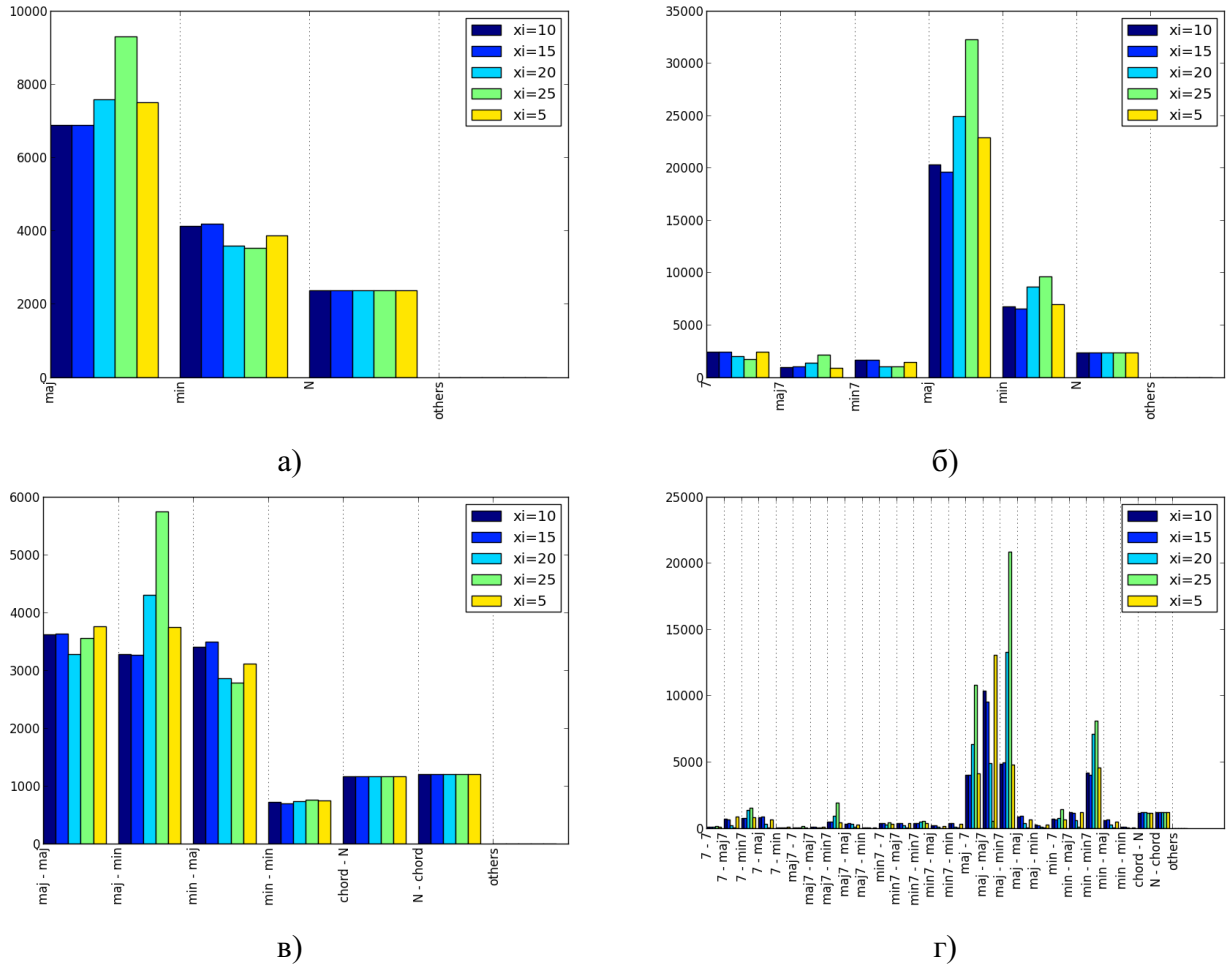

Рисунок 5.11: Диаграмма ошибок для разных значений ξ

аккордов и, таким образом, является одним из самых важных шагов в реализованном алгоритме.

5.4 Нейронные сети

Для нейронной сети необходимо определить оптимальные значения для метапараметров, которые задаются изначально и не изменяются в процессе обучения. Это, прежде всего, конфигурация сети: количество скрытых слоёв и количество нейронов во входном и в скрытых слоях, наличие рекуррентных соединений. Также это уровень шума, используемого при обучении очищающих автоассоциаторов.

Нейронная сеть была реализована на языке *Python* с использованием пакета *Theano* [95]. Обучающие данные делились на мини-пакеты по 5 векторов в каждом. Предварительное обучение каждого слоя с помощью автоассоциатора производилось в течение 15 эпох. Окончательное обучение нейронной сети также продолжалось в течение 15 эпох.

Рекуррентные соединения добавлялись к последнему из слоёв, обучаемых при помощи автоассоциаторов. При окончательном обучении рекуррентных вариантов сети сохранялась исходная последовательность обучающих векторов. При предварительном обучении слоёв и при окончательном обучении нерекуррентных вариантов обучающие векторы перемешивались в случайном порядке.

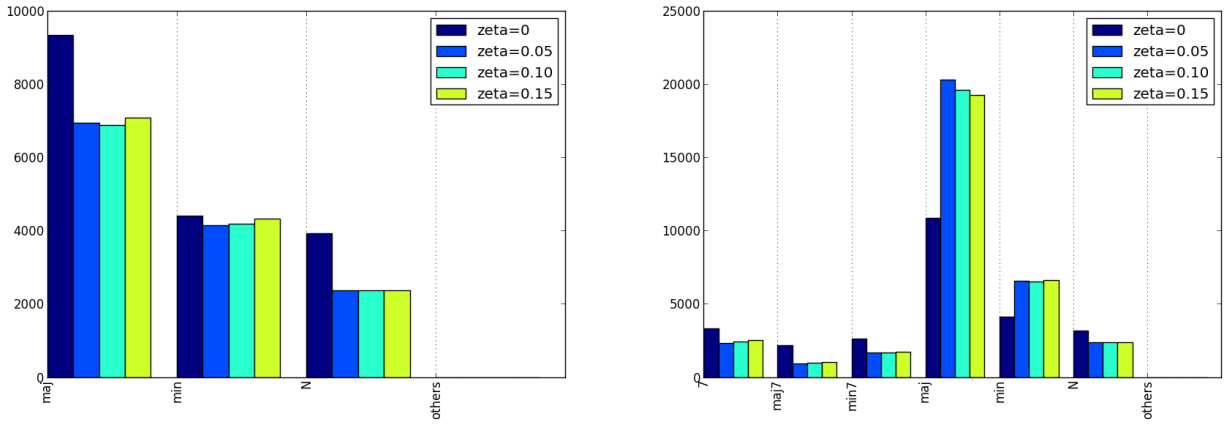

а) б)

Рисунок 5.12: Диаграмма ошибок для разных значений ζ

Для проведения экспериментов тестовая коллекция из 318 композиций была случайным образом поделена на 2 равные части, каждая из которых поочередно выступала в качестве обучающей и тестовой выборки.

5.4.1 Конфигурация нейронной сети

Были рассмотрены различные варианты нерекуррентных сетей (SDA) с 48 и с 60 входами (охватывающие, соответственно, 4 или 5 октав звукозаписи), имеющие 1, 2 или 3 скрытых слоя с разными количествами нейронов. Для всех сетей были рассмотрены также соответствующие рекуррентные варианты (RSDA). Соответствующие результаты приведены в таблице 5.11. В названии конфигурации первое число в скобках соответствует количеству входов, остальные – количеству нейронов в скрытых слоях.

В предыдущей публикации XXX было замечено, что качество распознавания аккордов растёт с ростом количества нейронов в сети. Поэтому в экспериментах было решено использовать слои, состоящие из достаточно большого количества нейронов.

Таблица 5.11: Влияние конфигурации нейронной сети на качество распознавания аккордов

Конфигурация	Triads	Tetrads	Сегментация
SDA (48, 200)	0.7639	0.6234	0.8035
SDA (48, 200, 200)	0.7616	0.6316	0.8009
SDA (60, 300)	0.7649	0.6322	0.8011
SDA (60, 300, 300)	0.7655	0.6364	0.8006
SDA (60, 300, 300, 300)	0.7674	0.6373	0.8011
RSDA (48, 200)	0.7616	0.6226	0.7963
RSDA (48, 200, 200)	0.7660	0.6342	0.7982
RSDA (60, 300)	0.7613	0.6298	0.7955
RSDA (60, 300, 300)	0.7672	0.6373	0.7982
RSDA (60, 300, 300, 300)	0.7686	0.6360	0.7986

По итогам экспериментов не выявлено существенных различий в качестве распознавания аккордов между разными конфигурациями нейронной сети. Полученные результаты достаточно близки, и лишь в нескольких парах есть статистически значимые различия. При этом обучение нейронных сетей с рекуррентым слоем и последующее их тестирование отнимает

значительно больше времени, чем для сетей без рекуррентного слоя. Количество нейронов во входном слое несущественно влияет на время работы, но большее их количество приводит к чуть лучшему результату. С учётом высказанных соображений, в дальнейших экспериментах было решено использовать конфигурацию SDA (60, 300).

В экспериментах предварительно вычисленные спектрограммы звукозаписей по столбцам подавались на вход нейронной сети. Описанные в параграфах 3.2 и 3.3 преобразования к спектрограмме не применялись, за исключением взятия логарифма от её компонент. Однако матрица самоподобия использовалась для сглаживания последовательности хроматических векторов, полученных на выходе нейронной сети. При определении последовательности аккордов использовались эвристики, описанные в параграфе 3.4.

Без предварительного логарифмирования спектрограммы в конфигурации SDA (60, 300, 300) были получены следующие результаты: Triads – 0.7346, Tetrads – 0.6050, Segmentation – 0.7882.

TODO Для описанного в главе 4 метода получения векторов признаков с использованием нейронных сетей важными являются следующие вопросы:

1. каковы оптимальные значения для уровней шума при обучении очищающих автоассоциаторов;

2. и др.

5.5 Классификация векторов признаков

Для определения последовательности аккордов по полученной последовательности хроматических векторов используется простой метод ближайшего соседа. Для этого строятся шаблонные хроматческие векторы для всех аккордов из множества распознаваемых аккордов Y. При построении шаблонов используются 2 параметра: количество учитываемых обертонов и вклад h этих обертонов в шаблон (в соответствии с формулой (2.2)). Затем для каждого вектора из последовательности определяются расстояния от него до всех шаблонных векторов. Необходимо рассмотреть разные способы определения расстояния.

5.5.1 Шаблонные векторы

Поскольку первый обертон любой ступени звукоряда соответствует звуку с таким же названием, нет смысла рассматривать отдельно случай шаблонов без обертонов. Но, учитывая экспоненциальный характер убывания вклада каждого последующего обертона в шаблоны, имеет смысл рассматривать достаточно небольшое их количество. В [34] авторы ограничиваются первыми пятью обертонами. В соответствии с формулой (2.2)) при $h = 0.6$ вклад пятого обертона будет составлять $0.6^5 \approx 0.078$ от вклада первого, то есть более чем в 12 раз слабее. Поэтому вряд ли имеет смысл рассматривать большее их количество.

Таблица 5.12: Влияние количества обертонов в шаблонах на качество распознавания аккордов

Количество обертонов	Triads	Tetrads	Сегментация
1	0.7516	0.1586	0.8064
2	0.7720	0.4310	0.8141
3	0.7706	0.3611	0.8139
4	0.7680	0.5713	0.8134
5	0.7703	0.6173	0.8137

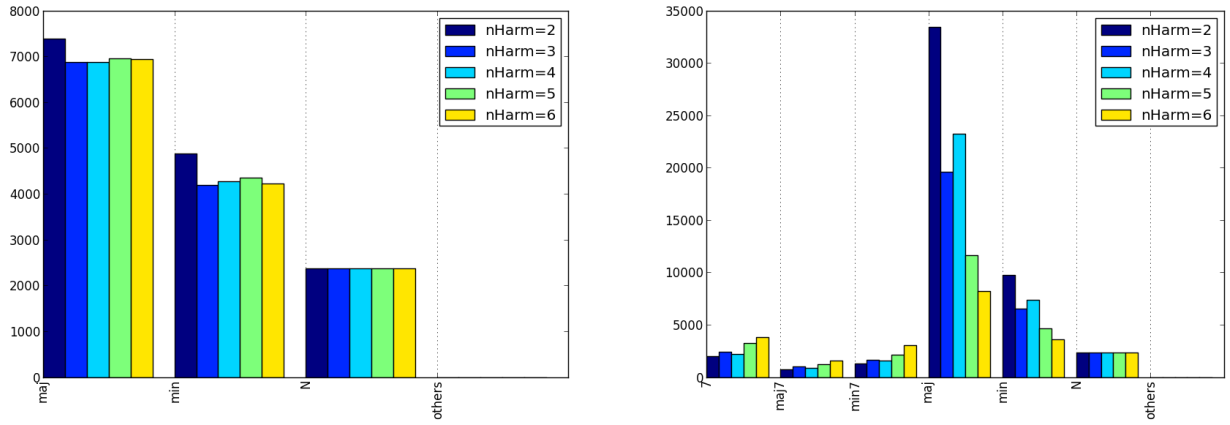

а) б)

Рисунок 5.13: Диаграмма ошибок при разных количествах обертонов в шаблонах

В таблице 5.12 показаны результаты экспериментов в зависимости от количества учитываемых в шаблонах обертонов. Различия между 2 и 3 обертонами, а также между 3, 4 и 5 обертонами, не являются статистически значимыми, но максимум наблюдается при использовании в шаблонах 2 обертонов дополнительно к основному тону.

Коэффициент h убывания вклада обертонов в [51] и [34] выбирается равным 0.6, его влияние в этих работах не исследуется. В таблице 5.13 приведены значения взвешенного среднего перекрытия и сегментации, полученные автором для разных значений h. Для случаев $h = 0.5$, $h = 0.6$, $h = 0.7$ статистически значимые различия не обнаружены, но их отличия от вариантов $h = 0.4$, $h = 0.8$ являются статистически значимыми. В целом, влияние данного параметра достаточно слабое.

Таблица 5.13: Влияние коэффициента убывания вклада обертона на качество распознавания аккордов

h	Triads	Tetrads	Сегментация
0.4	0.7660	0.2038	0.8121
0.5	0.7694	0.2881	0.8135
0.6	0.7720	0.4310	0.8141
0.7	0.7733	0.5749	0.8133
0.8	0.7708	0.6216	0.8114

Примечательно (см. рисунки 5.14, 5.13), что параметры шаблонов не оказывают почти никакого влияния в случае распознавания только мажорных и минорных трезвучий, но сильно влияют на результат при распознавании септаккордов. Это можно объяснить тем, что получаемые в реальности 12-мерные тональные векторы не являются бинарными. Определённое количество звуковой энергии приходится на все их компоненты. А поскольку шаблоны для септаккордов учитывают гармоники 4 тональных классов, почти все их компоненты оказываются ненулевыми. За счёт этого расстояние от таких шаблонов до полученных тональных векторов оказывается меньше, и септаккорд определяется там, где на самом деле звучит мажорное или минорное трезвучие. Для частичной компенсации этого эффекта количество гармоник в шаблонах для септаккордов было ограничено двумя. С увеличением же количества гармоник и вклада каждой из последующих гармоник энергия в шаблонах для трезвучий распределяется более равномерно. В результате эти шаблоны оказываются более подходящими для отделения трезвучий от септаккордов.

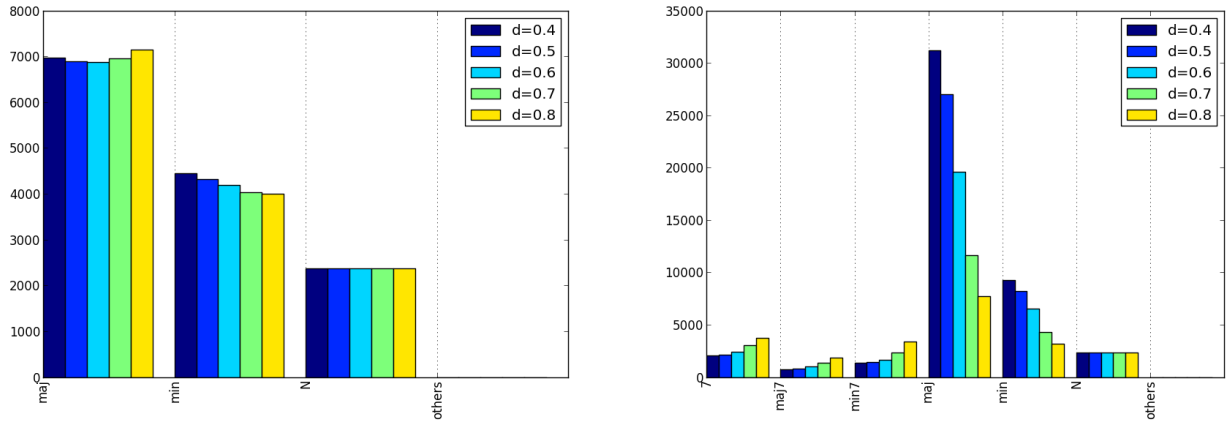

а) б)

Рисунок 5.14: Диаграмма ошибок для разных значений h

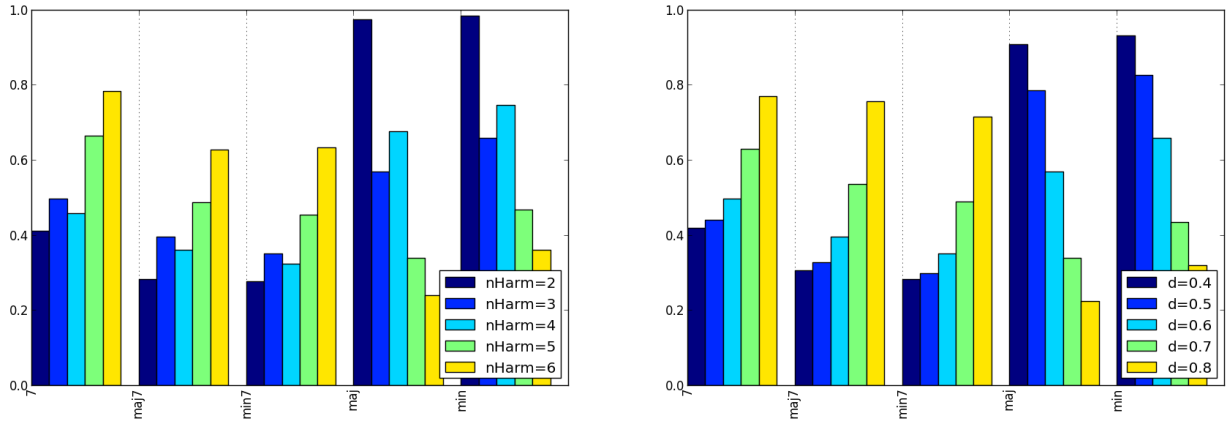

а) б)

Рисунок 5.15: Нормализованная диаграмма ошибок для разных значений количества обертонов и параметра h

Вспомним, что в совокупности все фрагменты, на которых звучат септаккорды, составляют лишь чуть более 20% от длительности тестовой коллекции (см. таблицу 5.1). Поэтому падение количества ошибок на септаккордах может оказаться менее важным, чем рост количества ошибок на мажорных и минорных трезвучиях. На рисунке 5.15 высота столбцов соответствует доле фрагментов с аккордами каждого из типов, на которых была сделана ошибка распознавания. Видно, что в действительности уменьшение количества ошибок распознавания трезвучий компенсируется ростом количества ошибок распознавания септаккордов. Но из-за существенно меньшей доли фрагментов с септаккордами в коллекции значение метрики “Tetrads” растёт. Нельзя говорить, однако, что при больших значениях параметра h или количества гармоник в шаблонах алгоритм лучше распознаёт септаккорды.

5.5.2 Эвристики

Изменения результата при использовании предложенных эвристик показаны в таблице 5.14. Как видно, исправление типа аккорда оказывается, фактически, бесполезным. Однако исправление аккордов, которые продолжаются в течение только одной метрической доли, имеет заметный эффект и даёт статистически значимое улучшение качества распознавания аккордов.

Таблица 5.14: Влияние эвристик на качество распознавания аккордов

Эвристики	Triads	Tetrads	Сегментация
Без эвристик	0.7634	0.4341	0.8083
Исправление одиночных аккордов	0.7721	0.4393	0.8164
Исправление типа аккорда	0.7655	0.4270	0.8141
Обе эвристики	0.7720	0.4310	0.8141

5.6 Результаты соревнования MIREX Audio Chord Estimation 2013

Реализованный в рамках данной работы алгоритм был выставлен на ежегодное соревнование среди систем распознавания аккордов *MIREX Audio Chord Estimation 2013* [96], [97], [98]. Диаграммы результатов представлены на рисунках 5.16, 5.17 и 5.18.

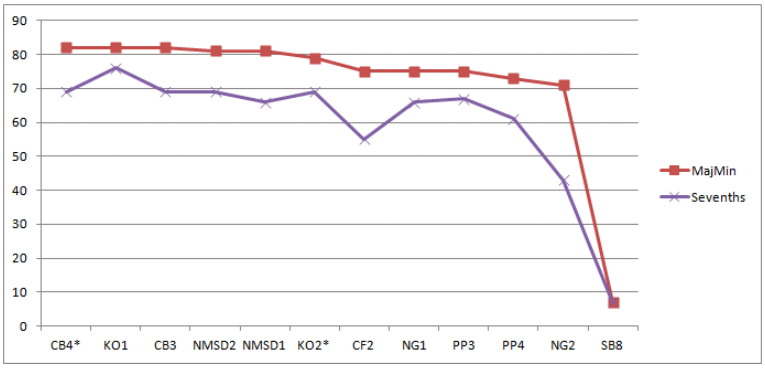

Рисунок 5.16: Результаты MIREX ACE 2013 на коллекции Mirex2009

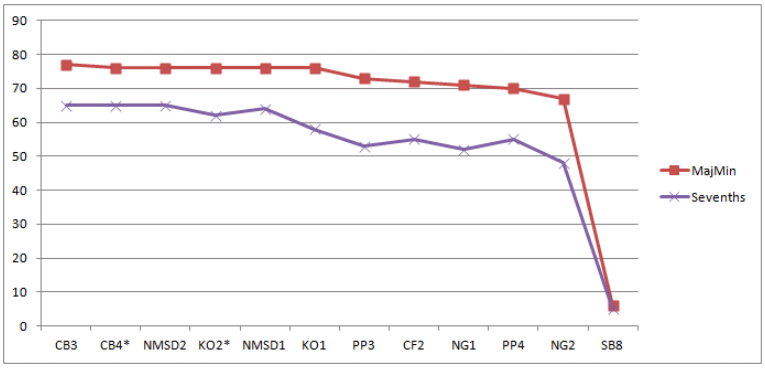

Рисунок 5.17: Результаты MIREX ACE 2013 на коллекции Billboard2012

Как видно, описанный в главе 3 метод показывает сравнимые с другими участниками результаты. При этом все остальные алгоритмы используют методы машинного обучения. Версия алгоритма под названием NG2 отличается от NG1 только тем, что содержит шаблоны для мажорного и минорного септаккордов, а также для доминантсептаккорда. За счёт ошибочного определения септаккордов вместо обычных мажорного или минорного аккорда версия NG2 показала более слабый результат.

Можно заметить, что все алгоритмы показывают более слабый результат на коллекциях *Billboard 2012* и *Billboard2013*, недоступных для участников, чем на широко используемой много лет подряд коллекции *Isophonics*. В случае, когда от алгоритмов требуется распознавать септаккорды, результаты также падают. Интересно, что даже наилучшие из алгоритмов незначительно превышают значение 0.8 для взвешенного среднего перекрытия, и до сих пор никому

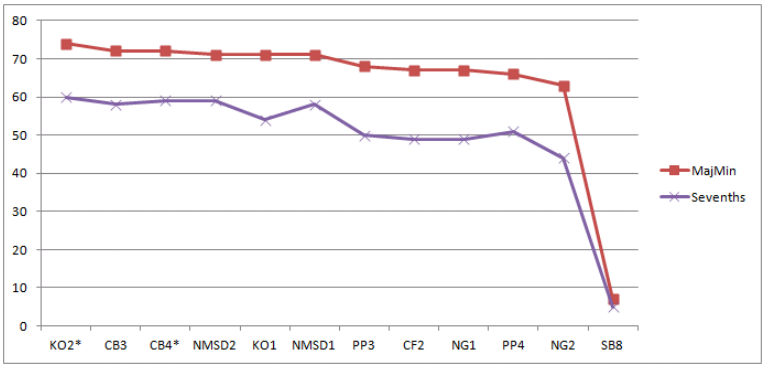

Рисунок 5.18: Результаты MIREX ACE 2013 на коллекции Billboard2013

не удалось добиться существенного прогресса в качестве распознавания. Исключением являются случаи переобучения (пример приведен в [82], когда алгоритм обучается и тестируется на одной и той же коллекции. Очевидно, что в данном случае сравнение с результатами, полученными при обучении и тестировании на разных коллекциях, некорректны.

5.7 Быстродействие

Метод должен обладать достаточным быстродействием для того, чтобы его использование для решения реальных задач было целесообразным. В данном разделе анализируется производительность реализованного метода в зависимости от значений параметров.

Весь процесс обработки звукового файла можно разделить на 4 стадии:

1. определение частоты настройки музыкальных инструментов;
2. определение ритма при помощи внешней библиотеки;
3. вычисление спектрограммы;
4. преобразования спектрограммы и распознавание аккордов.

Процесс распознавания аккордов при наличии последовательности хроматических векторов отнимает очень небольшое время, и поэтому не был выделен в отдельную стадию. Однако вычисление преобразований спектрограммы уже отнимает заметное время. При использовании нейронной сети все дополнительные затраты времени на её обучение также могут быть отнесены к этой стадии.

На быстродействие алгоритма определения ритма автор повлиять не может. Длительность остальных стадий обработки файла зависит от параметров метода. Наибольшее влияние оказывают количество компонент преобразования постоянного качества (количество октав и количество компонент на октаву N_0) и коэффициент T, соответствующий количеству вычислений спектра звука, приходящихся на одну метрическую долю. Именно эти параметры задают количество преобразований постоянного качества, которые необходимо вычислить для получения спектрограммы звукозаписи, и количество участвующих в каждом преобразовании значений.

Полностью процесс распознавания аккордов в используемой коллекции из 318 композиций общей длительностью около 17 ч 8 мин отнимает примерно 4 ч 15 мин при следующих условиях:

- компьютер с процессором Intel Core i5 с тактовой частотой 2.8 ГГц;
- вычисления в 3 потока;

- $N_0 = 36$, охват 6 октав, начиная со звука *до* большой октавы (65.4 Гц);
- $T = 8$.

Взвешенное среднее перекрытие и сегментация для каждой композиции из используемой коллекции представлены в приложении А.

При тех же условиях (но с использованием 4 потоков) только наиболее продолжительные действия – определение частоты настройки и получение спектрограммы (при известных моментах начала метрических долей и без дополнительных преобразований) – занимают примерно 3 ч 40 мин. В таблице 5.15 показано время выполнения этих же действий при разных значениях N_0. При использовании $N_0 = 60$, несмотря на большее время работы, прирост качества распознавания аккордов практически не заметен (см. таблицу 5.6). При $N_0 = 12$ выигрыш во времени невелик, при этом ухудшение результата очень заметно.

Таблица 5.15: Совокупная продолжительность определения частоты настройки и вычисления спектрограммы

N_0	Время
12	2 ч 59 мин 2 с
36	3 ч 37 мин 47 с
60	4 ч 23 мин 27 с

Время, затрачиваемое на обучение нейронной сети, оказывается на практике достаточно заметным. Однако, как видно из таблицы 5.16, добавление каждого нового слоя существенно увеличивает время обучения при незначительном улучшении результата (см. таблицу 5.11). Добавление рекуррентных соединений резко увеличивает время обучения по сравнению с аналогичной нерекуррентной сетью. Кроме того, из-за наличия зависимости от значений предыдущего шага не удаётся эффективно вычислять выходные значения во время тестов, из-за чего продолжительность тестов также резко возрастает.

Таблица 5.16: Совокупная продолжительность обучения и тестов при разных конфигурациях нейронной сети

Конфигурация	Продолжительность обучения	Продолжительность тестов
SDA (60, 300)	1 ч 20 мин 48 с	5 мин 17 с
SDA (60, 300, 300)	6 ч 21 мин 28 с	8 мин 18 с
SDA (60, 300, 300, 300)	15 ч 21 мин 19 с	13 мин 21 с
RSDA (60, 300)	6 ч 55 мин 43 с	1 ч 52 мин 01

TODO влияние параметра T на время обработки.

5.8 Выводы

1. Произведён анализ влияния параметров реализованного метода на качество распознавания аккордов и скорость работы метода. Определена степень влияния каждого из параметров на качество распознавания аккордов.

2. Определены параметры, наиболее сильно влияющие на быстродействие метода; показано, что можно добиться прироста скорости при незначительном снижении качества распознавания.

3. Реализованный алгоритм показал хороший результат в международном соревновании среди алгоритмов распознавания аккордов *MIREX Audio Chord Estimation 2013*.

4. Произведён анализ ошибок метода и предложены возможные пути для их устранения.

Заключение

Основные результаты работы заключаются в следующем.

1. На основе анализа свойств музыкальных звукозаписей был разработан метод для более точного выделения в звуке компонент, соответствующих музыкальным инструментам.

2. Исследование показало, что глубокие нейронные сети в применении к получению музыкальных признаков могут показывать хорошие результаты, сравнимые с результатами традиционных подходов к получению признаков.

3. Численные исследования показали, что реализованные в рамках работы подходы позволяют добиться качества распознавания аккордов, сравнимого с лучшими из известных алгоритмов, при достаточно высокой скорости обработки.

4. Для выполнения поставленных задач был создан программный комплекс на языках Java и Python, свободно доступный через интернет.

В нынешних условиях любые методы обработки информации должны быть нацелены на работу с очень большими её объёмами. Вероятно, именно чрезмерное количество времени, необходимое для анализа миллионов композиций, препятствует широкому применению методов распознавания аккордов. С другой стороны, малый объем размеченных и доступных для обучения данных затрудняет широкое применение методов, основанных на алгоритмах машинного обучения. Именно поэтому, как представляется автору, разработка достаточно быстрого метода распознавания аккордов, не использующего машинное обучение, является важным шагом на пути к обработке больших музыкальных коллекций.

Список рисунков

Список таблиц

Литература

1. Schüler Nico. Reflections on the history of computer-assisted music analysis I: predecessors and the beginnings. // Muzikoloski zbornik. 2005. T. 41. C. 31–43. URL: http://uweb.txstate.edu/ ns13/Schuler-CAMA-I.pdf.
2. Freedman M. David. Analysis of Musical Instrument Tones // The Journal of the Acoustical Society of America. 1967. T. 41, № 4A. C. 793–806. URL: http://link.aip.org/link/?JAS/41/793/1.
3. Moorer James A. On the Segmentation and Analysis of Continuous Musical Sound by Digital Computer: Master's thesis: Stanford University. Stanford, CA, 1975. URL: https://ccrma.stanford.edu/files/papers/stanm3.pdf.
4. Martin Keith D. Automatic Transcription of Simple Polyphonic Music: Robust Front End Processing. 1996.
5. Fujishima Takuya. Realtime Chord Recognition of Musical Sound: a System Using Common Lisp Music // Proc. ICMC, 1999. 1999. C. 464–467. URL: http://ci.nii.ac.jp/naid/10013545881/en/.
6. Aono Y., Katayose H., Inokuchi S. A Real-time Session Composer with Acoustic Polyphonic Instruments // Proceedings of ICMC 1998. 1998. C. 236–239.
7. MIREX Home Page. 2013. September. URL: http://www.music-ir.org/mirex/wiki/MIREX_HOME/.
8. Ableton Live 9. 2013. September. URL: https://www.ableton.com/en/live/.
9. AnySong Chord Recognition. 2013. September. URL: https://play.google.com/store/apps/details?id=com.musprojects.chord.
10. Chord Detector. 2013. September. URL: http://www.chord-detector.com/wordpress/apps/chorddetector/.
11. Chordify. 2013. September. URL: http://chordify.net/.
12. Humphrey E.J., Cho T., Bello J.P. Learning a robust tonnetz-space transform for automatic chord recognition // Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP-12). Kyoto, Japan: 2012. May. C. 453–456.
13. De Haas W. Bas, Magalhães José Pedro, Wiering Frans. Improving Audio Chord Transcription by Exploiting Harmonic and Metric Knowledge // Proceedings of the 13th International Society for Music Information Retrieval Conference. Porto, Portugal: 2012. October 8-12. http://ismir2012.ismir.net/event/papers/295-ismir-2012.pdf.
14. MIREX 2012: Audio Chord Description - MIREX09 Dataset. 2013. November. URL: http://nema.lis.illinois.edu/nema_out/mirex2012/results/ace/mrx/.

15. MIREX 2012: Audio Chord Description - McGill Dataset. 2013. November. URL: http://nema.lis.illinois.edu/nema_out/mirex2012/results/ace/mcg/.

16. Большая советская энциклопедия. / под ред. А. М. Прохоров. 3-е изд. М.: Советская энциклопедия, 1972. Т. 9.

17. Вахромеев В. А. Элементарная теория музыки / под ред. К. Соловьева. Москва "Государственное музыкальное издательство 1961.

18. Lerch Alexander. Audio content analysis: an introduction. John Wiley & Sons, Inc., Hoboken, New Jersey, 2012.

19. И. А. Алдошина Р. Приттс. Музыкальная акустика / под ред. Т. И. Кий. Санкт-Петербург "Композитор 2006.

20. Hugo Fastl Eberhard Zwicker. Psychoacoustics - Facts and Models / под ред. Manfred R. Schroeder Thomas S. Huang, Teuvo Kohonen. Springer-Verlag Berlin Heidelberg, 2007.

21. Способин И. В. Элементарная теория музыки / под ред. В. Григоренко. Москва "КИФА-РА 2012.

22. Levitin Daniel J. This is Your Brain on Music: Understanding a Human Obsession. Atlantic Books Ltd., 2006.

23. MIDI Specifications. 2013. September. URL: http://www.midi.org/techspecs/.

24. MIDI Tuning Messages. 2013. September. URL: http://www.midi.org/techspecs/midituning.php/.

25. Sheh Alexander, Ellis Daniel P. W. Chord segmentation and recognition using EM-trained hidden markov models. // ISMIR. 2003.

26. Bello Juan Pablo, Pickens Jeremy. A Robust Mid-Level Representation for Harmonic Content in Music Signals // Proceedings of the 6th International Conference on Music Information Retrieval. London, UK: 2005. September 11-15. С. 304–311. http://ismir2005.ismir.net/proceedings/1038.pdf.

27. Lee K. Automatic chord recognition from audio using enhanced pitch class profile // ICMC Proceedings. 2006.

28. A Cross-Validated Study of Modelling Strategies for Automatic Chord Recognition in Audio / John Ashley Burgoyne, Laurent Pugin, Corey Kereliuk [и др.] // Proceedings of the 8th International Conference on Music Information Retrieval. Vienna, Austria: 2007. September 23-27. С. 251–254. http://ismir2007.ismir.net/proceedings/ISMIR2007_p251_burgoyne.pdf.

29. Lee Kyogu, Slaney Malcolm. A Unified System for Chord Transcription and Key Extraction Using Hidden Markov Models // Proceedings of the 8th International Conference on Music Information Retrieval. Vienna, Austria: 2007. September 23-27. С. 245–250. http://ismir2007.ismir.net/proceedings/ISMIR2007_p245_lee.pdf.

30. Papadopoulos Hélène, Peeters Geoffroy. Large-Scale Study of Chord Estimation Algorithms Based on Chroma Representation and HMM // CBMI / под ред. Jenny Benois-Pineau. IEEE, 2007. С. 53–60.

31. Mauch Matthias, Dixon Simon. A Discrete Mixture Model for Chord Labelling // Proceedings of the 9th International Conference on Music Information Retrieval. Philadelphia, USA: 2008. September 14-18. С. 45–50. http://ismir2008.ismir.net/papers/ISMIR2008_214.pdf.

32. Khadkevich Maksim, Omologo Maurizio. Use of Hidden Markov Models and Factored Language Models for Automatic Chord Recognition // Proceedings of the 10th International Society for Music Information Retrieval Conference. Kobe, Japan: 2009. October 26-30. С. 561–566. http://ismir2009.ismir.net/proceedings/OS7-4.pdf.

33. Mauch Matthias, Noland Katy, Dixon Simon. Using Musical Structure to Enhance Automatic Chord Transcription // Proceedings of the 10th International Society for Music Information Retrieval Conference. Kobe, Japan: 2009. October 26-30. С. 231–236. http://ismir2009.ismir.net/proceedings/PS2-7.pdf.

34. Oudre Laurent, Grenier Yves, Févotte Cédric. Template-Based Chord Recognition : Influence of the Chord Types // Proceedings of the 10th International Society for Music Information Retrieval Conference. Kobe, Japan: 2009. October 26-30. С. 153–158. http://ismir2009.ismir.net/proceedings/PS1-17.pdf.

35. Minimum Classification Error Training to Improve Isolated Chord Recognition / Jeremy Reed, Yushi Ueda, Sabato Siniscalchi [и др.] // Proceedings of the 10th International Society for Music Information Retrieval Conference. Kobe, Japan: 2009. October 26-30. С. 609–614. http://ismir2009.ismir.net/proceedings/PS4-6.pdf.

36. Mauch Matthias, Dixon Simon. Approximate Note Transcription for the Improved Identification of Difficult Chords // Proceedings of the 11th International Society for Music Information Retrieval Conference. Utrecht, The Netherlands: 2010. August 9-13. С. 135–140. http://ismir2010.ismir.net/proceedings/ismir2010-25.pdf.

37. Khadkevich Maksim, Omologo Maurizio. Time-frequency reassigned features for automatic chord recognition // Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing, ICASSP 2011, May 22-27, 2011, Prague Congress Center, Prague, Czech Republic. IEEE, 2011. С. 181–184.

38. Harmony Progression Analyzer for MIREX 2011 / Yizhao Ni, Matt Mcvicar, Raul Santos-Rodriguez [и др.]. 2012.

39. Zhang Xinglin, Gerhard David. Chord Recognition using Instrument Voicing Constraints // Proceedings of the 9th International Conference on Music Information Retrieval. Philadelphia, USA: 2008. September 14-18. С. 33–38. http://ismir2008.ismir.net/papers/ISMIR2008_241.pdf.

40. Cho T., Weiss R.J., Bello J.P. Exploring common variations in state of the art chord recognition systems // Proceedings of the Sound and Music Computing Conference (SMC). Barcelona, Spain: 2010. July. С. 1–8.

41. Concurrent Estimation of Chords and Keys from Audio / Thomas Rocher, Matthias Robine, Pierre Hanna [и др.] // Proceedings of the 11th International Society for Music Information Retrieval Conference. Utrecht, The Netherlands: 2010. August 9-13. С. 141–146. http://ismir2010.ismir.net/proceedings/ismir2010-26.pdf.

42. Cho Taemin, Bello Juan P. A Feature Smoothing Method for Chord Recognition Using Recurrence Plots // Proceedings of the 12th International Society for Music Information Retrieval Conference. Miami (Florida), USA: 2011. October 24-28. С. 651–656. http://ismir2011.ismir.net/papers/OS8-4.pdf.

43. Automatic Chord Transcription with Concurrent Recognition of Chord Symbols and Boundaries / Takuya Yoshioka, Tetsuro Kitahara, Kazunori Komatani [и др.] // Proceedings of the 5th International Conference on Music Information Retrieval. Barcelona, Spain: 2004. October 10-14. http://ismir2004.ismir.net/proceedings/p020-page-100-paper149.pdf.

44. Automatic Chord Recognition Based on Probabilistic Integration of Chord Transition and Bass Pitch Estimation / Kouhei Sumi, Katsutoshi Itoyama, Kazuyoshi Yoshii [и др.] // Proceedings of the 9th International Conference on Music Information Retrieval. Philadelphia, USA: 2008. September 14-18. С. 39–44. http://ismir2008.ismir.net/papers/ISMIR2008_236.pdf.

45. Weller Adrian, Ellis Daniel, Jebara Tony. Structured Prediction Models for Chord Transcription of Music Audio // Proceedings of the 2009 International Conference on Machine Learning and Applications. ICMLA '09. Washington, DC, USA: IEEE Computer Society, 2009. С. 590–595. URL: http://dx.doi.org/10.1109/ICMLA.2009.132.

46. Leveraging Noisy Online Databases for Use in Chord Recognition / Matt Mcvicar, Yizhao Ni, Raul Santos-Rodriguez [и др.] // Proceedings of the 12th International Society for Music Information Retrieval Conference. Miami (Florida), USA: 2011. October 24-28. С. 639–644. http://ismir2011.ismir.net/papers/OS8-2.pdf.

47. Chord Recognition Using Duration-explicit Hidden Markov Models / Ruofeng Chen, Weibin Shen, Ajay Srinivasamurthy [и др.] // Proceedings of the 13th International Society for Music Information Retrieval Conference. Porto, Portugal: 2012. October 8-12. http://ismir2012.ismir.net/event/papers/445-ismir-2012.pdf.

48. Davies Matthew E. P., Plumbley Mark D. Context-Dependent Beat Tracking of Musical Audio // Trans. Audio, Speech and Lang. Proc. Piscataway, NJ, USA, 2007. March. Т. 15, № 3. С. 1009–1020. URL: http://dx.doi.org/10.1109/TASL.2006.885257.

49. Dixon Simon. Evaluation of the Audio Beat Tracking System BeatRoot // Journal of New Music Research. 2007. March. Т. 36, № 1. С. 39–50. URL: http://dx.doi.org/10.1080/09298210701653310.

50. Ellis Daniel P. W. Beat tracking by dynamic programming // Journal of New Music Research. 2007. Т. 36(1). С. 51–60.

51. Gómez E. Tonal Description of Music Audio Signals. Ph.D. thesis: Universitat Pompeu Fabra. 2006. URL: files/publications/emilia-PhD-2006.pdf.

52. Analyzing Chroma Feature Types for Automated Chord Recognition / Nanzhu Jiang, Peter Grosche, Verena Konz [и др.] // Proceedings of the AES 42nd International Conference: Semantic Audio. Ilmenau, Germany: AES, 2011. С. 285–294.

53. Harte C. A., Sandler M. Automatic chord identification using a quantised chromagram // Proc. of the 118th Convention. of the AES. 2005.

54. Zhu Yongwei, Kankanhalli Mohan S., Gao Sheng. Music Key Detection for Musical Audio // Multi-Media Modeling Conference, International. Los Alamitos, CA, USA, 2005. Т. 0. С. 30–37.

55. Peeters Geoffroy. Musical key estimation of audio signal based on hidden Markov modeling of chroma vectors // Proc. of the Int. Conf. on Digital Audio Effects (DAFx-06. 2006. С. 127–131.

56. Khadkevich Maksim, Omologo Maurizio. Phase-change based tuning for automatic chord recognition. // Proceedings of the 12th International Conference on Digital Audio Effects of DAFX. Como, Italy: 2009. September 1-4.

57. Separation of a Monaural Audio Signal into Harmonic/Percussive Components by Complementary Diffusion on Spectrogram / Nobutaka Ono, Ken-Ichi Miyamoto, Jonathan Le Roux [и др.] // Proceedings of the EUSIPCO 2008 European Signal Processing Conference. 2008. August.

58. А. Оппенгейм Р. Шафер. Цифровая обработка сигналов / под ред. О. Н. Кулешова. Москва "Техносфера 2006.

59. Brown Judith, Puckette Miller S. An efficient algorithm for the calculation of a constant Q transform // Journal of the Acoustical Society of America. 1992. November. Т. 92, № 5. С. 2698–2701.

60. Л. Рабинер Б. Гоулд. Теория и применение цифровой обработки сигналов / под ред. Л. Якименко. Москва "МИР 1978.

61. Kodera K., Gendrin R., Villedary C. Analysis of time-varying signals with small BT values // Acoustics, Speech and Signal Processing, IEEE Transactions on. 1978. Т. 26, № 1. С. 64–76.

62. Fletcher Harvey, Munson W. A. Loudness, Its Definition, Measurement and Calculation // The Journal of the Acoustical Society of America. 1933. October. Т. 5, № 2. С. 82–108.

63. Müller Meinard, Ewert Sebastian, Kreuzer Sebastian. Making chroma features more robust to timbre changes // Proceedings of the 2009 IEEE International Conference on Acoustics, Speech and Signal Processing. ICASSP '09. Washington, DC, USA: IEEE Computer Society, 2009. С. 1877–1880. URL: http://dx.doi.org/10.1109/ICASSP.2009.4959974.

64. Logan Beth. Mel Frequency Cepstral Coefficients for Music Modeling // Proceedings of the 1st International Conference on Music Information Retrieval. Plymouth (Massachusetts), USA: 2000. October 23. http://ismir2000.ismir.net/papers/logan_paper.pdf.

65. Talbot-Smith Michael. Audio Engineer's Reference Book. Taylor & Francis, 1999. URL: http://books.google.ru/books?id=LcySXZbdamEC.

66. Müller Meinard. Information retrieval for music and motion. Springer-Verlag Berlin Heidelberg, 2007.

67. Harte Christopher, Sandler Mark, Gasser Martin. Detecting harmonic change in musical audio // Proceedings of the 1st ACM workshop on Audio and music computing multimedia. AMCMM '06. New York, NY, USA: ACM, 2006. С. 21–26. URL: http://doi.acm.org/10.1145/1178723.1178727.

68. vv ll jj ffIntroduction to Neo-Riemannian Theory: A Survey and a Historical Perspective // Journal of Music Theory. 1998. Vol. 42, no. 2. P. pp. 167–180. URL: http://www.jstor.org/stable/843871.

69. Chew Elaine. Towards a Mathematical Model of Tonality. Ph.D. thesis: Massachusetts Institute of Technology. 2000. Feb. URL: http://www-bcf.usc.edu/˜echew/papers/Dissertation2000/ec-dissertation.pdf.

70. Lee Kyogu. A System for Automatic Chord Transcription from Audio Using Genre-Specific Hidden Markov Models // Adaptive Multimedial Retrieval: Retrieval, User, and Semantics / под ред. Nozha Boujemaa, Marcin Detyniecki, Andreas NГjrnberger. Springer Berlin Heidelberg, 2008. Т. 4918 из *Lecture Notes in Computer Science*. С. 134–146.

71. Gradient-based learning applied to document recognition / Y. LeCun, L. Bottou, Y. Bengio [и др.] // Proceedings of the IEEE. Nov. Т. 86, № 11. С. 2278–2324.

72. Using Hyper-genre Training to Explore Genre Information for Automatic Chord Estimation / Yizhao Ni, Matt Mcvicar, Raul Santos-Rodriguez [и др.] // Proceedings of the 13th International Society for Music Information Retrieval Conference. Porto, Portugal: 2012. October 8-12. http://ismir2012.ismir.net/event/papers/109-ismir-2012.pdf.

73. И. Рабинер. Скрытые марковские модели и их применение в избранных приложениях при распознавании речи: Обзор // ТИИЭР. 1989. Т. 77, № 2.

74. Ghahramani Zoubin. An Introduction to Hidden Markov Models and Bayesian Networks // IJPRAI. 2001. Т. 15, № 1. С. 9–42.

75. Lafferty John D., McCallum Andrew, Pereira Fernando C. N. Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data // Proceedings of the Eighteenth International Conference on Machine Learning. ICML '01. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2001. С. 282–289. URL: http://dl.acm.org/citation.cfm?id=645530.655813.

76. Temperley D. The cognition of basic musical structures. Mit Press, 2001.

77. Lerdahl F. Tonal Pitch Space. Oxford University Press, USA, 2001.

78. Lerch Alexander. On the Requirement of Automatic Tuning Frequency Estimation // International Symposium/Conference on Music Information Retrieval. 2006. С. 212–215.

79. Fitzgerald D. Harmonic/Percussive Separation using Median Filtering // Audio. 2010. № 1. С. 10–13. URL: http://arrow.dit.ie/argart/9/.

80. Glazyrin N., Klepinin A. Chord Recognition using Prewitt Filter and Self-Similarity // Proceedings of the 9th Sound and Music Computing Conference. Copenhagen, Denmark: 2012. July. С. 480–485.

81. Maas A. Le Q. O'Neil T. Vinyals O. Nguyen P. Ng A. Recurrent Neural Networks for Noise Reduction in Robust ASR // Proceedings of INTERSPEECH (2012). 2012.

82. Boulanger-Lewandowski Nicolas, Bengio Yoshua, Vincent Pascal. Audio chord recognition with recurrent neural networks // Proceedings of the 14th International Society for Music Information Retrieval Conference. 2013. November 4-8. http://www.ppgia.pucpr.br/ismir2013/wp-content/uploads/2013/09/243_Paper.pdf.

83. P. Vincent H. Larochelle I. Lajoie Y. Bengio, Manzagol P.-A. Stacked Denoising Autoencoders: Learning Useful Representations in a Deep Network with a Local Denoising Criterion // The Journal of Machine Learning Research. 2010. Т. 11. С. 3371–3408.

84. Ng Andrew. CS294A Lecture Notes. Sparse autoencoder. URL: http://www.stanford.edu/class/cs294a/sparseAutoencoder.pdf.

85. Elman Jeffrey L. Finding structure in time // Cognitive Science. 1990. Т. 14, № 2. С. 179–211. URL: http://groups.lis.illinois.edu/amag/langev/paper/elman90findingStructure.html.

86. OMRAS2 Metadata Project 2009 / M. Mauch, C. Cannam, M. Davies [и др.] // Late-breaking session at the 10th International Conference on Music Information Retrieval, Kobe, Japan. 2009.

87. RWC Music Database: Popular, Classical and Jazz Music Databases / Masataka Goto, Hiroki Hashiguchi, Takuichi Nishimura [и др.] // ISMIR. 2002.

88. Burgoyne John Ashley, Wild Jonathan, Fujinaga Ichiro. An Expert Ground Truth Set for Audio Chord Recognition and Music Analysis // Proceedings of the 12th International Society for Music Information Retrieval Conference, ISMIR 2011, Miami, Florida, USA, October 24-28, 2011 / под ред. Anssi Klapuri, Colby Leider. University of Miami, 2011. С. 633–638.

89. A Large-Scale Evaluation of Acoustic and Subjective Music-Similarity Measures / Adam Berenzweig, Beth Logan, Daniel P. W. Ellis [и др.] // Comput. Music J. Cambridge, MA, USA, 2004. June. Т. 28, № 2. С. 63–76. URL: http://dx.doi.org/10.1162/014892604323112257.

90. Harte C. Towards Automatic Extraction of Harmony Information from Music Signals. Ph.D. thesis: Queen Mary University of London, Centre for Digital Music. 2010.

91. Johan Pauwels Geoffroy Peeters. Evaluating automatically estimated chord sequences // Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP-13). Vancouver, Canada: 2013. May 26-31.

92. Mauch Matthias. Automatic Chord Transcription from Audio Using Computational Models of Musical Context. Ph.D. thesis: Queen Mary University of London. 2010.

93. Downie Stephen J. The music information retrieval evaluation exchange (2005-2007): A window into music information retrieval research // Acoustical Science and Technology. 2008. Т. 29, № 4. С. 247–255. URL: http://www.jstage.jst.go.jp/article/ast/29/4/29_247/_article.

94. Beat Tracking for Multiple Applications: A Multi-Agent System Architecture With State Recovery / João Lobato Oliveira, Matthew E. P. Davies, Fabien Gouyon [и др.] // IEEE Transactions on Audio, Speech & Language Processing. 2012. Т. 20, № 10. С. 2696–2706.

95. Theano: a CPU and GPU Math Expression Compiler / James Bergstra, Olivier Breuleux, Frédéric Bastien [и др.] // Proceedings of the Python for Scientific Computing Conference (SciPy). 2010. June. Oral Presentation.

96. MIREX 2013: Audio Chord Estimation Results MIREX 2009. 2013. November. URL: http://www.music-ir.org/mirex/wiki/2013:Audio_Chord_Estimation_Results_MIREX_2009.

97. MIREX 2013: Audio Chord Estimation Results Billboard 2012. 2013. November. URL: http://www.music-ir.org/mirex/wiki/2013:Audio_Chord_Estimation_Results_Billboard_2012.

98. MIREX 2013: Audio Chord Estimation Results Billboard 2013. 2013. November. URL: http://www.music-ir.org/mirex/wiki/2013:Audio_Chord_Estimation_Results_Billboard_2013.

Приложение А

Результаты распознавания аккордов в используемой коллекции

Результаты отсортированы по названию композиции в алфавитном порядке.

Таблица А.1: Результаты распознавания аккордов

Композиция	WAOR	Сегментация	Длительность (с)
01 A Kind Of Magic	0.9578	0.9071	262.51
01 Bohemian Rhapsody	0.6714	0.6840	358.29
01 - A Hard Day's Night	0.9310	0.9064	152.56
01 - Come Together	0.6542	0.7233	260.65
01 - Drive My Car	0.7811	0.8798	150.28
01 - Help!	0.8965	0.8953	141.09
01 - It Won't Be Long	0.6765	0.8537	133.75
01 - I Saw Her Standing There	0.8933	0.9255	175.80
01 - Magical Mystery Tour	0.8118	0.8829	171.83
01 - No Reply	0.9451	0.9247	137.85
01 - Sgt. Pepper's Lonely Hearts Club Band	0.9012	0.8844	122.69
01 - Spiel Mir Eine Alte Melodie	0.7955	0.8348	165.09
01 - Taxman	0.8175	0.7716	159.01
01 - Two of Us	0.8099	0.7536	216.69
02 Another One Bites The Dust	0.0300	0.6991	216.91
02 - All I've Got To Do	0.8850	0.8777	124.55
02 - Dig a Pony	0.8513	0.9160	234.81
02 - Eleanor Rigby	0.7034	0.8553	127.69
02 - I'm a Loser	0.8694	0.8108	153.52
02 - I Should Have Known Better	0.9003	0.7836	164.10
02 - Misery	0.9663	0.9663	110.18
02 - Norwegian Wood (This Bird Has Flown)	0.8546	0.5961	125.44
02 - Rawhide	0.6414	0.6744	215.98
02 - Something	0.8436	0.7803	183.01
02 - The Fool On The Hill	0.8630	0.6733	180.19
02 - The Night Before	0.9433	0.9114	156.71
02 - With A Little Help From My Friends	0.9402	0.8853	164.02
03 - Across the Universe	0.8838	0.8185	228.57
03 - All My Loving	0.9288	0.8983	129.57
03 - Anna (Go To Him)	0.8576	0.8863	177.58
03 - Baby's In Black	0.8367	0.6189	127.58
03 - Flying	0.8276	0.8948	136.99
03 - I'm Only Sleeping	0.9221	0.9135	181.68
03 - If I Fell	0.8818	0.8206	142.05
03 - Lucy In The Sky With Diamonds	0.7212	0.8060	208.46
03 - Maxwell's Silver Hammer	0.9205	0.5869	207.28
03 - She	0.7883	0.8979	158.67
03 - You've Got To Hide Your Love Away	0.8578	0.8522	131.45
03 - You Won't See Me	0.8021	0.7102	202.61
04 Fat Bottomed Girls	0.8130	0.7628	204.56
04 I Want It All	0.6387	0.8130	241.91
04 - Blue Jay Way	0.7467	0.5102	236.72
04 - Chains	0.9309	0.8768	146.49
04 - Don't Bother Me	0.8373	0.8960	149.39
04 - Erbauliche Gedanken Eines Tobackrauchers	0.5365	0.8059	342.73
04 - Getting Better	0.6542	0.6884	167.89
04 - I'm Happy Just To Dance With You	0.8080	0.8485	118.70
04 - I Me Mine	0.6243	0.8651	145.74
04 - I Need You	0.7505	0.6959	151.51
04 - Love You To	0.1257	0.8444	181.21
04 - Nowhere Man	0.8437	0.8426	164.31

04 - Oh! Darling	0.8771	0.8817	206.71
04 - Rock and Roll Music	0.9684	0.9504	153.76
05 Bicycle Race	0.5654	0.8317	183.80
05 I Want To Break Free	0.8927	0.8293	258.73
05 - Andersrum	0.7307	0.8096	122.46
05 - And I Love Her	0.8645	0.9488	151.09
05 - Another Girl	0.8200	0.8397	128.03
05 - Boys	0.8289	0.8415	147.51
05 - Dig It	0.7584	0.7942	50.02
05 - Fixing A Hole	0.7596	0.4400	156.63
05 - Here There And Everywhere	0.7580	0.8599	145.87
05 - I'll Follow the Sun	0.9328	0.8695	111.05
05 - Little Child	0.9059	0.8569	108.02
05 - Octopus's Garden	0.9214	0.9342	171.18
05 - Think For Yourself	0.8988	0.9622	139.34
05 - Your Mother Should Know	0.9037	0.9089	149.60
06 You're My Best Friend	0.7739	0.8099	172.17
06 - Ask Me Why	0.8777	0.8269	147.77
06 - I Am The Walrus	0.8370	0.8889	277.08
06 - I Want You	0.7398	0.8296	467.17
06 - Let It Be	0.8369	0.7683	243.33
06 - Mr. Moonlight	0.6972	0.5817	157.20
06 - She's Leaving Home	0.7633	0.8482	215.07
06 - Tell Me Why	0.7196	0.7479	130.09
06 - The Word	0.8277	0.8254	163.71
06 - Tigerfest	0.7215	0.7553	203.28
06 - Till There Was You	0.8781	0.8192	136.75
06 - Yellow Submarine	0.8222	0.6384	160.42
06 - You're Going to Lose That Girl	0.9470	0.9225	140.46
07 Don't Stop Me Now	0.7457	0.8452	211.73
07 - Akne	0.7644	0.8075	203.60
07 - Being For The Benefit Of Mr. Kite!	0.7671	0.7536	157.10
07 - Can't Buy Me Love	0.9033	0.9001	134.95
07 - Hello Goodbye	0.8268	0.7873	211.49
07 - Here Comes The Sun	0.8489	0.8213	185.57
07 - Kansas City- Hey Hey Hey Hey	0.8752	0.9097	153.47
07 - Maggie Mae	0.8175	0.8516	40.62
07 - Michelle	0.7714	0.8876	162.38
07 - Please Mister Postman	0.8820	0.9369	156.73
07 - Please Please Me	0.8759	0.8498	123.38
07 - She Said She Said	0.8068	0.7518	157.15
07 - Ticket To Ride	0.8413	0.8999	192.50
08 Save Me	0.8378	0.8910	228.60
08 - Act Naturally	0.9380	0.9049	153.18
08 - Any Time At All	0.8668	0.8736	133.41
08 - Because	0.6805	0.8765	165.54
08 - Blass	0.8176	0.8598	171.99
08 - Eight Days a Week	0.8943	0.8376	165.43
08 - Good Day Sunshine	0.9439	0.9281	129.78
08 - I've Got A Feeling	0.7608	0.6720	217.97
08 - Love Me Do	0.8837	0.8045	142.76
08 - Roll Over Beethoven	0.7674	0.7724	167.63
08 - Strawberry Fields Forever	0.7252	0.7965	250.57
08 - What Goes On	0.8868	0.8125	170.81
08 - Within You Without You	0.6071	0.3006	305.08
09 Crazy Little Thing Called Love	0.6625	0.7945	163.83
09 Who Wants To Live Forever	0.7622	0.8129	297.27
09 - And Your Bird Can Sing	0.9445	0.8108	121.76
09 - Girl	0.8637	0.8030	153.89
09 - Hold Me Tight	0.8518	0.8257	152.58
09 - I'll Cry Instead	0.9096	0.8658	107.76
09 - It's Only Love	0.9145	0.8649	118.80
09 - Mr Morgan	0.7298	0.6543	183.33
09 - One After 909	0.8621	0.8179	175.52
09 - P. S. I Love You	0.9291	0.8478	125.75
09 - Penny Lane	0.7541	0.7133	183.38
09 - When I'm Sixty-Four	0.8768	0.8206	157.73
09 - Words of Love	0.8556	0.8710	134.74
09 - You Never Give Me Your Money	0.8258	0.8593	242.42
10 Somebody To Love	0.6919	0.7797	297.67
10 - Baby It's You	0.9276	0.9387	158.07
10 - Baby You're A Rich Man	0.7815	0.6997	183.77
10 - For No One	0.8458	0.8330	121.73
10 - Honey Don't	0.9060	0.7618	179.62
10 - I'm Looking Through You	0.7064	0.8680	147.83
10 - Liebesleid	0.6536	0.7930	266.40
10 - Lovely Rita	0.0061	0.8555	162.12
10 - Sun King	0.8621	0.8217	146.31
10 - The Long and Winding Road	0.8398	0.8523	217.89
10 - Things We Said Today	0.7989	0.4869	158.85

10 - You Like Me Too Much	0.9313	0.8554	158.82
10 - You Really Got A Hold On Me	0.8858	0.8473	182.91
11 - All You Need Is Love	0.7326	0.8079	228.44
11 - Doctor Robert	0.9112	0.7594	135.21
11 - Do You Want To Know A Secret	0.7892	0.9047	119.35
11 - Every Little Thing	0.8424	0.6798	124.55
11 - For You Blue	0.8953	0.8829	152.74
11 - Good Morning Good Morning	0.6943	0.7670	161.62
11 - Ich Kann Heute Nicht	0.7730	0.8556	138.34
11 - In My Life	0.8793	0.8309	147.98
11 - I Wanna Be Your Man	0.8453	0.8021	118.99
11 - Mean Mr Mustard	0.8832	0.9059	66.45
11 - Tell Me What You See	0.8237	0.7576	159.71
11 - When I Get Home	0.8483	0.8194	138.37
12 Good Old-Fashioned Lover Boy	0.6468	0.6835	175.83
12 - A Taste Of Honey	0.8329	0.7668	125.15
12 - Devil In Her Heart	0.8169	0.7401	147.67
12 - Get Back	0.6343	0.7534	187.09
12 - I've Just Seen a Face	0.8359	0.7700	127.19
12 - I Don't Want to Spoil the Party	0.8929	0.8292	156.19
12 - I Want To Tell You	0.7771	0.7659	149.89
12 - Jakob Und Marie	0.6508	0.7894	186.31
12 - Polythene Pam	0.8172	0.8654	72.96
12 - Sgt. Pepper's Lonely Hearts Club Band (Reprise)	0.7132	0.8519	78.92
12 - Wait	0.6850	0.6762	136.99
12 - You Can't Do That	0.8492	0.8505	157.65
13 Play The Game	0.7491	0.8234	213.31
13 - A Day In The Life	0.6223	0.8357	333.91
13 - Got To Get You Into My Life	0.7289	0.6463	150.65
13 - I'll Be Back	0.8245	0.8212	140.56
13 - If I Needed Someone	0.9395	0.8608	143.86
13 - Not A Second Time	0.6062	0.8465	128.34
13 - Paparazzi	0.7263	0.8859	234.63
13 - She Came In Through The Bathroom Window	0.7320	0.8534	117.73
13 - There's A Place	0.8859	0.9237	112.88
13 - What You're Doing	0.8649	0.9177	154.70
13 - Yesterday	0.7143	0.7557	127.45
14 Hammer To Fall	0.6031	0.2688	220.51
14 - Dizzy Miss Lizzy	0.9625	0.9695	174.27
14 - Everybody's Trying to Be My Baby	0.8942	0.7791	143.87
14 - Golden Slumbers	0.9792	0.8707	91.59
14 - Money	0.4779	0.6181	167.56
14 - Run For Your Life	0.9213	0.8527	138.80
14 - Santa Donna Lucia Mobile	0.7758	0.8222	100.83
14 - Tomorrow Never Knows	0.8506	0.6381	177.40
14 - Twist And Shout	0.9046	0.8782	153.27
15 Friends Will Be Friends	0.7462	0.9431	248.89
15 Seven Seas Of Rhye	0.7979	0.7199	170.47
15 - Carry That Weight	0.9022	0.7557	96.89
15 - Es Wird Alles Wieder Gut Herr Professor	0.7004	0.8042	152.32
16 We Will Rock You	0.2103	0.3011	122.77
16 - The End	0.6859	0.8434	139.83
16 - Zu Leise Fuer Mich	0.4538	0.6787	241.21
17 We Are The Champions	0.6104	0.8050	181.40
17 - Duell	0.6714	0.6959	237.35
17 - Her Majesty	0.6413	0.6738	23.27
18 - Zuhause	0.6381	0.7925	210.91
CD1 - 01 - Back in the USSR	0.8492	0.8859	163.32
CD1 - 02 - Dear Prudence	0.6810	0.5145	236.38
CD1 - 03 - Glass Onion	0.6885	0.7860	137.98
CD1 - 04 - Ob-La-Di Ob-La-Da	0.9122	0.8281	188.84
CD1 - 05 - Wild Honey Pie	0.6382	0.8294	52.92
CD1 - 06 - The Continuing Story of Bungalow Bill	0.7371	0.6783	194.32
CD1 - 07 - While My Guitar Gently Weeps	0.8468	0.9020	285.31
CD1 - 08 - Happiness is a Warm Gun	0.8655	0.8783	163.47
CD1 - 09 - Martha My Dear	0.8278	0.8572	148.74
CD1 - 10 - I'm So Tired	0.8741	0.9122	123.32
CD1 - 11 - Black Bird	0.6794	0.7009	138.29
CD1 - 12 - Piggies	0.9057	0.9200	124.34
CD1 - 13 - Rocky Raccoon	0.7966	0.8887	212.90
CD1 - 14 - Don't Pass Me By	0.9018	0.8213	230.43
CD1 - 15 - Why Don't We Do It In The Road	0.8614	0.8394	101.46
CD1 - 16 - I Will	0.9032	0.9183	106.03
CD1 - 17 - Julia	0.9259	0.8556	174.20
CD2 - 01 - Birthday	0.6563	0.7498	162.93
CD2 - 02 - Yer Blues	0.6718	0.7309	241.11
CD2 - 03 - Mother Nature's Son	0.7056	0.6129	168.05
CD2 - 04 - Everybody's Got Something To Hide Except Me and My Monkey	0.6448	0.5629	144.82
CD2 - 05 - Sexy Sadie	0.9074	0.9322	195.34
CD2 - 06 - Helter Skelter	0.6492	0.6597	269.69

CD2 - 07 - Long Long Long	0.7892	0.7559	184.35
CD2 - 08 - Revolution	0.9003	0.8523	255.74
CD2 - 09 - Honey Pie	0.8990	0.8901	161.36
CD2 - 10 - Savoy Truffle	0.8275	0.7591	174.92
CD2 - 11 - Cry Baby Cry	0.8056	0.8834	181.89
CD2 - 12 - Revolution 9	0.1415	0.4334	502.36
CD2 - 13 - Good Night	0.8176	0.8353	191.80
N001-M01-T01	0.8280	0.8659	209.21
N002-M01-T02	0.6275	0.8107	222.71
N003-M01-T03	0.6542	0.8059	195.36
N004-M01-T04	0.6469	0.7380	242.51
N005-M01-T05	0.8105	0.8678	228.11
N006-M01-T06	0.6507	0.7897	206.57
N007-M01-T07	0.8225	0.9444	298.68
N008-M01-T08	0.7509	0.8096	192.19
N009-M01-T09	0.9080	0.8245	277.04
N010-M01-T10	0.8237	0.9265	215.69
N011-M01-T11	0.7040	0.7602	267.92
N012-M01-T12	0.8139	0.8668	204.87
N013-M01-T13	0.8494	0.8926	219.09
N014-M01-T14	0.9198	0.9219	234.95
N015-M01-T15	0.8143	0.9198	162.89
N016-M01-T16	0.7617	0.7954	262.15
N017-M02-T01	0.8105	0.8852	241.44
N018-M02-T02	0.7176	0.7292	254.11
N019-M02-T03	0.8666	0.8932	289.04
N020-M02-T04	0.7739	0.8687	250.15
N021-M02-T05	0.8237	0.9302	268.96
N022-M02-T06	0.8381	0.9118	209.52
N023-M02-T07	0.8543	0.8741	201.19
N024-M02-T08	0.4588	0.6912	240.25
N025-M02-T09	0.3705	0.7735	256.47
N026-M02-T10	0.8445	0.9133	207.05
N027-M02-T11	0.7704	0.7863	318.44
N028-M02-T12	0.5260	0.6525	250.99
N029-M02-T13	0.9017	0.9237	215.09
N030-M02-T14	0.4691	0.7517	196.29
N031-M02-T15	0.3552	0.7684	250.21
N032-M02-T16	0.7635	0.9381	252.08
N033-M03-T01	0.4796	0.5254	287.01
N034-M03-T02	0.9078	0.9237	207.64
N035-M03-T03	0.8855	0.8867	193.03
N036-M03-T04	0.7673	0.7702	316.25
N037-M03-T05	0.6664	0.9032	239.11
N038-M03-T06	0.6645	0.8566	275.33
N039-M03-T07	0.8695	0.9221	288.85
N040-M03-T08	0.7189	0.5712	226.25
N041-M03-T09	0.3308	0.9222	170.13
N042-M03-T10	0.6329	0.6849	248.76
N043-M03-T11	0.8235	0.9000	204.31
N044-M03-T12	0.8356	0.8437	246.08
N045-M03-T13	0.8121	0.9442	222.53
N046-M03-T14	0.8764	0.8895	199.01
N047-M03-T15	0.9391	0.9527	210.75
N048-M03-T16	0.8355	0.8638	269.59
N049-M04-T01	0.6869	0.8255	275.05
N050-M04-T02	0.6914	0.7956	195.40
N051-M04-T03	0.8930	0.9380	367.36
N052-M04-T04	0.6373	0.7542	225.45
N053-M04-T05	0.8579	0.6617	219.77
N054-M04-T06	0.8722	0.9184	222.92
N055-M04-T07	0.8801	0.9526	249.17
N056-M04-T08	0.9463	0.9476	322.96
N057-M04-T09	0.8113	0.8258	267.17
N058-M04-T10	0.5980	0.8699	225.96
N059-M04-T11	0.8999	0.8546	205.01
N060-M04-T12	0.8694	0.8792	243.51
N061-M04-T13	0.6991	0.8610	283.16
N062-M04-T14	0.9176	0.9561	191.11
N063-M04-T15	0.8749	0.8618	251.00
N064-M04-T16	0.8203	0.8991	292.47
N065-M05-T01	0.8610	0.8667	232.05
N066-M05-T02	0.6300	0.8518	320.60
N067-M05-T03	0.8625	0.9240	250.69
N068-M05-T04	0.8653	0.8208	294.25
N069-M05-T05	0.7929	0.9262	360.36
N070-M05-T06	0.8016	0.8035	246.72
N071-M05-T07	0.6964	0.9047	286.45
N072-M05-T08	0.7529	0.7597	201.37
N073-M05-T09	0.6570	0.8384	136.48

N074-M05-T10	0.9119	0.9009	194.31
N075-M05-T11	0.7625	0.7602	201.97
N076-M05-T12	0.7372	0.8099	230.89
N077-M05-T13	0.6923	0.8592	236.17
N078-M05-T14	0.7665	0.8579	261.24
N079-M05-T15	0.8109	0.8349	268.37
N080-M05-T16	0.7724	0.9157	219.09
N081-M06-T01	0.8823	0.8624	230.81
N082-M06-T02	0.8419	0.9236	337.08
N083-M06-T03	0.6334	0.7374	217.41
N084-M06-T04	0.5809	0.8818	280.43
N085-M06-T05	0.8954	0.9459	210.49
N086-M06-T06	0.8905	0.9109	257.85
N087-M06-T07	0.7501	0.8079	291.27
N088-M06-T08	0.6897	0.8455	249.56
N089-M06-T09	0.8359	0.8438	223.40
N090-M06-T10	0.8322	0.8885	277.73
N091-M07-T01	0.9061	0.8698	223.85
N092-M07-T02	0.5612	0.7689	220.42
N093-M07-T03	0.8156	0.8806	258.85
N094-M07-T04	0.6515	0.9152	223.94
N095-M07-T05	0.5847	0.6851	232.83
N096-M07-T06	0.7168	0.8852	280.01
N097-M07-T07	0.6141	0.6306	243.15
N098-M07-T08	0.6920	0.7406	211.93
N099-M07-T09	0.6362	0.7567	317.26
N100-M07-T10	0.8971	0.9321	293.41